Estratégia Concursos

Aula 19

Polícia Federal (Agente de Polícia) Passo Estratégico de Informática - Prof. Thiago Cavalcanti

Autor:

Thiago Rodrigues Cavalcanti

06 de Abril de 2023

98276239072 - FABIANO CARBONELL DA SILVA

Banco de dados relacionais: conceitos básicos e características. Chaves e relacionamentos. Noções de mineração de dados: conceituação e características

Sumário

Análise Estatística 2
Roteiro de revisão e pontos do assunto que merecem destaque 3
Banco de dados relacionais: conceitos básicos e características 3
Metadados 7
Tabelas, visões (views) e índices 7
Chaves e relacionamentos 13
Noções de mineração de dados 15
Conceitos básicos: Mineração de Dados 16
Processo de mineração e modelo de referência CRISP-DM 19
Técnicas de pré-processamento 25
Tarefas de mineração 26
Regras de associação 26
Classificação 28
Agrupamento (Clustering) 30
Abordagem para outros problemas de mineração 31
Conceitos Complementares 32
Aposta estratégica 34
Banco de dados relacionais: conceitos básicos e características 35

98276239072 - FABIANO CARBONELL DA SILVA

Metadados 35
Tabelas (Restrições de integridade) 36
Chaves e relacionamentos 38
Mineração de dados 38
CRISP-DM 39
Técnicas e tarefas de mineração de dados 39
Principais tarefas de mineração 40
Questões estratégicas 40
Questionário de revisão e aperfeiçoamento 54
Perguntas 55
Perguntas com respostas 55

ANÁLISE ESTATÍSTICA

Assunto	Grau de incidência em concursos similares Cebraspe
4 Conceitos de proteção e segurança. 4.1 Noções de vírus, worms e pragas virtuais. 4.2 Aplicativos para segurança (antivírus, firewall, anti-spyware etc.). 5 Computação na nuvem (cloud computing).	15,07%
3 Redes de computadores. 10 Redes de comunicação. 10.1 Introdução a redes (computação/telecomunicações). 10.2 Camada física, de enlace de dados e subcamada de acesso ao meio. 10.3 Noções básicas de transmissão de dados: tipos de enlace, códigos, modos e meios de transmissão. 11 Redes de computadores: locais, metropolitanas e de longa distância. 11.1 Terminologia e aplicações, topologias, modelos de arquitetura (OSI/ISO e TCP/IP) e protocolos. 11.2 Interconexão de redes, nível de transporte.	13,33%
1 Conceito de internet e intranet. 2 Conceitos e modos de utilização de tecnologias, ferramentas, aplicativos e procedimentos associados a internet/intranet.	9,86%
2.1 Ferramentas e aplicativos comerciais de navegação.	9,86%

98276239072 - FABIANO CARBONELL DA SILVA

2.2 Noções de sistema operacional (ambiente Windows).	9,86%
2.4 Edição de planilhas (ambientes Microsoft Office e LibreOffice).	6,96%
2.1 Ferramentas e aplicativos comerciais de correio eletrônico, de grupos de discussão, de busca, de pesquisa e de redes sociais.	6,09%
2.4 Edição de textos (ambientes Microsoft Office e LibreOffice).	6,09%
9.4 Banco de dados relacionais: conceitos básicos e características. 9.5 Chaves e relacionamentos. 9.6 Noções de mineração de dados: conceituação e características.	5,22%
2.2 Noções de sistema operacional (ambiente Linux).	4,06%
6 Fundamentos da Teoria Geral de Sistemas. 7 Sistemas de informação. 7.1 Fases e etapas de sistema de informação. 8 Teoria da informação. 8.1 Conceitos de informação, dados, representação de dados, de conhecimentos, segurança e inteligência.	3,48%
9 Banco de dados. 9.1 Base de dados, documentação e prototipação. 9.2 Modelagem conceitual: abstração, modelo entidaderelacionamento, análise funcional e administração de dados. 9.3 Dados estruturados e não estruturados.	3,19%
2.3 Acesso à distância a computadores, transferência de informação e arquivos, aplicativos de áudio, vídeo e multimídia.	2,61%
9.7 Noções de aprendizado de máquina. 9.8 Noções de bigdata: conceito, premissas e aplicação.	2,03%
2.4 Edição de apresentações (ambientes Microsoft Office e LibreOffice).	1,45%
12 Noções de programação Python e R. 13 API (application programming interface). 14 Metadados de arquivos.	0,87%

ROTEIRO DE REVISÃO E PONTOS DO ASSUNTO QUE MERECEM DESTAQUE

A ideia desta seção é apresentar um roteiro para que você realize uma revisão completa do assunto e, ao mesmo tempo, destacar aspectos do conteúdo que merecem atenção.

Para revisar e ficar bem preparado no assunto, você precisa, basicamente, seguir os passos a seguir:

Banco de dados relacionais: conceitos básicos e características

O modelo relacional retrata os dados como sendo armazenados em **tabelas retangulares bidimensionais**, chamadas de **relações**, similares ao formato no qual a informação é mostrada por programas de planilha. A figura abaixo mostra um exemplo de uma relação, mais especificamente a relação aluno. Perceba que as linhas da tabela são chamadas de tuplas e as colunas descreve os atributos da relação.

98276239072 - FABIANO CARBONELL DA SILVA

Atributos

Nome da relação

ALUNO

Tuplas

Nome	Cpf	Telefone_residencial	Endereco	Telefone_comercial	Idade	Media
Bruno Braga	305.610.243-51	(17)3783-1616	Rua das Paineiras, 2918	NULL	19	3,21
Carlos Kim	381.620.124-45	(17)3785-4409	Rua das Goiabeiras, 125	NULL	18	2,89
Daniel Davidson	422.111.232-70	NULL	Avenida da Paz, 3452	(17)4749-1253	25	3,53
Roberta Passos	489.220.110-08	(17)3476-9821	Rua da Consolação, 265	(17)3749-6492	28	3,93
Barbara Benson	533.690.123-80	(17)3239-8461	Rua Jardim, 7384	NULL	19	3,25

Na terminologia formal do modelo relacional, uma **linha** é chamada de **tupla**, um **cabeçalho da coluna** é chamado de **atributo** e a **tabela** é chamada de **relação**. O tipo de dado que descreve os tipos de valores que podem aparecer em cada coluna é representado por **um domínio de valores** possíveis.

Um sistema de banco de dados relacional é responsável por armazenar dados de forma confiável e permitir fácil recuperação e atualização desses dados e **neste caso armazena dados de forma relacional, isto é, na forma de linhas e colunas em tabelas.**

Já sabemos que um banco de dados é uma **coleção de dados persistentes** que podem ser **compartilhados** e **estar inter-relacionados**. Ou seja, os dados são armazenados de modo permanente, como em um disco magnético. Ele também pode ter múltiplas aplicações e usuários, fazendo acesso aos dados armazenados. Tais dados são vistos como unidades separadas e podem ser ligados para fornecer um quadro completo.

Os sistemas de banco de dados relacionais foram desenvolvidos originalmente por causa da **familiaridade** e **simplicidade**. Como as tabelas são utilizadas para comunicar ideias em vários campos do conhecimento, a terminologia de tabelas, linhas e colunas é facilmente compreendida por diferentes usuários. No modelo, **tanto os dados quanto os relacionamentos são representados em tabelas ou relações**.

Além da familiaridade e simplicidade dos bancos de dados relacionais, há também **uma sólida base matemática**. A matemática dos bancos de dados relacionais implica a conceitualização de tabelas como **conjuntos**. O modelo tem uma base formal sólida, que está estruturada na **teoria dos conjuntos e na lógica de primeira ordem**.

A combinação de familiaridade e simplicidade com a base matemática é tão poderosa, que os SGBDs relacionais são **líderes no mercado de armazenamento de dados operacionais**. O modelo relacional é constantemente descrito como tendo os três aspectos a seguir:

Aspecto estrutural: os dados no banco de dados **são percebidos pelo usuário como tabelas**, e nada além de tabelas.

98276239072 - FABIANO CARBONELL DA SILVA

Aspecto de integridade: essas tabelas satisfazem a certas restrições de integridade ou **limitações nos valores**, que podem aparecer em cada registro.
Aspecto manipulador: os **operadores** disponíveis para que o usuário possa **manipular** essas **tabelas** – por exemplo, para propósitos de busca de dados – são operadores que derivam tabelas a partir de outras tabelas. Desses operadores, três particularmente importantes são os operadores de restrição, projeção e junção.

Ok! Vamos sair do texto puro e observar uma figura. Ela vai nos ajudar a entender esses conceitos de forma bem mais tranquila. Veja a figura abaixo:

Tabela Professor (**aspecto estrutural**)

Identidade	Nome	Concurso	Comida Favorita
0000001	Eduardo (Dudu)	ICMS-SP	Pudim
0000002	Rosenval Junior	IBAMA	Churrasco
0000003	Ricardo Vale	MIDC	Salada
0000004	Paulo Bilynskyj	Delegado (DHPP)	McDonald´s

Colunas:
Identidade (numérica)
Comida favorita (texto)
(**aspecto de integridade**)

Operação:
Projeção com as colunas
Nome e Comida Favorita
(**aspecto manipulador**)

Nome	Comida Favorita
Eduardo (Dudu)	Pudim
Rosenval Junior	Churrasco
Ricardo Vale	Salada
Paulo Bilynskyj	McDonald´s

O modelo relacional é um modelo de dado **representativo** (ou de **implementação**). Como um modelo, ele procura abstrair e organizar os dados de um banco de dados. Para isso, o modelo relacional define um conjunto de conceitos para representação dos dados. O elemento básico deste modelo está definido pelo conceito **de relação**. Um banco de dados seria, portanto, um conjunto de relações. Cada relação pode ser vista como **uma tabela**. Assim, os SGBDs relacionais devem representar os dados sob a forma de **tabelas bidimensionais** organizadas em linhas e colunas.

Observe que os sistemas relacionais só exigem que o banco de dados seja percebido pelo usuário como tabelas. As tabelas são a **estrutura lógica** em um sistema relacional, **não** a **estrutura física**. No nível físico, os dados podem ser organizados em outros tipos de estrutura – usando arquivos sequenciais, indexação, *hashing*, cadeias de ponteiros, etc. – desde que ele **possa mapear essa representação armazenada como tabelas no nível lógico.** **Isso é um reflexo da abstração provida pelo modelo relacional.**

O termo estrutura lógica pretende englobar os níveis conceitual e externo da arquitetura ANSI/SPARC. O detalhe é que os níveis conceitual e externo em um **sistema relacional** serão representados usando o modelo relacional. Os bancos de dados relacionais satisfazem a um princípio muito interessante, chamado **Princípio da Informação**:

98276239072 - FABIANO CARBONELL DA SILVA

Todo o conteúdo de informação do banco de dados é representado de um e somente um modo, ou seja, como valores explícitos em posições de colunas em linhas de tabelas.

Veja que os valores são armazenados em uma tabela. Vamos olhar, mais uma vez, para uma imagem e tentar esclarecer, de uma vez por todas, essa característica. Olhe para o modelo abaixo e perceba que temos duas tabelas: empregado (EMP) e departamento (DEPTO). Perceba que a coluna DEPTO# da tabela EMP possui os valores dos departamentos.

DEPTO

DEPTO#	NOMEDEPTO	ORÇAMENTO
D1	Marketing	10M
D2	Desenvolvimento	12M
D3	Pesquisa	5M

EMP

EMP#	NOMEEMP	DEPTO#	SALÁRIO
E1	Lopez	D1	40K
E2	Cheng	D1	42K
E3	Finzi	D2	30K
E4	Saito	D2	35K

Sendo assim, existe uma conexão entre a linha D1 da tabela DEPTO e a linha E1 da tabela EMP. Essa conexão é representada pelo **aparecimento do valor D1** na tabela EMP. Vamos agora resumir os conceitos que vimos até aqui.

RESUMINDO

98276239072 - FABIANO CARBONELL DA SILVA

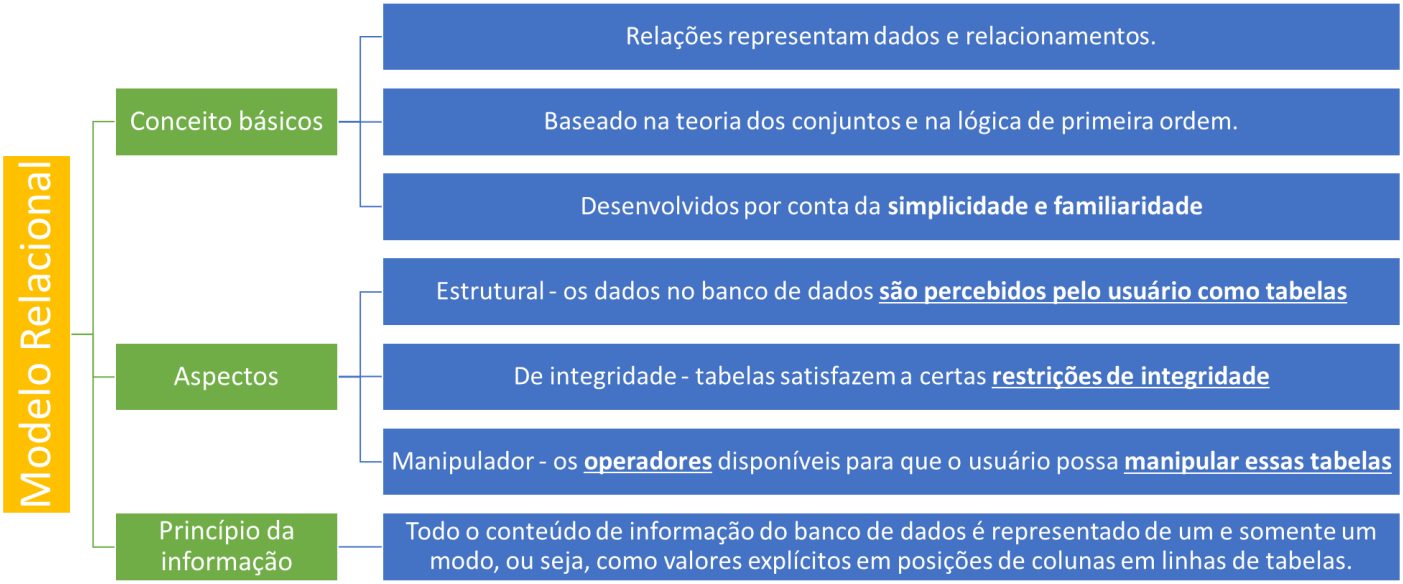

Metadados

Metadados: dados que descrevem outros dados incluindo a fonte, o uso, o valor e o significado dos dados. O Sistema de Gerenciamento de Banco de Dados precisa fornecer uma **função de catálogo ou dicionário**. O catálogo é o lugar em que – dentre outras coisas – todos os diversos esquemas (externo, conceitual, interno) e todos os mapeamentos correspondentes (externo/conceitual, conceitual/interno) são mantidos.

Em outras palavras, o catálogo contém informações detalhadas. Às vezes, elas são chamadas informações do descritor ou metadados, com objetos *RelVars*, índices, usuários, restrições de integridade, restrições de segurança, e assim por diante.

As informações do descritor são essenciais para que o sistema faça seu trabalho de modo apropriado. Por exemplo, o otimizador utiliza informações do catálogo a respeito de índices e outras estruturas físicas de armazenamento, bem como muitas outras informações, para ajudá-lo a decidir como implementar as requisições do usuário. Da mesma forma, o subsistema de autorização utiliza informações do catálogo sobre usuários e restrições de segurança para conceder ou negar tais requisições.

O SGBD armazena as descrições das **construções e restrições do esquema** — também denominadas **metadados** — **no catálogo do SGBD**, de modo que o software do SGBD possa recorrer ao esquema sempre que precisar. O **esquema** às vezes é chamado de **intenção**, e um **estado do banco de dados** é chamado de **extensão do esquema**.

Tabelas, visões (views) e índices

Cada linha de uma tabela é conhecida como uma **tupla**, ou uma coleção de valores relacionados. Cada coluna é vista como **um atributo**, que possui um determinado conjunto de valores possíveis: **o domínio**. Um domínio é um conjunto de valores atômicos. A figura a seguir resume os conceitos vistos por meio da representação da **tabela Alunos**.

98276239072 - FABIANO CARBONELL DA SILVA

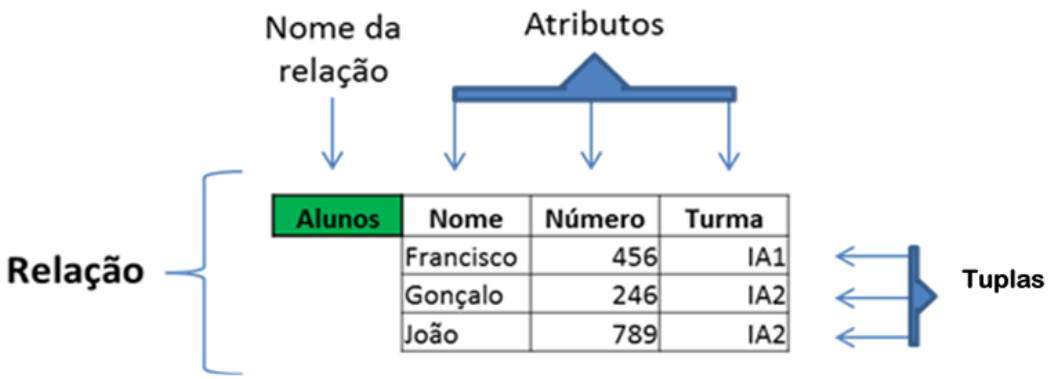

Percebam que a tabela é uma relação dentro do modelo de dados. Cada uma das colunas (Nome, Número e Turma) representa um atributo, que deve ser associado a cada uma das tuplas desta tabela. Cada linha descreve um aluno desta tabela. A primeira linha apresenta os dados de Francisco com seus respectivos número e turma.

Outra constatação que podemos fazer, a partir da figura anterior, é a presença de um conjunto de valores possíveis para cada uma das colunas. Não está explícito. Não sabemos a definição formal da tabela. Contudo, podemos observar que as tuplas desta relação apresentam apenas valores numéricos associados a coluna Número e caracteres associados a coluna Nome. É importante perceber que cada coluna possui um **tipo de dados**.

Um **tipo de dados** define os valores que um dado pode assumir e as operações que podem ser efetuadas sobre o mesmo. Tipos podem ser, por exemplo: inteiros, reais, caracteres, etc.

Quando especificamos **um domínio**, geralmente definimos um tipo de dado do qual são retirados os valores possíveis para o atributo. Além do tipo de dado, um domínio pode ser descrito por meio de um nome, um formato e outras informações adicionais a respeito dos dados. Apenas para exemplificar, um atributo **salário** pode ser definido como **um decimal positivo com 10 dígitos e seu valor ser definido em reais (R$)**.

Outra característica relevante associada ao domínio é o fato dele **ser atômico**. Isso **faz parte da definição do modelo relacional**. Não se esqueça disso! Outro ponto importante está relacionado à **integridade dos dados**. O modelo apresenta um conjunto de restrições básicas para dados e relacionamentos, conhecidas como **restrições de integridade**.

Ok! Temos as nossas relações! Conseguimos definir, pelo menos de forma gráfica, um conjunto de tabelas com seus atributos. Se quisermos, podemos povoar ou inserir tuplas nessas tabelas com seus respectivos dados. Agora, se eu quiser associar ou analisar os dados de mais de uma tabela conjuntamente, ou ainda, fazer uma consulta que me retorne apenas as tuplas ou linhas com uma certa restrição, o que devo fazer?

98276239072 - FABIANO CARBONELL DA SILVA

Os **operadores relacionais** são usados para manipular as informações pertencentes a cada uma das relações do nosso modelo. Esse conjunto de operações é conhecido como **álgebra relacional**. Ela vai nos ajudar a trabalhar com os dados em nossos esquemas relacionais.

Você deve estar lembrado que o esquema é considerado o projeto do banco de dados, a forma de bolo sobre a qual nossas instâncias são armazenadas. Assim, imagine uma tabela aluno com 100 alunos. O esquema vai definir os atributos necessários para cada linha da relação. Já as linhas são consideradas instâncias da tabela. Lembrando que as linhas podem ser denominadas **tuplas da tabela**. Que tal falarmos um pouco mais sobre elas?

Uma tupla deve conter um conjunto de elementos. Cada elemento deve conter o **nome** do atributo, o nome do **tipo** e um **valor**. Por exemplo:

TUPLA {**NOME**:**CARACTER**:**THIAGO**, **CARGO**:**CARACTER**:**PROFESSOR**}

Veja que cada um dos elementos do conjunto acima, por exemplo, **NOME**:**CARACTER**:**THIAGO,** corresponde a um **componente** da tupla e é conhecido como **tripla ordenada**. A quantidade de componentes de uma tupla é conhecida como **grau** ou aridez da tupla. Neste caso, o grau da nossa tupla é igual a 2.

Os dois primeiros valores, **NOME**:**CARACTER,** são vistos como um par ordenado e descrevem um atributo da tupla. Neste exemplo, **THIAGO** é o valor do atributo em questão. O conjunto completo de atributos é conhecido como **cabeçalho**, este vai determinar o **tipo de uma tupla.**

As tuplas satisfazem a uma série de **propriedades importantes**, todas elas consequências imediatas das definições apresentadas até aqui:

(a) Cada tupla contém exatamente um valor para cada um de seus atributos.

(b) Não existe ordenação da esquerda para a direita nos componentes de uma tupla. Essa propriedade acontece porque uma tupla é definida por meio de um conjunto de componentes, e os conjuntos na matemática não possuem qualquer ordenação em seus elementos.

(c) Cada subconjunto de uma tupla é uma tupla (e cada subconjunto de um cabeçalho é um cabeçalho). Mais que isso, essa afirmação também é válida para um subconjunto vazio em particular!

Esse último ponto merece uma explicação mais detalhada. Existe a tupla vazia (**TUPLA { }**). Às vezes, referimo-nos a uma tupla de grau zero mais explicitamente como uma **"0-tupla"**, a fim de enfatizar o fato de que ela não possui componentes. Outro nome conhecido é de tupla ***nulária***.

A relação é um **objeto formal**, enquanto a tabela é um **objeto informal** que pode ser representada em uma folha de papel. Vejamos algumas das diferenças entre tabelas e relações:

98276239072 - FABIANO CARBONELL DA SILVA

Característica	Relação	Tabela
Nomes de tipo são omitidos nos cabeçalhos.	**Não**	**Sim (normalmente)**
Nomes de tipo e do atributo normalmente são omitidos no corpo.	**Não**	**Sim**
Atributos/colunas possuem uma ordem da esquerda para a direita.	**Não**	**Sim**
As tuplas/linhas possuem uma ordem de cima para baixo.	**Não**	**Sim**
Pode conter tuplas/linhas duplicatas.	**Não**	**Sim**[1]

Falamos das propriedades importantes das tuplas. Neste momento, vamos falar das **propriedades importantes das relações**. Dentro de qualquer relação, temos as seguintes propriedades:

1. Cada tupla contém exatamente um valor (do tipo apropriado) para cada atributo. Trata-se da atomicidade dos atributos.
2. Atributos não são ordenados da esquerda para a direita. Essa propriedade acontece, pois uma tupla é definida em termos de conjuntos matemáticos, que não possuem ordenação dos seus elementos.
3. Tuplas não são ordenadas de cima para baixo.
4. Não existem tuplas duplicadas.

Visões

As views ou visões são objetos SQL, ou relacionais, que podemos criar dentro dos nossos bancos de dados. Uma VIEW é um comando SQL que é armazenado no banco de dados e possui um nome associada a ela. Podemos observar algumas funções básicas. A primeira é facilitar a visualização dos dados dispersos em diversas tabelas, tornando-os mais natural ou intuitivo ao entendimento humano.

Outra função importante para a *view* está relacionada à segurança dos dados. É possível restringir o acesso aos campos e às colunas de uma tabela por meio de uma *view*. Desta forma, o usuário teria visão apenas a parte dos dados ou das informações. Esse grupo de informações deve ser compatível com as funções e as necessidades de acesso do usuário.

[1] Neste caso, pense em uma tabela do Excel. Se estivermos falando de uma tabela no modelo relacional, ela não pode conter linhas duplicadas e todos os seus atributos devem ser atômicos.

98276239072 - FABIANO CARBONELL DA SILVA

Uma terceira opção para o uso de *view* é sumarizar dados de diferentes tabelas, gerando relatórios. Vejamos abaixo dois exemplos do uso de **Views**. Lembrando que ela pode ser criada sobre uma ou múltiplas tabelas. Observe que o comando, basicamente, inclui a sintaxe "CREATE VIEW nome AS" antes de uma consulta ao banco de dados (comando SELECT).

```
V1:  CREATE VIEW  TRABALHA_EM1
     AS SELECT    Pnome, Unome, Projnome,
                  Horas
        FROM      FUNCIONARIO, PROJETO,
                  TRABALHA_EM
        WHERE     Cpf=Fcpf AND Pnr=Projnumero;
V2:  CREATE VIEW  DEP_INFO(Dep_nome, Qtd_
                  func, Total_sal)
     AS SELECT    Dnome, COUNT (*), SUM
                  (Salario)
        FROM      DEPARTAMENTO, FUNCIONARIO
        WHERE     Dnumero=Dnr
        GROUP BY  Dnome;
```

Para visualizarmos os dados de uma visão, basta escrevermos um comando SELECT sobre ela, vejam o exemplo sobre a view **TRABALHA_EM1** criada acima.

```
SELECT   Pnome, Unome
FROM     TRABALHA_EM1
WHERE    Projnome='ProdutoX';
```

A view é considerada uma tabela virtual, porque ela só existe durante o período que você está utilizando-a. Todas as operações que são feitas sobre a tabela podem ser feitas em uma VIEW, mas a tabela é virtual e, na teoria, não deve ser armazenada no banco de dados.

Para finalizar, vamos comparar os conceitos de tabelas e visões de forma pragmática. A distinção entre uma **tabela básica** e uma visão é constantemente caracterizada desta maneira:

> Tabelas básicas "existem realmente", no sentido de que **representam dados de fato armazenados** no banco de dados.

98276239072 - FABIANO CARBONELL DA SILVA

> As visões, ao contrário, não "existem realmente", mas apenas oferecem diferentes modos de visualização dos "dados reais".

Índices

O primeiro conceito que devemos ter em mente sobre o assunto é a definição de índices. **Um índice é um mecanismo utilizado para melhorar a velocidade de acesso aos dados**. Ele é composto por uma chave, que é um atributo ou um conjunto de atributos usado para procurar registros em um arquivo. Um índice também possui um ponteiro, que consiste em um identificador para um bloco de disco, além do deslocamento dentro do bloco para encontrar o registro.

Um arquivo de índice consiste em um conjunto de registros com o formato apresentado na figura abaixo. A esse registro se dá o nome de registro de índice ou entrada de índice.

Como uma técnica para criar estruturas de dados auxiliares, os índices agilizam a busca e a recuperação de registros. Para isso, eles envolvem armazenamento de dados auxiliares. Esses dados são armazenados nos arquivos de índices. Alguns tipos de acesso podem se beneficiar dos índices, por exemplo, a localização de registro com um valor especificado e a localização de registros em um intervalo especificado de valores. Veja a figura abaixo para entender um pouco mais sobre índices:

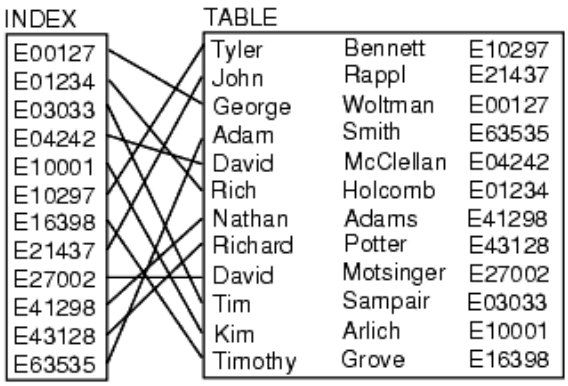

É necessário saber se esse benefício, de fato, traz um ganho de desempenho ao sistema de banco de dados. Avaliar os índices para medir seus efeitos na performance é um passo importante. Vários SGBDs possuem utilitários que ajudam a quantificar os efeitos pretendidos com a criação de índices sobre tabelas. Esse valor é baseado em alguns fatores, entre eles, o tempo de acesso, inserção e deleção; o overhead de espaço em disco e os métodos de acesso suportados.

Os índices podem ser classificados de acordo com a figura abaixo:

98276239072 - FABIANO CARBONELL DA SILVA

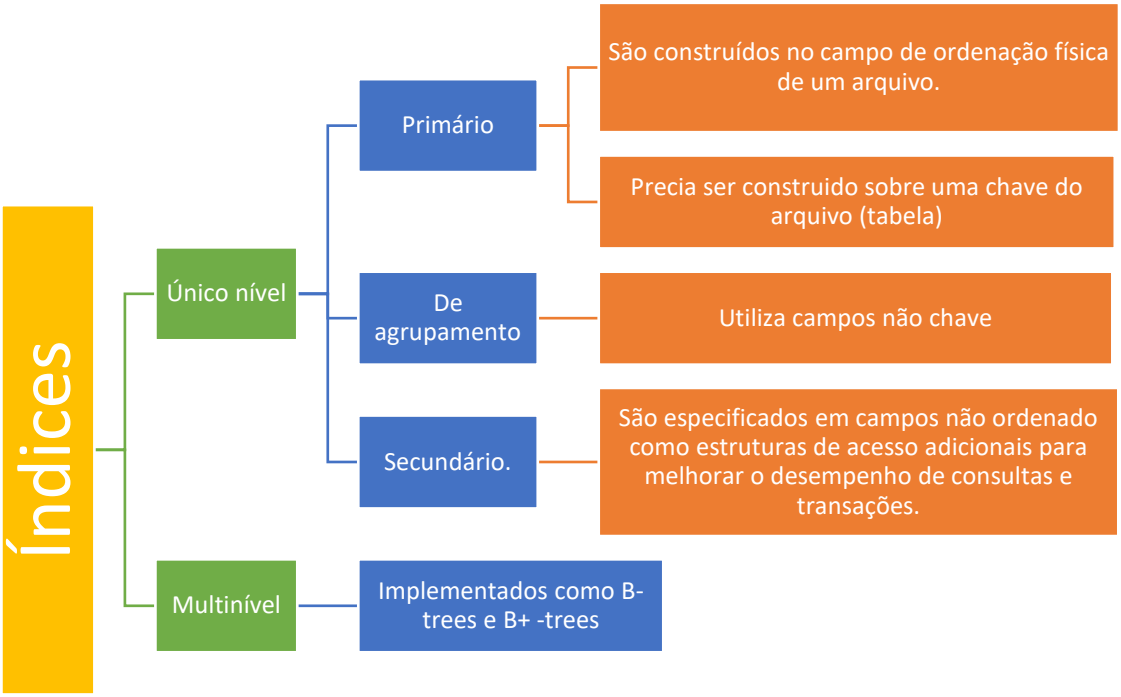

Chaves e relacionamentos

Superchave, chave, chave candidata, chave primária e chave estrangeira

Vamos começar falando sobre **chave**. Existem alguns conceitos relacionados à chave. O primeiro deles é o de **superchave**. Trata-se de uma coluna ou uma combinação de colunas contendo valores únicos para cada linha. A combinação de todas as colunas em uma tabela sempre é uma superchave, porque as linhas de uma relação devem ser sempre únicas.

Uma definição formal afirma que uma superchave de um esquema de relação R = $\{A_1, A_2, ..., A_n\}$ é um conjunto de atributos S C R (S está contido em R) que contenha a propriedade na qual não haverá duas tuplas t_1 e t_2, em qualquer estado válido da relação, cuja $t_1[S] = t_2[S]$. Em outras palavras, uma superchave é um conjunto de atributos que tem a característica de restringir o conjunto de tuplas de uma relação em apenas uma linha.

Quando olhamos para um conjunto de atributos em uma tabela que não se repetem em nenhuma das linhas da tabela, podemos considerá-los uma **superchave**.

Já entendemos o conceito de superchave. Uma superchave pode ser considerada apenas uma chave. Neste caso, a chave é defendida como uma **superchave mínima ou irredutível** (vou chama-la de K), onde qualquer remoção de atributo de K fará com que K deixe de ser superchave da relação. Se um esquema tiver mais de uma chave, cada uma delas é chamada de **chave candidata**. Entre as chaves candidatas, uma delas é escolhida para ser a chave da relação e é denominada **chave primária**. As demais são renegadas e são denominadas **chaves secundárias ou alternativas**.

Segundo o Date, se K for um conjunto de atributos de uma variável de relação R, então K é uma **chave candidata** para R, se e somente se, ela possui ambas as propriedades.

98276239072 - FABIANO CARBONELL DA SILVA

ATENÇÃO
DECORE!

Unicidade: Nenhum valor válido de R contém duas tuplas diferentes com o mesmo valor para K.
Irredutibilidade: Nenhum subconjunto apropriado de K tem a propriedade de unicidade.

De posse deste conhecimento, é possível definir o conceito de **atributo primário,** que nada mais é do que um atributo membro (que faz parte) de alguma ***chave candidata*** da relação (R). Por sua vez, de forma bem intuitiva, um **atributo não primário** é todo aquele que não for um atributo primário!

FIQUE
ATENTO!

Nesta parte da aula, gostaria que você fixasse o conceito de chave primária e estrangeira. Esse é um conceito importante dentro do assunto de banco de dados. A chave primária vai ser usada pelo SGBD na organização dos arquivos de dados. Isso significa que o acesso aos dados pode ser feito de forma mais rápida, usando o conjunto de atributos definido como chave primária.

O conjunto de atributos deve manter a propriedade de unicidade, ou seja, cada valor associado a uma chave primária só pode aparecer em uma linha da tabela. Olhe para a figura abaixo e me responda: quais campos podem ser usados como chave primária da tabela APROVADOS?

APROVADOS

Id_Aprovado	Nome	Municipio	CPF	Passaporte
1	Thiago	2611606	11111111111	111111
2	Flávia	2604106	22222222222	222222
3	Vinícius	2604106	33333333333	333333
4	Lucas	Null	44444444444	444444

Chave candidata

Chave primária

Chave Alternativa

Chave Estrangeira

Toda superchave com a propriedade de irredutibilidade.

A **chave candidata** **<u>designada</u>** para identificar as linhas de uma tabela.

Id_Municipio	Nome	Descrição
2611606	Recife	Veneza brasileira
2604106	Caruaru	Capital do forró

RESUMINDO

Atributos de uma relação cujos valores devem corresponder a valores de alguma chave candidata de alguma relação.

98276239072 - FABIANO CARBONELL DA SILVA

Se você pensou nos atributos Id_Aprovado, CPF e Passaporte, parabéns! Você pensou certo. Qualquer um destes campos pode ser usado como chave primária da tabela, por isso, eles são denominados **chaves candidatas**. No nosso exemplo, escolhemos o atributo Id_aprovado para ser usado como **chave primária** da relação Aprovados e o campo Id_Municipio para ser chave primária da relação MUNICIPIO. As outras chaves que foram preteridas podem ser denominadas **chave alternativa**.

Agora, vamos falar sobre **chave estrangeira**. Observe que, na relação aprovados, temos um campo denominado Municipio. Esse campo vai "apontar" para a chave primária da tabela Municipio (Id_Municipio). O que acontece aqui é que os valores presentes na coluna Municipio da tabela aprovados devem estar presentes na chave da tabela município. Outra opção é que o valor seja definido como desconhecido (nulo). Qualquer outro valor que apareça na coluna Municipio fere a integridade referencial. Neste caso, é como se você estivesse se referindo a um município não cadastrado. Isso fere a integridade referencial que vimos anteriormente.

A chave estrangeira é considerada uma coluna ou uma combinação de colunas em que os valores devem corresponder aos valores de uma chave candidata. A chave estrangeira deve ter tipo de dado igual ao da chave candidata associada. As chaves estrangeiras são usadas no modelo relacional para construir relacionamentos entre as tabelas.

É possível, ainda, um relacionamento em que a chave estrangeira aponta para a mesma tabela. Neste caso, temos um auto relacionamento. Os auto-relacionamentos representam associações entre membros do mesmo conjunto. Os auto-relacionamentos não são comuns, mas são importantes quando ocorrem. No banco de dados de uma universidade, um professor pode supervisionar outros professores e ser supervisionado por um professor. Veja o exemplo de um auto relacionamento na tabela abaixo:

Auto-relacionamento

CPFProf	NomeProf	SobrenomeProf	CidadeProf	UFProf	DeptoProf	ClassificacaoProf	SalarioProf	SupervisorProf	DataAdmProf	CEPProf
098-76-5432	LEONARD	VINCE	SEATTLE	WA	ADM	ASSISTENTE	R$35.000	654-32-1098	01-Abril-95	98111-9921
543-21-0987	VICTORIA	EMMANUEL	BOTHELL	WA	ADM	CATEDRATICO	R$120.000		01-Abril-96	98011-2242
654-32-1098	LEONARD	FIBON	SEATTLE	WA	ADM	ASSOCIADO	R$70.000	543-21-0987	01-Abril-95	98121-0094
765-43-2109	NICKI	MACON	BELLEVUE	WA	FINAN	CATEDRATICO	R$65.000		01-Abril-97	98015-9945
876-54-3210	CRISTOPHER	COLAN	SEATTLE	WA	ADM	ASSISTENTE	R$40.000	654-32-1098	01-Abril-99	98114-1332
987-65-4321	JULIA	MILLS	SEATTLE	WA	FINAN	ASSOCIADO	R$75.000	765-43-2109	01-Abril-00	98114-9954

Noções de mineração de dados

A **mineração de dados** é definida como o processo de **descoberta de padrões nos dados**. O processo deve ser automático ou (mais comumente) semiautomático. Os padrões descobertos devem ser significativos, pois levam a alguma vantagem - por exemplo, uma vantagem econômica. Os dados estão invariavelmente presentes em quantidades substanciais. E como os padrões são expressos?

98276239072 - FABIANO CARBONELL DA SILVA

Padrões úteis nos permitem fazer previsões não triviais sobre novos dados.

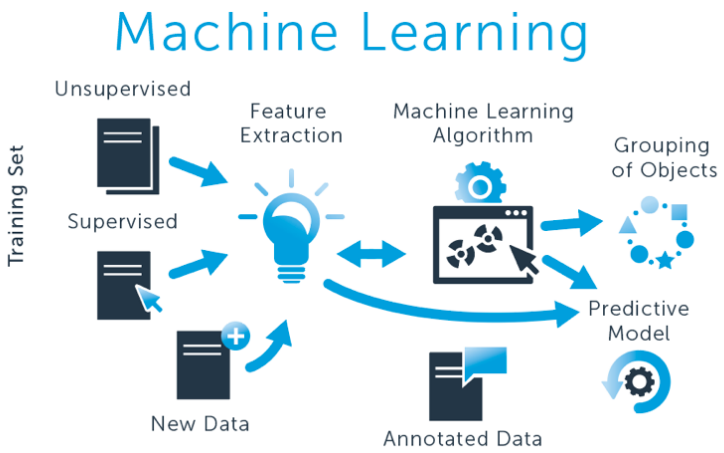

Há dois extremos para a expressão de um padrão: **uma caixa-preta** cujas entranhas são efetivamente incompreensíveis e **uma caixa transparente** cuja construção revela a **estrutura** do padrão. Ambos, estamos assumindo, fazem boas previsões. A diferença é se os padrões que são extraídos são ou não representados em termos de uma estrutura que pode ser examinada, fundamentada e usada para informar decisões futuras. Tais padrões nós chamamos de **estruturais** porque eles capturam a estrutura de decisão de uma maneira explícita. Em outras palavras, eles ajudam a explicar algo sobre os dados.

A **mineração de dados** é um tópico prático e envolve aprendizado de máquina em um sentido prático, não teórico. Estamos interessados **em técnicas para encontrar padrões em dados, padrões que forneçam insight ou possibilitem tomadas de decisão rápidas e precisas**.

Os dados tomarão a forma de um conjunto de exemplos - exemplos de clientes que trocaram a lealdade, por exemplo, ou situações em que certos tipos de lentes de contato podem ser prescritos. A saída toma a forma de previsões sobre novos exemplos - uma previsão sobre se um determinado cliente mudará ou uma previsão de que tipo de lente será prescrita sob determinadas circunstâncias.

Muitas técnicas de aprendizado procuram descrições estruturais do que é aprendido, descrições que podem se tornar bastante complexas e são tipicamente expressas como conjuntos de regras ou como árvores de decisão. Como elas podem ser entendidas pelas pessoas, essas descrições servem para explicar o que foi aprendido, em outras palavras, para explicar a base para novas previsões.

Conceitos básicos: Mineração de Dados

Começamos os conceitos tentando responder ao seguinte questionamento: O que é mineração de dados? Vários autores propuseram definições semelhantes para o termo, vejamos algumas delas:

1. Eduardo Gimenes: É o processo de **extrair informação válida**, previamente desconhecida e de máxima abrangência a partir de **grandes bases de dados**, usando-as para efetuar **decisões** cruciais.
2. Laudon&Laudon: **Análise** de grandes quantidades de **dados** a fim de encontrar **padrões e regras** que possam ser usadas para orientar a **tomada de decisões** e **prever o comportamento** futuro.
3. Mineração de dados, ou data mining, é o processo de análise de conjuntos de dados que tem por objetivo a descoberta de padrões interessantes e que possam representar informações úteis.

98276239072 - FABIANO CARBONELL DA SILVA

Como o nome indica, data mining se refere à mineração ou à descoberta de novas informações em função de padrões ou regras em grandes quantidades de dados. Para ser útil, na prática, a mineração de dados precisa ser realizada eficientemente em grandes arquivos e banco de dados.

Vejamos outras definições possíveis para o termo. "A mineração de dados é a aplicação de algoritmos específicos para extração de padrões a partir dos dados" de FAYYAD. "A mineração de dados se refere à extração, ou mineração, de conhecimento a partir de grandes quantidades de dados" de HAN e KAMBER.

Com o crescente avanço da quantidade de dados em todas as aplicações, a mineração de dados atende à necessidade iminente de uma análise de dados eficaz, escalável e flexível em nossa sociedade. A mineração de dados pode ser considerada como uma evolução natural da tecnologia da informação e uma confluência de várias disciplinas relacionadas e domínios de aplicação.

A mineração de dados é, portanto, o processo de descobrir padrões interessantes a partir de grandes quantidades de dados. Como um **processo** de descoberta de conhecimento, normalmente envolve **limpeza de dados, integração de dados, seleção de dados, transformação de dados, descoberta de padrões, avaliação de padrões e apresentação de conhecimento**.

Segundo HAN, uma visão multidimensional da mineração de dados descreve as principais dimensões como sendo dados, conhecimento, tecnologias e aplicativos.

A mineração de dados pode ser realizada em qualquer tipo de dados, desde que os dados sejam significativos para um aplicativo de destino, como dados do banco de dados, dados do data warehouse, dados transacionais e tipos de dados avançados. Os tipos de dados avançados incluem dados relacionados a tempo ou sequência, fluxos de dados, dados espaciais e espaço-temporais, dados de texto e multimídia, dados em gráfico e em rede e dados da Web.

Um **data warehouse** é um repositório para armazenamento em longo prazo de dados de várias origens, organizado de modo a facilitar a tomada de decisões gerenciais. Os dados são armazenados em um esquema unificado e geralmente são resumidos. Os sistemas de data warehouse fornecem recursos de análise de dados multidimensionais, coletivamente chamados de processamento analítico on-line (OLAP).

A mineração de dados multidimensional (também chamada de mineração de dados multidimensional exploratória) integra as técnicas de mineração de dados com a análise multidimensional baseada em OLAP. Ela procura padrões interessantes entre múltiplas combinações de dimensões (atributos) em níveis variados de abstração, explorando, assim, o espaço de dados multidimensional.

A mineração de dados, como um domínio altamente orientado a aplicativos, incorporou tecnologias de muitos outros domínios. Estes incluem **estatísticas**, **aprendizado de máquina**, **bancos de dados** e **sistemas de armazenamento de dados e recuperação de informações**. A natureza interdisciplinar da pesquisa e desenvolvimento de mineração de dados contribui significativamente para o sucesso da mineração de dados e suas extensas aplicações.

A mineração de dados tem muitos aplicativos de sucesso, como inteligência de negócios, pesquisa na Web, bioinformática, informática em saúde, finanças, bibliotecas digitais e governos digitais. Existem, ainda, muitos problemas desafiadores na pesquisa de mineração de dados. As áreas incluem metodologia de mineração,

98276239072 - FABIANO CARBONELL DA SILVA

interação com o usuário, eficiência e escalabilidade, além de lidar com diversos tipos de dados. A pesquisa de mineração de dados tem impactado fortemente a sociedade e continuará a fazê-lo no futuro.

Problemas onde as técnicas tradicionais poderiam não se ajustar à enorme quantidade de dados, à alta dimensionalidade dos dados e à heterogeneidade e natureza distribuídas dos dados podem aparecer no radar. Data Mining, então, surge para completar essa lacuna. Sua base teórica é uma mistura de diferentes disciplinas, como já falamos. Ok! Então, antes de começarmos a descrever o que mais faz parte da mineração de dados, vamos tratar do que alguns autores conhecem como falácias de Data Mining. São basicamente quatros:

Falácias de Data Mining

Data Mining é automático: é um processo, é iterativo, requer supervisão.

Investimentos são recuperados rapidamente: depende de muitos fatores!

Software são intuitivos e simples: é mais importante conhecer os conceitos dos algoritmos e o negócio em si!

Data Mining pode identificar problemas no negócio: DM pode encontrar padrões e fenômenos, identificar a causa deve ser feito por especialistas.

Podemos concluir, então, que existe um processo iterativo, que requer supervisão e depende de vários fatores para uma implementação de sucesso. É importante entender os algoritmos, as tarefas e o negócio. Assim, é possível encontrar os padrões e fenômenos sobre a massa de dados.

O uso da mineração de dados é, portanto, potencializada por alguns fatores: o volume de dados disponível atualmente é enorme, o fato de os dados estarem mais organizados, os recursos computacionais estão cada vez mais potentes, a competição empresarial exige técnicas mais modernas de decisão e os programas comerciais de mineração de dados já podem ser adquiridos.

Para executarmos qualquer análise sobre os dados é necessário que tenhamos em mente qual a tarefa que estamos realizando. Uma **tarefa de mineração de dados** consiste na especificação **do que** queremos buscar nos dados. Podemos buscar por algum tipo de regularidade ou categoria de padrões que temos interesse em encontrar ou ainda padrões que poderiam nos surpreender (por exemplo, um gasto exagerado de um cliente de cartão de crédito, fora dos padrões usuais de seus gastos).

A classificação das tarefas pode ser feita de acordo com alguns critérios. O primeiro divide as tarefas em **descritivas** e **preditivas**. As **descritivas** caracterizam as propriedades gerais dos dados em um banco de dados. Estão focadas em achar padrões reconhecidos por seres humanos para descrever os dados. As **preditivas**, por outro lado, realizam uma inferência sobre os dados atuais para fazer previsões futuras sobre eles. Usa variáveis para prever valores futuros ou desconhecidos de outras variáveis.

Outra taxonomia divide as tarefas em top-down e botton-up. Algumas tarefas são abordadas de forma **top-down** chamado **teste de hipóteses**. Em testes de hipóteses, um comportamento armazenado no banco de dados passado é utilizado para verificar ou refutar notações preconcebidas, ideias e palpites referentes às relações nos dados.

98276239072 - FABIANO CARBONELL DA SILVA

Outras tarefas são melhores abordadas de forma bottom-up chamado de descoberta de conhecimento (Knowledge discorvery). Na descoberta de conhecimento, a análise sobre os dados é feita sem suposições prévias. Os dados são autorizados a falar por si.

As tarefas adequadas para mineração de dados (não é limitado a essas) são:

Classificação (Preditiva)
Clustering (Descritiva)
Regra de Associação (Descritiva)
Regressão (Preditiva)
Detecção de desvios (Preditiva).

Outro ponto importante dentro do assunto são as técnicas de mineração que consistem na especificação de **métodos** que nos garantam como descobrir os padrões que nos interessam. Dentre as principais técnicas utilizadas em mineração de dados, temos: técnicas estatísticas, técnicas de aprendizado de máquina e técnicas baseadas em crescimento-poda-validação.

Por fim, temos três características que são aplicadas a muitos conjuntos de dados e que possuem um impacto significativo sobre as técnicas de mineração de dados: **dimensão**, **dispersão** e **resolução**. A **dimensão** refere-se à quantidade de atributos de um conjunto de dados. A **resolução** está relacionada à granularidade dos dados. Um conjunto de dados é muito disperso quando para um atributo relevante, a maioria dos valores é NULL (desconhecido) ou um valor padrão. Esse conceito está relacionado à **dispersão.**

Um último conceito que já foi cobrado em provas de concurso diz respeito aos métodos para identificar padrões em dados, que são basicamente três:

- **Modelos simples** (consultas baseadas em SQL, OLAP, raciocínio humano)
- **Modelos intermediários** (regressão, árvores de decisão, agrupamento)
- **Modelos complexos** (redes neurais, indução de regras)

Processo de mineração e modelo de referência CRISP-DM

Antes de falar do processo de mineração propriamente dito, vamos examinar a figura abaixo que trata do processo de BI.

98276239072 - FABIANO CARBONELL DA SILVA

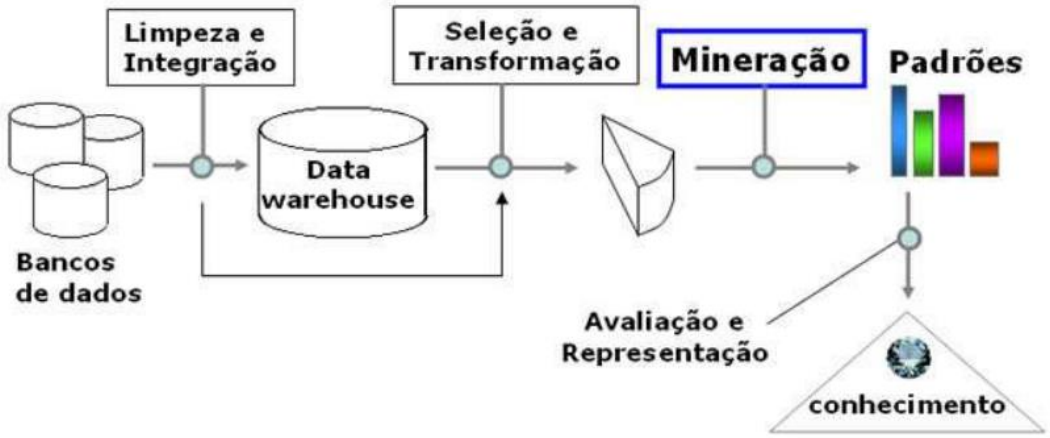

Baseado na figura é possível listar as etapas do processo:

1. Limpeza dos dados: etapa onde são eliminados ruídos e dados inconsistentes.

2. Integração dos dados: etapa onde diferentes fontes de dados podem ser combinadas, produzindo um único repositório de dados.

3. Seleção: etapa onde são selecionados os atributos que interessam ao usuário. Por exemplo, o usuário pode decidir que informações como endereço e telefone não são relevantes para decidir se um cliente é um bom comprador ou não.

4. Transformação dos dados: etapa onde os dados são transformados num formato apropriado para aplicação de algoritmos de mineração (por exemplo, por meio de operações de agregação).

5. Mineração: etapa essencial do processo consistindo na aplicação de técnicas inteligentes a fim de se extrair os padrões de interesse.

O processo de mineração de dados se assemelha um pouco ao processo de BI descrito acima. Propõe uma **visão geral do ciclo de vida** de um **projeto** de mineração de dados. Vejam a figura abaixo:

98276239072 - FABIANO CARBONELL DA SILVA

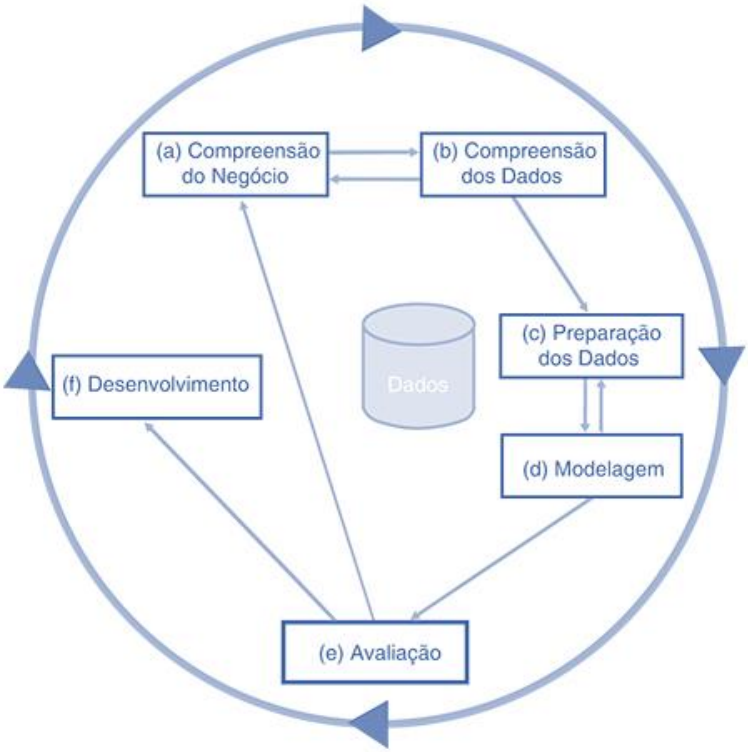

Em 1996, um conjunto de três empresas especializadas no então jovem e imaturo mercado de data mining desenvolveram um modelo de processos genéricos, com o intuito de padronizar as etapas do processo de mineração de dados, dando início ao denominado projeto CRISP-DM (CRoss Industry Standard Process for Data Mining) [The CRISP-DM Consortium, 2000].

Na figura acima é mostrado o ciclo de vida de um projeto de mineração de dados, que consiste em seis fases. A sequência de fases não é obrigatória, ocorrendo a transição para diferentes fases, dependendo do resultado de cada fase, e qual etapa particular de cada fase precisa ser executada em seguida. As setas indicam as mais importantes e mais frequentes dependências entre as fases.

O ciclo externo na figura simboliza o ciclo natural da mineração de dados. Um processo de mineração de dados continua após a solução ter sido desenvolvida. As lições aprendidas durante o processo podem provocar perguntas novas, frequentemente mais pertinentes ao negócio. Processos subsequentes se beneficiarão das experiências de processos anteriores.

Entendimento do Negócio

O entendimento do negócio (Business Understanding) foca na **compreensão do negócio** que visa obter conhecimento sobre os objetivos do negócio e seus requisitos.

Entre as principais considerações técnicas que devem ser verificadas no início de um processo de KDD estão:

- **Identificar as pessoas e áreas envolvidas no processo de KDD**. Os especialistas do domínio da aplicação, a equipe de tecnologia da informação e os grupos de decisão da

98276239072 - FABIANO CARBONELL DA SILVA

empresa devem ser submetidos, sempre que necessário, a um treinamento em KDD que nivele o conhecimento técnico na área.

- **Esboçar uma lista de necessidades e expectativas dos indivíduos envolvidos** quanto ao propósito do KDD. Para isso, é necessário **identificar que critérios** podem ser adotados para mensurar o sucesso do processo.
- **Fazer um levantamento do hardware e software existentes.** O CRISP-DM recomenda que o processo de KDD seja realizado em plataforma com arquitetura expansível, que suporte grandes volumes de dados, boa capacidade de processamento e acesso à base de dados heterogênea.
- **Fazer um inventário das bases de dados disponíveis**. Incluem-se neste item tanto bases de dados internas quanto externas. Potenciais bases externas são aquelas relacionadas com o domínio da aplicação e que possam ser utilizadas no enriquecimento dos dados.
- **Verificar a existência de Data Warehouses**. A utilização de Data Warehouses preexistentes pode poupar muitos esforços de pré-processamento dos dados.
- **Identificar e documentar, se possível, todo o conhecimento prévio** existente e disponível acerca do **domínio da aplicação**. Este conhecimento pode ser útil no decorrer do processo.

Uma vez definido o domínio sobre o qual se pretende executar o processo de descoberta, o próximo passo é selecionar e coletar o conjunto de dados ou variáveis necessárias. Consiste no entendimento dos dados utilizando-se de conjuntos de dados "modelo".

Compreensão dos Dados

Essa fase se inicia com **uma coleta inicial de dados**, e com procedimentos e atividades visando **à familiarização com os dados**, para identificar possíveis problemas de qualidade, ou detectar subconjuntos interessantes para formar hipóteses. É geralmente executada em conjunto com a fase anterior, e requer um **estudo minucioso das informações disponíveis**. Esta fase normalmente envolve as seguintes atividades:

- **Compreender o significado e perceber a relevância dos atributos/ dados disponíveis**. Esta análise tem um papel crucial na definição dos objetivos do processo de KDD. Metadados acerca das bases de dados e seus atributos devem ser documentados.
- **Avaliar a qualidade dos dados disponíveis**. Deve-se procurar identificar o propósito para o qual os dados foram coletados, assim como a caracterização do nível de ruído envolvido. Bases de dados poluídas requerem o uso de ferramentas adequadas ao processo de limpeza. Em geral, os recursos de limpeza são fortemente dependentes do domínio da aplicação e podem ser otimizados com a utilização de conhecimentos preexistentes.
- **Verificar se os dados estão disponíveis em quantidade suficiente para o processo de KDD**. Bases de dados pequenas ou que contenham dados pouco representativos das condições normais do domínio da aplicação podem inviabilizar o processo de KDD.

98276239072 - FABIANO CARBONELL DA SILVA

- A próxima etapa é a preparação dos dados (Data Preparation) que consiste na **limpeza**, **transformação**, **integração** e **formatação** dos dados da etapa anterior. É a atividade pela qual os ruídos, dados estranhos ou inconsistentes são tratados. Esta fase abrange todas as atividades para construir o conjunto de dados final (dados que serão alimentados nas ferramentas de mineração), a partir do conjunto de dados inicial.

A Preparação dos Dados compreende as ações de pré-processamento dos dados para a fase de modelagem propriamente dita. São exemplos de ações desta fase:

- **Selecionar os dados que serão efetivamente analisados**. Como comentado em Capítulos anteriores, a seleção de dados pode integrar dados coletados de diferentes fontes, enriquecendo o conjunto de dados que será analisado.
- **Promover a limpeza dos dados**, procurando remover inconsistências e completar (ou eliminar) dados ausentes.
- **Adequar o formato** dos dados.
- **Construir novos atributos** a partir de atributos existentes.

PRESTE MAIS ATENÇÃO!!

Lembre-se: A utilização de Data Warehouses facilita esta etapa do processo de mineração de dados, que costuma ser a fase que exige mais esforço, correspondendo geralmente a mais de 50% do trabalho. Por isso, é muito importante para uma organização que ela possua em seus processos habituais boas práticas da administração de dados, como o *Data Cleansing*, que é uma parte fundamental da cadeia da administração da informação, responsável pelas etapas de detecção, validação e correção de erros em bases de dados.

Modelagem dos Dados

Esta fase consiste da escolha e da aplicação da(s) técnica(s) de modelagem (algoritmo(s) de mineração) sobre os dados a serem analisados. Corresponde à etapa de Mineração de Dados do Processo de KDD. Envolve testes iniciais voltados à calibração de parâmetros do(s) algoritmo(s).

Diversas técnicas de modelagem dos dados são experimentadas e, em cada uma delas, diversos valores de parâmetros são testados. Essa atividade prevê um retorno à atividade de preparação dos dados, visto que algumas técnicas de modelagem apresentam demandas diferentes quanto ao formato do conjunto de dados utilizado.

98276239072 - FABIANO CARBONELL DA SILVA

Algumas técnicas possuem requerimentos específicos na forma dos dados. Consequentemente, voltar para a etapa de preparação de dados é frequentemente necessário. A maioria das técnicas de mineração de dados é baseada em conceitos de aprendizagem de máquina, reconhecimento de padrões, estatística.

Avaliação do processo (Evaluation).

Neste momento, o objetivo é garantir que o modelo gerado atenda às expectativas da organização. Os resultados do processo de descoberta do conhecimento podem ser mostrados de diversas formas. Porém, estas formas devem possibilitar uma análise criteriosa para identificar a necessidade de retornar a qualquer um dos estágios anteriores do processo de mineração. Nesta etapa, verificamos se o modelo construído possui qualidade, sob uma perspectiva da análise de dados.

O resultado da fase anterior é um conjunto de um ou mais modelos de conhecimento. A fase de Avaliação compreende a verificação da qualidade desses modelos gerados diante das expectativas formuladas na fase inicial do processo. A partir dessa avaliação, os especialistas em KDD podem propor revisões nas fases anteriores e redefinir os passos seguintes a serem realizados.

Assim, antes de prosseguir, é importante avaliar mais detalhadamente o modelo, e rever as etapas executadas para construir o modelo, para se certificar de que ele conseguirá alcançar os objetivos de negócio. Deve se determinar se houve algum importante objetivo do negócio que não foi suficientemente alcançado. No fim desta fase, uma decisão sobre o uso dos resultados da mineração deve ser tomada.

Entrega (Deployment)

A Entrega (Deployment) consiste na definição das fases de implantação do projeto de Mineração de Dados. A criação do modelo não é o fim do projeto. Mesmo se a finalidade do modelo for apenas aumentar o conhecimento dos dados, o conhecimento ganho deve ser organizado e apresentado em uma maneira que o cliente possa usar.

A fase em questão consiste do planejamento e do acompanhamento das ações a serem realizadas com o(s) modelo(s) de conhecimento gerado(s) pelas fases anteriores. Essa fase envolve também a elaboração de um **relatório final do processo**, que apresenta os **resultados obtidos e possíveis alternativas** de ação de descoberta de conhecimento na organização na qual o processo esteja sendo aplicado.

A figura abaixo descreve as ações feitas em cada uma das etapas do processamento:

98276239072 - FABIANO CARBONELL DA SILVA

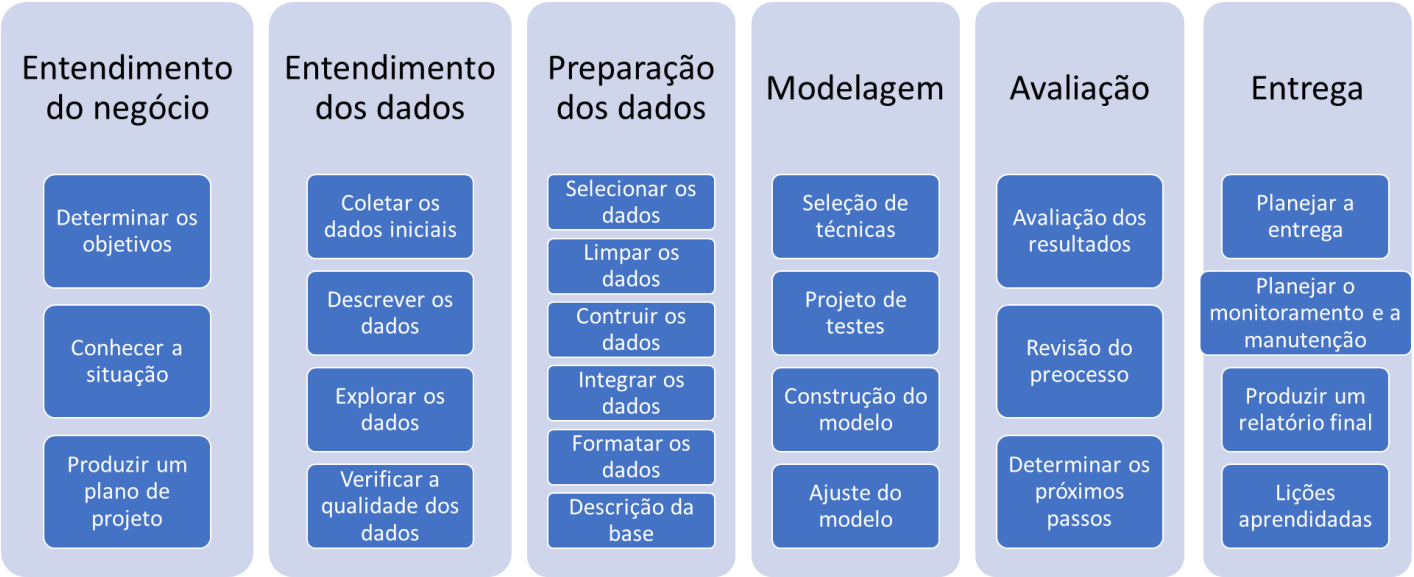

Dependendo das exigências, a fase de entrega pode ser tão simples quanto a geração de um relatório, ou tão complexo quanto executar processos de mineração de dados repetidamente. Em muitos casos será o cliente, não o analista dos dados, que realizará as etapas da execução. Entretanto, mesmo se o analista não se encarregar da execução é importante que ele faça o cliente compreender que medidas deverão ser tomadas a fim de empregar efetivamente os modelos criados.

Com isso, terminamos nossa rápida explicação sobre o processo de mineração de dados descrito pelo CRISP-DM. Vamos agora tratar das tarefas de mineração. Antes, porém, vamos fazer duas questões sobre o assunto:

Técnicas de pré-processamento

Nesta parte da aula vamos apresentar algumas técnicas que nos permitem fazer ajustes nos dados para facilitar a mineração, bem como para garantir que a síntese feita sobre os dados produza alguma informação consistente.

Os dados no mundo real são “sujos”, ou seja, podem, por exemplo, estarem incompletos com valores faltantes, atributos faltantes. Outra possibilidade é a existência de ruídos, que provocam erros ou outliers sobre os dados. Por fim, podemos verificar a consistência entre atributos, por exemplo, a data de nascimento e o atributo idade precisam ser compatíveis. Uma pessoa que nasceu em 1983 não pode ter, em 2017, 50 anos.

Técnicas de pré-processamento e transformação de dados são aplicadas para **aumentar a qualidade** e o **poder de expressão dos dados** a serem minerados. Dados sem qualidade podem gerar uma mineração sem qualidade, que por consequência vão levar a decisões sem qualidade. Se os dados estiverem duplicados ou faltantes podemos gerar cálculos estatísticos incorretos.

Esta fase tende a consumir uma parte significativa do tempo dedicado ao processo de KDD. E para avaliar se a qualidade dos dados está de acordo com a necessidade das análises de mineração, precisamos avaliar alguns aspectos dos dados, como: acurácia, completude, consistência, se eles estão corretos em relação ao tempo, à confiabilidade, ao grau de agregação de valor, à sua capacidade de interpretação e à acessibilidade.

98276239072 - FABIANO CARBONELL DA SILVA

Neste sentido, algumas tarefas de pré-processamento podem ser executadas. Antes de apresentar as tarefes, gostaria de fazer duas considerações. Primeiramente perceba que essas tarefas têm uma correlação com as atividades de transformação do processo de ETL. Segundo, não confunda essas tarefas (de pré-processamento) com as tarefas de mineração que veremos a seguir.

Limpeza dos Dados – Preenche valores faltantes, suaviza dados ruidosos, identifica ou remove "outliers" e resolve inconsistências.
Integração – Dados de origens diferentes devem ser integrados.
Transformação – Normalização e agregação dos dados.
Redução - Tenta reduzir o volume de dados sem provocar grandes alterações no resultado final.
Discretização – Faz parte do processo de redução, mas tem papel importante, especialmente com dados numéricos. Visa estabelecer valores discretos para variáveis contínuas.

Agora que já conseguimos diferenciar algumas tarefas de pré-processamento, observe a figura para entender um pouco mais esses conceitos.

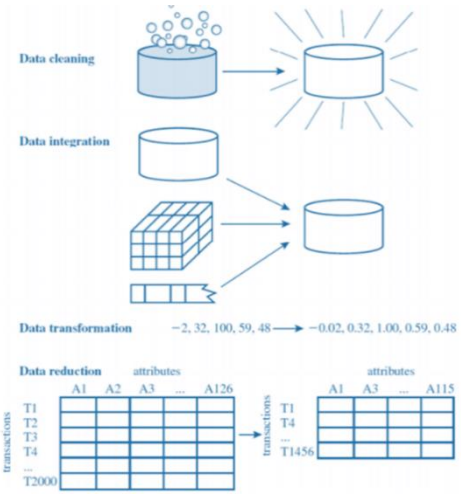

Tarefas de mineração

As funcionalidades de mineração de dados são usadas para especificar os tipos de padrões ou conhecimentos encontrados **nas tarefas de mineração de dados**. As funcionalidades incluem caracterização e discriminação; a mineração de padrões frequentes, associações e correlações; classificação e regressão; análise de cluster; e detecção de outliers. À medida que novos tipos de dados, novos aplicativos e novas demandas de análise continuarem surgindo, não há dúvida de que veremos mais e mais novas tarefas de mineração de dados. Vamos falar agora das tarefas de mineração, começando pela regra de associação.

Regras de associação

As regras de associação relacionam a presença de um conjunto de itens com outra faixa de valores de outro conjunto de variáveis. Podemos pensar nos seguintes exemplos: 1. Quando uma mulher compra uma bolsa em uma loja, ela está propensa a comprar sapatos (na mesma loja) e 2. Uma imagem de raio X contendo as

98276239072 - FABIANO CARBONELL DA SILVA

características a e b provavelmente exibirá também a característica c (o mesmo raio-x). Veja as figuras abaixo que ilustram esses exemplos:

Uma regra de associação é um padrão da forma X → Y, onde X e Y são conjuntos de valores. O seguinte padrão "clientes que compram pão também compram leite" representa uma regra de associação que reflete um padrão de comportamento dos clientes do supermercado. Descobrir regras de associação entre produtos comprados por clientes numa mesma compra pode ser útil para melhorar a organização das prateleiras, facilitar (ou dificultar) as compras do usuário ou induzi-lo a comprar mais.

Os autores definem os conceitos de lado da mão direita e lado da mão esquerda para ilustrar essa ideia de compra casada. É como se eu estivesse propenso a consumir os dois produtos. A união entre o lado da mão esquerda e o lado da mão direita gera outra definição conhecida como conjunto-item (o conjunto de todos os itens comprados pelos clientes). Observe a figura abaixo com o conjunto-item formado por picanha (Friboi é claro!) e carvão!

Para que uma regra de associação seja do interesse de um pesquisador de dados, a regra precisa satisfazer algumas medidas. O suporte que define quão frequente a regra acontece no banco de dados e a confiança que é a força da regra. Vamos detalhar um pouco mais essas definições.

O **Suporte** é uma **medida objetiva** para avaliar o **interesse** de uma **regra de associação.** Representa **a porcentagem de transações (%)** de um banco de dados de transações **<u>onde a regra se verifica.</u>**

98276239072 - FABIANO CARBONELL DA SILVA

A **Confiança** é outra medida **objetiva** para **regras de associação** que mede o **grau de certeza** de uma associação. Em termos estatísticos, trata-se simplesmente da **probabilidade condicional P (Y | X)**, isto é, a porcentagem de transações contendo os itens de X que também contêm os itens de Y.

O problema de regras de associação pode ser decomposto em três passos principais:

1. Gerar todas as combinações de itens;

2. Descobrir conjuntos de itens: Este passo consiste em gerar um conjunto com todas as combinações de itens obedecendo a um limiar, chamado **suporte mínimo**. As combinações que satisfazem esta condição são chamadas de **conjunto de itens grandes**, enquanto que os que não satisfazem são chamados de **conjunto de itens pequenos**;

3. Gerar as regras de associação para a base de dados: Após o conjunto de itens finais ter sido produzido, deve-se gerar as regras de associação de um conjunto de itens Y = I1,I2,,...,Ik, sendo k ≥ 2. O antecedente da regra será um conjunto X de Y tal que, X possua k-1 itens, e o consequente seja Y – X. Para verificar a validade de uma regra, a confiança da regra (suporte(Y) / suporte(X)) deve satisfazer o valor mínimo de confiança informado.

Uma pergunta pode ser relevante neste momento: **como descobrir todos os conjuntos de itens grandes?**

Temos que verificar duas propriedades: 1. **Fechamento por baixo,** ou seja, um itemset grande também deve ser grande (desta forma cada subconjunto de um itemset excede o suporte mínimo exigido). 2. **Antimonotonicidade** um superconjunto de um itemset pequeno também é pequeno (implicando que ele não tem suporte suficiente). Sendo assim, quando se descobre um itemset pequeno, então qualquer extensão deste itemset será pequeno.

Classificação

Parece ser um imperativo humano. A fim de compreender e comunicar sobre o mundo que estamos constantemente a classificar, categorizar e classificar. Dividimos as coisas vivas em filos, espécies e gênero; matéria em elementos; cães em raças, as pessoas em raças. Os objetos a serem classificados são geralmente representados por registros em um banco de dados ou um arquivo, e o ato de classificação consiste em adicionar uma nova coluna com um código de classe de algum tipo.

Uma das tarefas mais comuns dentro de mineração de dados consiste em examinar as características de um objeto recém-apresentado e atribuí-lo a um dos conjuntos predefinidos de classes. A tarefa de classificação é caracterizada por uma definição das classes (1), e conjunto dados para aprendizado (2) pré-classificados.

Uma definição mais formal para a classificação é a tarefa de aprendizado de uma função alvo f que mapeia cada atributo de um conjunto x para um rótulo de classe predefinido y. Essa descrição foi dada por Tan em seu livro de mineração e pode ser observada na figura abaixo:

98276239072 - FABIANO CARBONELL DA SILVA

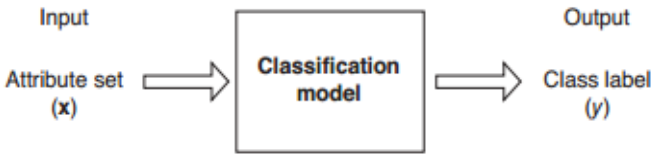

O modelo construído baseia-se na análise prévia de um conjunto de dados de amostragem ou dados de treinamento, contendo objetos corretamente classificados. Por exemplo, suponha que o gerente do supermercado está interessado em descobrir que tipo de características classificam seus clientes em "bom comprador" ou "mau comprador". Um modelo de classificação poderia incluir a seguinte regra: "Clientes da faixa econômica B, com idade entre 50 e 60 são maus compradores".

São técnicas usualmente empregadas em tarefas de classificação, árvores de decisão e redes neurais. Boa parte dos métodos de classificação utilizam técnicas estatísticas e de aprendizado de máquina. Segundo o Navathe, classificação é o processo de encontrar um conjunto de modelos (funções) que descrevem e distinguem classes ou conceitos.

Tem o propósito de utilizar o modelo para predizer a classe de objetos que ainda não foram classificados. Utiliza um aprendizado supervisionado para separar classes em grupos distintos. Vejam um exemplo na figura abaixo:

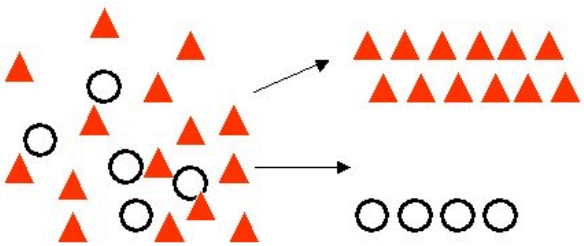

Na classificação, o objetivo é a construção de um modelo que possa ser aplicado a dados não classificados e classificá-los. São exemplos de tarefas de classificação que foram abordados por meio de técnicas de mineração de dados: classificação de pedido de crédito como baixo, médio ou alto risco, escolher conteúdo a ser exibido em uma página Web, determinar quais os números de telefone correspondem a máquinas de fax, descobrir sinistros fraudulentos e atribuir códigos da indústria e denominações de emprego com base nas descrições de texto livre.

Em todos os exemplos, há **um número limitado de classes**, e espera-se ser capaz de atribuir qualquer registo em um ou outra. As **árvores de decisão** e técnicas semelhantes são bem adaptadas para a classificação. **Rede neural** e análise de links também são úteis para a classificação de certas circunstâncias. Vejam na figura a seguir um fluxo que mostra o funcionamento de um algoritmo de classificação:

98276239072 - FABIANO CARBONELL DA SILVA

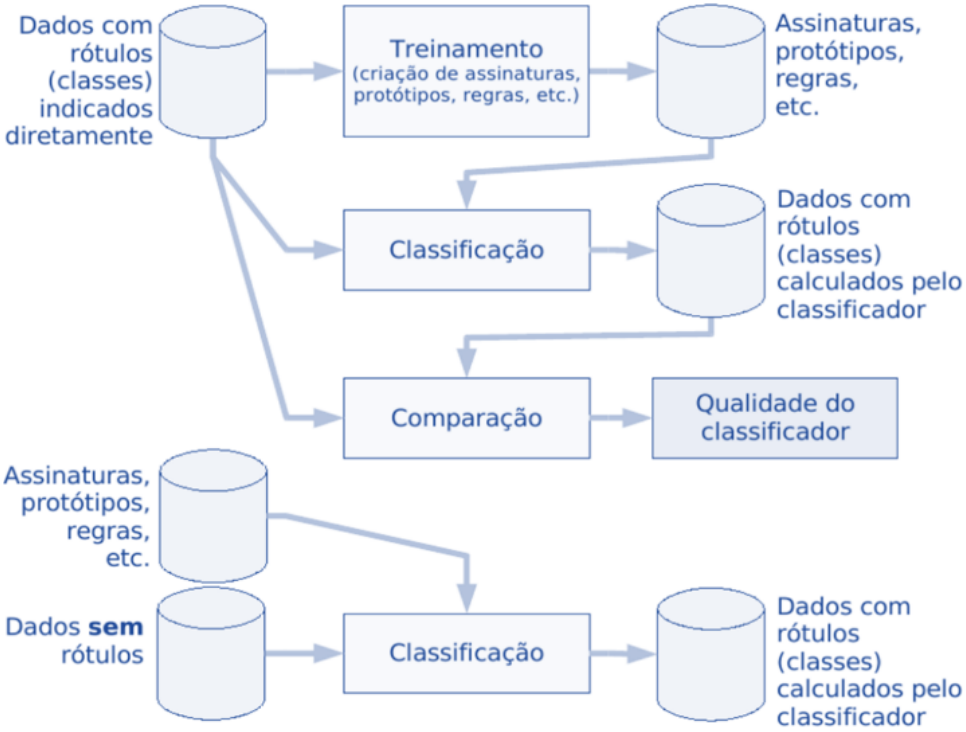

Agrupamento (Clustering)

Diferentemente da classificação e predição, onde os dados de treinamento estão devidamente classificados e as etiquetas das classes são conhecidas, a análise de clusters trabalha sobre dados onde as etiquetas das classes não estão definidas.

A técnica consiste em identificar **agrupamentos de objetos**, estes que identificam **uma classe.** Trabalha sobre dados onde as etiquetas das classes **não estão definidas**. Conhecido também por **aprendizado não supervisionado** e, às vezes, chamado de classificação por estatísticos e de segmentação por pessoas de marketing.

Queremos achar grupos naturais nos dados onde dados em um mesmo grupo são semelhantes entre si e dados de grupos diferentes são diferentes entre si. Mas, como medir essa semelhança? Existem algumas métricas para calcular as distâncias e as dissimilaridades entre os itens de dados.

As medidas de distância podem ser calculadas entre dois objetos. Sejam O1 e O2 dois objetos de um universo de possíveis objetos. A distância (dissimilaridade) entre O1 e O2 é um número real denotado por D (O1, O2). Observem a figura abaixo para entender melhor o conceito:

98276239072 - FABIANO CARBONELL DA SILVA

Algumas propriedades podem ser analisadas nas medidas de distância. A **simetria** (D (A, B) = D (B, A)), caso contrário você poderia afirmar que "Alex parece com Bob, mas Bob não parece com Alex". A **constância de autossimetria** (D (A, A) = 0), caso contrário você poderia afirmar que "Alex parece mais com Bob, do que o próprio Bob".

A **positividade** (D(A, B) = 0 ←→ A = B) caso contrário existiriam objetos no seu mundo que são diferentes, mas você não consegue diferenciá-los. E a **desigualdade triangular:**

$$(D(A,B) \leq D(A, C) + D(B,C))$$

caso contrário você poderia afirmar que "Alex é parecido com Bob, e Alex é parecido com Carl, mas Bob não se parece com Carl".

Podemos usar alguns tipos de algoritmos para agrupamentos. Algoritmos **particionais** que objetivam construir diversas partições e avaliá-las com algum critério. Algoritmos **hierárquicos** que criam uma decomposição hierárquica de um conjunto de objetos utilizando algum critério. Vejam o exemplo abaixo:

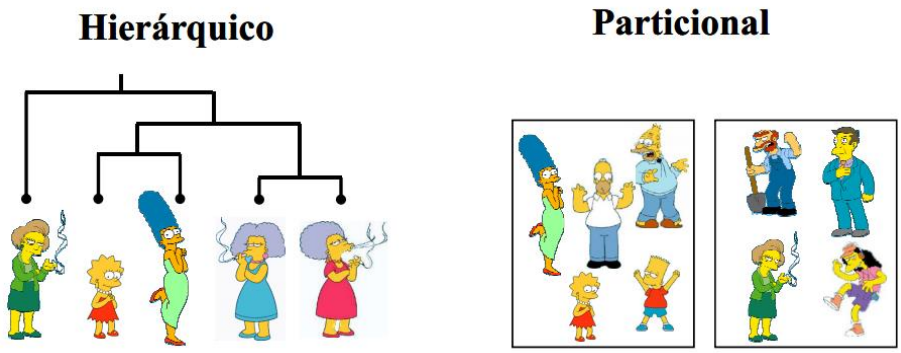

Por exemplo, poderíamos aplicar análise de clusters sobre o banco de dados de um supermercado a fim de identificar grupos homogêneos de clientes. Clientes residentes em determinados pontos da cidade costumam vir ao supermercado aos domingos. Enquanto clientes residentes em outros pontos da cidade costumam fazer suas compras às segundas-feiras.

Abordagem para outros problemas de mineração

Análise de padrões sequenciais - Um padrão sequencial é uma expressão da forma < i1;.....; in >, onde cada i é um conjunto de itens. A ordem em que estão alinhados estes conjuntos reflete a ordem cronológica em que aconteceram os fatos representados por estes conjuntos. Assim, por exemplo, a sequência < {carro}, {pneu, toca-fitas} > representa o padrão "Clientes que compram carro, **tempos depois compram** pneu e toca-fitas de carro". Descobrir tais padrões sequenciais em dados temporais pode ser **útil** em **campanhas de marketing**, por exemplo.

Análise de Padrões em Séries Temporais - O preço de fechamento de uma ação ou de um fundo de investimentos é um evento que ocorre a cada dia da semana para cada fundo ou ação. Sequências desses valores

98276239072 - FABIANO CARBONELL DA SILVA

são exemplos de uma serie temporal. Séries temporais são sequências de eventos, cada evento pode ser um tipo fixo dado uma transação.

Uma série temporal é uma coleção de observações feitas sequencialmente ao longo do tempo. Em séries temporais, a ordem dos dados é fundamental. Uma característica muito importante deste tipo de dados é que as observações vizinhas são dependentes e o interesse é analisar e modelar esta dependência.

Predição – Consultando o dicionário, encontramos a seguinte definição: dizer antecipadamente o que vai acontecer, seja por meio de regras certas, pretensa adivinhação ou conjetura. Em algumas aplicações, o usuário está mais interessado em predizer alguns valores ausentes em seus dados, em vez de descobrir classes de objetos. Isto ocorre, sobretudo, quando os valores que faltam são numéricos. Neste caso, a tarefa de mineração é denominada Predição.

Análise de Outliers - Um banco de dados pode conter dados que não apresentam o mesmo comportamento padrão da maioria. Estes dados são denominados outliers (exceções). Muitos métodos de mineração descartam estes outliers como sendo ruído indesejado. Entretanto, em algumas aplicações, tais como detecção de fraudes, estes eventos raros podem ser mais interessantes do que eventos que ocorrem regularmente. Por exemplo, podemos detectar o uso fraudulento de cartões de crédito ao descobrir que certos clientes efetuaram compras de valor extremamente alto, fora de seu padrão habitual de gastos.

Veja que você pode descobrir fraudes por análise de outleirs ou classificação. No primeiro, você conhece o padrão dos dados ou transações comuns ao banco de dados e algo que não se adapte a esse padrão é um ponto fora da curva. No segundo você treina um modelo para que ele reconheça padrões de fraude.

Regressão - Regressão é uma aplicação especial da regra de classificação. Se uma regra de classificação é considerada uma função sobre variáveis que as mapeia em uma classe destino, a regra é chamada regressão. Uma aplicação de regressão ocorre quando, em vez de mapear uma tupla de dados de uma relação para uma classe específica, o valor da variável é previsto baseado naquela tupla.

Quando: Y = f(x1, x2, ..., xn). Uma função f é linear no domínio das variáveis xi, o processo de derivar f de um dado conjunto de tuplas para <x1, x2, ... Xn, y> é chamado **regressão linear**.

Conceitos Complementares

Para concluirmos o conteúdo de Data Mining, vamos tratar de alguns termos complementares presentes da literatura especializada que ainda não foram vistos ao longo da nossa aula.

Alguns autores classificação mineração de dados de acordo com a forma. Essa classificação possui três categorias: Preditivo, Textual e Espacial. Veja a definição de cada um deles abaixo:

Preditivo - A data mining pode mostrar como certos atributos dos dados irão se comportar no futuro.

Textual - Processo de obtenção de informação utilizando fontes de dados textuais. Aplicações em classificação automática de textos e busca de agrupamentos.

98276239072 - FABIANO CARBONELL DA SILVA

Espacial - Processo de descoberta de padrões utilizando bancos de dados espaciais povoados por mapas.

A mineração de dados apoia o conhecimento indutivo, que descobre novas regras e padrões nos dados fornecidos. O conhecimento pode ser representado de muitas formas:

1. Quando não estruturado, pode ser representado por regras ou por lógica proposicional.
2. Em uma forma estruturada, podem ser representados por árvores de decisão, redes semânticas, redes neurais ou hierarquias de classes ou frames.

OLAP x Data Mining

O termo para processamento analítico on-line representa a característica de trabalhar os dados com operadores dimensionais. OLAP possibilita uma forma múltipla e combinada de análise.

Data Mining está mais relacionado com os processos de análise de inferência do que com a análise dimensional de dados. Representa uma forma de busca de informação baseada em algoritmos que objetivam o reconhecimento de padrões escondidos nos dados. Esses padrões não são necessariamente revelados pelas outras abordagens analíticas, como o OLAP.

Para finalizar, vamos apresentar uma última definição de data mining: "A mineração de dados é um campo interdisciplinar que reúne técnicas de **aprendizado de máquina**, **reconhecimento de padrões**, **estatísticas**, **banco de dados** e **visualização** para abordar a questão da **extração de informações** a partir de **grandes** bases de dados".

Mineração de texto

Considerada uma evolução da área de Recuperação de Informações (RI), a Mineração de textos (Text Mining) é um processo que utiliza técnicas de análise e extração de dados a partir de textos, frases ou apenas palavras. Envolve a aplicação de algoritmos computacionais que processam textos e identificam informações úteis e implícitas, que normalmente não poderiam ser recuperadas utilizando métodos tradicionais de consulta, pois a informação contida nestes textos não pode ser obtida de forma direta, uma vez que, em geral, estão armazenadas em formato não estruturado.

Os benefícios da mineração de textos podem se estender a qualquer domínio que utilize textos, sendo que suas principais contribuições estão relacionadas à busca de informações específicas em documentos, à análise qualitativa e quantitativa de grandes volumes de textos, e a melhor compreensão do conteúdo disponível em documentos textuais.

A ferramenta de busca do Google é um ótimo exemplo de mineração de texto. Existem vários algoritmos que classificam e ordenam os textos que aparecem como resultado das nossas consultas. Textos estes que podem estar representados das mais diversas formas, dentre elas: e-mails; arquivos em diferentes formatos (pdf, doc, txt, por exemplo); páginas Web; campos textuais em bancos de dados; textos eletrônicos digitalizados a partir de papéis.

Existem várias definições para mineração de textos. Segundo Lopes, o termo se refere ao processo de extração de padrões interessantes e não triviais, ou conhecimento a partir de documentos em textos não estruturados.

98276239072 - FABIANO CARBONELL DA SILVA

Moura descreve a mineração de textos como sendo uma área de pesquisa tecnológica cujo objetivo é a busca por padrões, tendências e regularidades em textos escritos em linguagem natural.

Já Wives afirma que a mineração de textos pode ser entendida como a aplicação de técnicas de KDD sobre dados extraídos de textos. Na prática, a mineração de textos define um processo que auxilia na descoberta de conhecimento inovador a partir de documentos textuais, que pode ser utilizado em diversas áreas do conhecimento.

Para finalizar, vamos apresentar uma última definição de **data mining**: "A mineração de dados é um campo interdisciplinar que reúne técnicas de **aprendizado de máquina**, **reconhecimento de padrões**, **estatísticas**, **banco de dados** e **visualização** para abordar a questão da **extração de informações** a partir de **grandes** bases de dados".

APOSTA ESTRATÉGICA

A ideia desta seção é apresentar os pontos do conteúdo que mais possuem chances de serem cobrados em prova, considerando o histórico de questões da banca em provas de nível semelhante à nossa, bem como as inovações no conteúdo, na legislação e nos entendimentos doutrinários e jurisprudenciais[2].

[2] Vale deixar claro que nem sempre será possível realizar uma aposta estratégica para um determinado assunto, considerando que às vezes não é viável identificar os pontos mais prováveis de serem cobrados a partir de critérios objetivos ou minimamente razoáveis.

98276239072 - FABIANO CARBONELL DA SILVA

Banco de dados relacionais: conceitos básicos e características

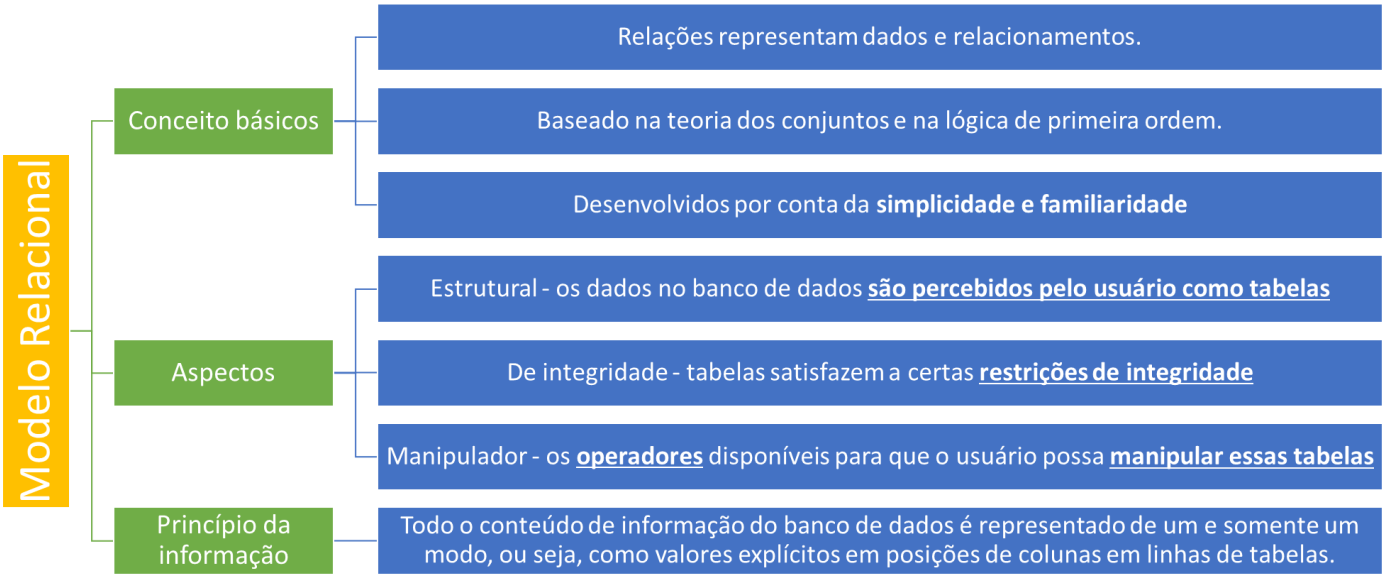

Metadados

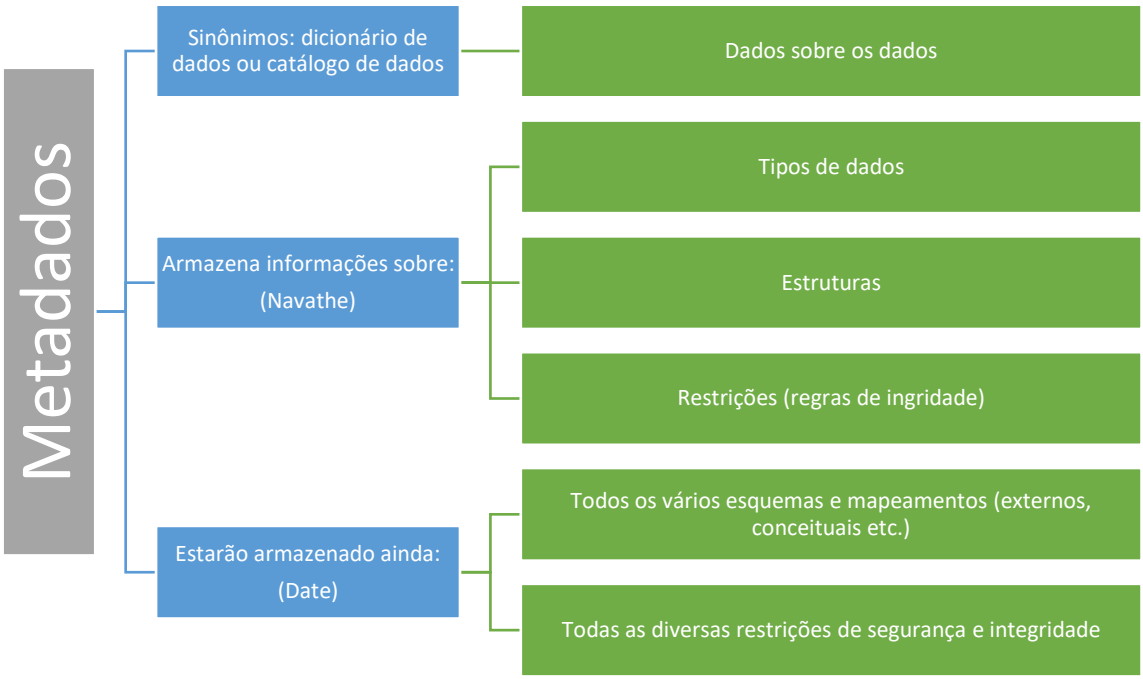

98276239072 - FABIANO CARBONELL DA SILVA

Tabelas (Restrições de integridade)

98276239072 - FABIANO CARBONELL DA SILVA

Restrições de Integridade

Integridade de Domínio

- Estabelece o conjunto dos valores que podem ser atribuidos a um atributo
- Comando SQL: CHECK

Integridade de Vazio

- Define se um atributo aceita ou não valores nulos.
- Comando SQL: NULL ou NOT NULL

Integridade de Entidade

- Afirma que cada tabela deve ter uma chave primária
- Estabelece que nenhum valor da chave primária pode ser null

Integridade de Chave

- Todos os valores da chave devem ser únicos.
- Não se admite repetições de valores
- Unicidade
- Comando SQL: UNIQUE/PRIMARY KEY

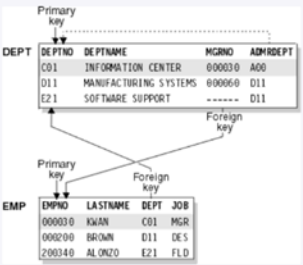

Integridade Referencial

- Faz a associação entre duas relações
- Limita os valores da chaves estrangeira aos valores presentes na(s) coluna(s) referenciada(s)
- Comando SQL: FOREING KEY

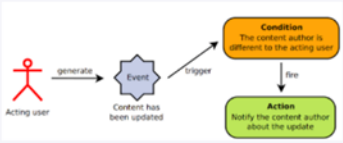

Integridade Semântica

- Descreve regras de negócio da organização
- Assertions ou triggers

Chaves e relacionamentos

Id_Aprovado	Nome	Municipio	CPF	Passaporte
1	Thiago	2611606	11111111111	111111
2	Flávia	2604106	22222222222	222222
3	Vinícius	2604106	33333333333	333333
4	Lucas	Null	44444444444	444444

RESUMINDO

Chave candidata

Chave primária

Chave Alternativa

Chave Estrangeira

Atributos de uma relação cujos valores devem corresponder a valores de alguma chave candidata de alguma relação.

Toda superchave com a propriedade de irredutibilidade.

A **chave candidata** **designada** para identificar as linhas de uma tabela.

Id_Municipio	Nome	Descrição
2611606	Recife	Veneza brasileira
2604106	Caruaru	Capital do forró

Mineração de dados

A **mineração de dados** é um campo interdisciplinar que reúne **técnicas de aprendizado de máquina**, reconhecimento de padrões, estatísticas, banco de dados e visualização para abordar a questão da extração de informações a partir de grandes bases de dados.

THIAGO CAVALCANTI
PROFESSOR

- Descritiva – caracterizam as **propriedades gerais** dos dados em um banco de dados
  - Achar **padrões** reconhecidos por seres humanos para descrever os dados.

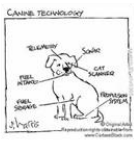

- Preditiva – essas tarefa **realiza uma inferências** sobre os dados atuais para fazer previsões sobre os mesmos
  - Usa variáveis para **prever valores futuros** ou desconhecidos de outras variáveis.

98276239072 - FABIANO CARBONELL DA SILVA

CRISP-DM

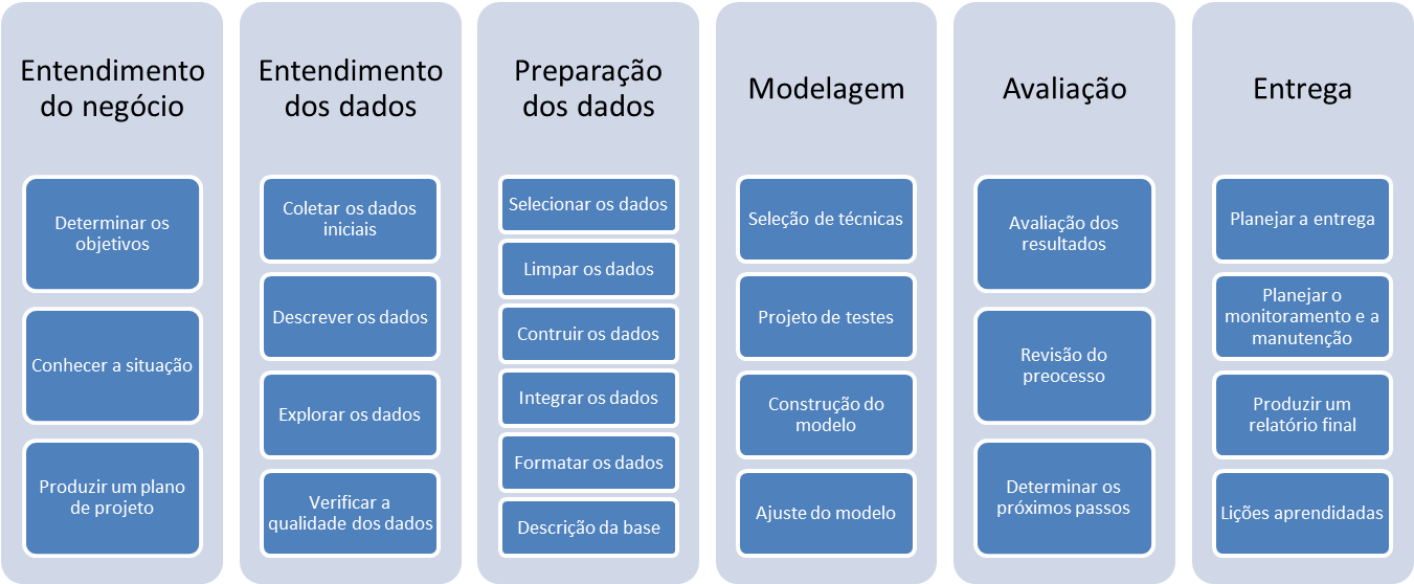

Técnicas e tarefas de mineração de dados.

- **Tarefas**: Consistem **na especificação do que estamos querendo buscar nos dados**, que tipo de regularidades ou categoria de padrões temos interesse em encontrar, ou que tipo de padrões poderiam nos surpreender (por exemplo, um gasto exagerado de um cliente de cartão de crédito, fora dos padrões usuais de seus gastos).
- **Técnicas**: Consiste na **especificação de métodos** que nos garantam **como** descobrir os padrões que nos interessam.
  - Dentre as principais técnicas utilizadas em mineração de dados, temos técnicas estatísticas, técnicas de aprendizado de máquina e técnicas baseadas em crescimento-poda-validação.

98276239072 - FABIANO CARBONELL DA SILVA

Principais tarefas de mineração

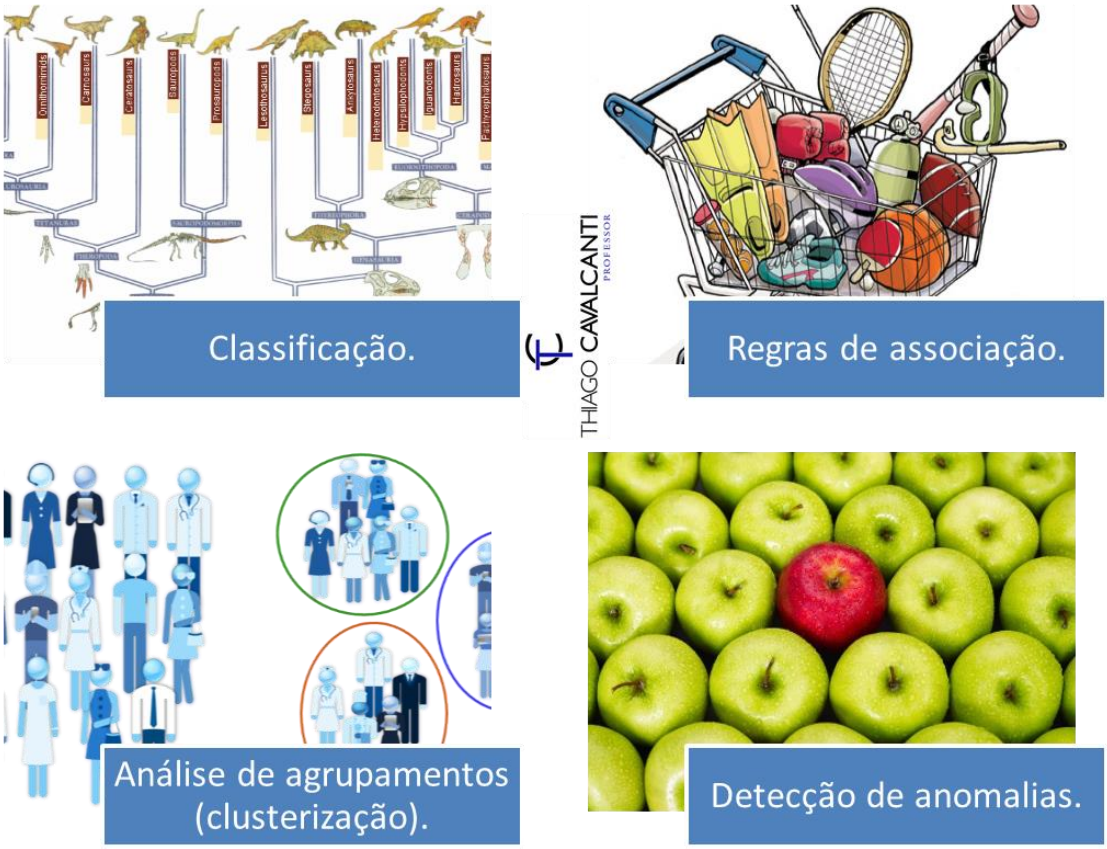

Imprima o capítulo Aposta Estratégica separadamente e dedique um tempo para absolver tudo o que está destacado nessas duas páginas. Caso tenha alguma dúvida, volte ao Roteiro de Revisão e Pontos do Assunto que Merecem Destaque. Se ainda assim restar alguma dúvida, não hesite em me perguntar no fórum.

QUESTÕES ESTRATÉGICAS

Nesta seção, apresentamos e comentamos uma amostra de questões objetivas selecionadas estrategicamente: são questões com nível de dificuldade semelhante ao que você deve esperar para a sua prova e que, em conjunto, abordam os principais pontos do assunto.

A ideia, aqui, não é que você fixe o conteúdo por meio de uma bateria extensa de questões, mas que você faça uma boa revisão global do assunto a partir de, relativamente, poucas questões.

98276239072 - FABIANO CARBONELL DA SILVA

1. **Ano: 2019 Banca: CESPE Órgão: SEFAZ-RS Prova: Auditor Assunto: Banco de Dados**

No modelo relacional, a afirmação "Duas tuplas distintas, em qualquer estado da relação, não podem ter valores idênticos para os atributos na chave" é

A uma propriedade de chave do modelo.

B falsa.

C uma restrição de domínio do modelo.

D uma propriedade exclusiva do modelo objeto-relacional.

E uma condição que deverá estar explícita na representação dos atributos de uma tupla.

Comentário: As principais propriedades das chaves são unicidade e irredutibilidade. Vejamos as definições:

Unicidade: Nenhum valor válido de relação contém duas tuplas diferentes com o mesmo valor para os atributos chave.

Irredutibilidade: Nenhum subconjunto apropriado da chave tem a propriedade de unicidade.

Veja que a questão trata de unicidade, logo **uma propriedade de chave do modelo**.

Gabarito: A

---

2. **Ano: 2019 Banca: CESPE Órgão: SEFAZ-RS Prova: Auditor Assunto: Banco de dados**

No modelo relacional, variável corresponde a

A um valor variável que não possui local no tempo nem no espaço.

B uma matriz de valores codificados e armazenados na memória.

C um recipiente para se armazenar um valor que pode ser atualizado.

D um valor que não admite substituição.

E uma constante individual.

Comentário: Veja que essa questão foi totalmente inspirada no livro do CJ Date – Introdução a Sistemas de Banco de Dados, que também usamos na elaboração deste material. Veja o que diz o texto original do livro:

"A primeira coisa que precisamos fazer é identificar a diferença lógica crucial e fundamental entre **valores** e **variáveis** (há uma confusão surpreendente sobre essa questão na literatura) ... adotamos as seguintes definições:

98276239072 - FABIANO CARBONELL DA SILVA

Um **valor** é uma "constante individual" – por exemplo, a constante individual que é o inteiro 3. Um valor **não possui local no tempo ou no espaço**. Contudo, os valores podem ser representados na memória por meio de alguma codificação, e tais representações, ou (nosso termo preferido) aparições, possuem locais no tempo e no espaço. Na realidade, aparições distintas do mesmo valor podem existir em vários locais distintos no tempo e no espaço, significando, informalmente, que diversas variáveis diferentes podem ter o mesmo valor, ao mesmo tempo. Observe que, por definição, um valor não pode ser atualizado; se pudesse, então, depois dessa modificação, ele não seria mais o mesmo valor.

Uma **variável** é um recipiente para um aparecimento de um valor. Uma variável **possui um local no tempo e no espaço**. Além disso, logicamente, as variáveis, diferente dos valores, **podem ser atualizadas**; ou seja, o valor atual da variável em questão pode ser substituído por outro valor, provavelmente, diferente do anterior. "

Assim, temos nossa resposta na alternativa C, ou seja, **uma variável corresponde a um recipiente para se armazenar um valor que pode ser atualizado**.

Gabarito: C.

---

3. Ano: 2018 Banca: CESPE Órgão: TCE-PB Cargo: Auditor de Constas Públicas Questão: 97

A respeito de SGBDs, assinale a opção correta.

A Um SGBD, por definição, não é flexível, dada a dificuldade de mudar a estrutura dos dados quando os requisitos mudam.

B Um SGBD é um software que não prevê as funções de definição, recuperação e alteração de dados, sendo essa tarefa a função básica de um sistema de banco de dados.

C A consistência de dados é o princípio que determina a manutenção de determinado dado em vários arquivos diferentes.

D Conforme o princípio da atomicidade, caso ocorra erro em determinada transação, todo o conjunto a ela relacionado será desfeito até o retorno ao estado inicial, como se a transação nunca tivesse sido executada.

E O controle de concorrência é o princípio que garante e permite a manipulação, no mesmo momento, de um mesmo dado por mais de uma pessoa ou um sistema.

Comentário: Vamos analisar as alternativas acima. Elas são relevantes para consolidar nosso conhecimento sobre o assunto.

a) Começando pela alternativa A. O **erro** aparece quando o examinador afirmar que os SGBDs não são flexíveis. Lembre-se que um SGBD veio solucionar um problema de **redundância não controlada** dos dados em diversos arquivos distintos. Agora, com uma fonte única dos dados, as alterações dos mesmos são **centralizadas**.

b) Já a alternativa B nos remonta as funcionalidades do SGBD. O que podemos fazer com tal sistema? É possível, primariamente, **armazenar e manipular dados**, para tal, é necessário **descrever as estruturas das tabelas**. Todos os SGBDs possuem comandos para construção do banco de dados, usando uma linguagem padrão, por exemplo SQL – Structured Query Language. Sendo assim, a alternativa B também está **incorreta**.

98276239072 - FABIANO CARBONELL DA SILVA

c) e d) As próximas duas alternativas tratam das **propriedades das transações**, mais especificamente da **consistência**, que tem por objetivo levar o banco de dados de um estado válido para outro estado consistente, e da **atomicidade**, que parte do princípio que uma transação é composta por vários comandos de modificação da base de dados e que estes comandos devem ser executados em conjunto completamente ou não serem executados. Desta forma, para garantir a atomicidade, caso uma transação falhe todas as operações já efetivadas precisam ser desfeitas. Desta forma, a alternativa C está **incorreta** e a alternativa D é **a nossa resposta**.

e) Por fim, o controle de concorrência é um mecanismo que permite que apenas um usuário consiga modificar um dado específico do sistema em um determinado instante no tempo. É importante entender que é possível várias pessoas terem acesso aos dados **simultaneamente para leitura**. Como se todos estivessem lendo um livro ou um outdoor. Contudo, na hora de escrever só existe uma caneta e, se alguma pessoa estiver de posse da caneta, apenas ela poderá fazer alterações na base. No banco de dados a caneta é representado por um bloqueio de escrita (WRITE_LOCK) que impede outros usuários fazerem acesso ao mesmo registro, seja para leitura ou para escrita. Logo, temos uma alternativa **incorreta**.

Gabarito: D.

---

4. Ano: 2018 Banca: CESPE Órgão: TCM-BA Cargo: Auditor de Contas Questão: 09

Considerando os conceitos de banco de dados relacionais, assinale a opção correta a respeito das propriedades de uma tupla.

A A tupla tem o mesmo significado e as mesmas propriedades de uma tabela.

B Os componentes de uma tupla são ordenados da esquerda para a direita.

C Cada tupla contém exatamente um valor para cada um de seus atributos.

D Um subconjunto de uma tupla não é considerado uma tupla.

E Uma tupla nunca é vazia, seu grau pode variar de 1 até n.

Comentário: Vimos ao longo do nosso curso de análise de informações que as tuplas são linhas de uma tabela. Elas, quando consideramos a referência teórica e matemática do modelo relacional não são ordenadas e não se repetem. Vamos agora analisar cada uma das alternativas acima.

A) **Errada**. A tupla é a linha da tabela. Representa uma instância ou um valor armazenado. Pense na tabela aluno, cada aluno armazenado é uma tupla da tabela. Contudo, uma tabela pode ter atributos que não são específicos da tupla como a quantidade máxima de registros.

B) **Errada**. Os as tuplas não são ordenadas de cima para baixo, nem seus atributos ou componentes são ordenados da esquerda para a direita.

C) **Certa**. Pela definição de modelo relacional do Codd os atributos de uma relação devem ter valores atômicos. Logo, cada coluna deve ter um valor dentro do seu respectivo domínio. Este pode ou não aceitar valores nulos. Sendo assim, essa afirmação presente na alternativa é uma afirmação certa, no meu ponto de vista.

D) **Errada**. Um subconjunto de uma tupla é outra tupla, inclusive se lembrarmos da propriedade de fechamento das operações de álgebra relacional, podemos perceber que o resultado de

E) **Errada**. Uma tupla de uma tabela pode ser vazia, ela é conhecida como empty tuple ou nullary tuple. Para preencher valores desconhecidos usamos o valor nulo que uma notação para vazio. Além disso ela

98276239072 - FABIANO CARBONELL DA SILVA

representa um conjunto de atributos, a quantidade de atributos de uma tupla é denominada grau e pode variar de 0 até n. Logo, temos mais uma alternativa incorreta.

Gabarito: C

---

5. Ano: 2018 Banca: CESPE Órgão: TCM-BA Cargo: Auditor de Contas Questão: 10

A respeito de entidades, relacionamentos e tipos de chave, assinale a opção correta.

A Uma entidade fraca não possui seus próprios atributos chave.

B Toda relação deve possuir somente uma chave primária de atributo único.

C Um identificador ou chave é usado para determinar exclusivamente uma instância de um relacionamento entre entidades.

D A abordagem entidade-relacionamento permite somente relacionamentos binários e dos tipos 1:1 e 1:n.

E Uma entidade forte existe no banco de dados e possui atributos que a identificam sem que ela precise estar associada a outra entidade identificadora.

Comentário: Vejam que essa questão apresenta um conceito associado ao modelo entidade-relacionamento. Uma entidade forte significa que possui atributos suficientes para identificar de forma unívoca cada instância ou elemento de um conjunto de entidade. Logo, podemos marcar a **resposta na alternativa E**. Vamos agora procurar os erros das demais alternativas.

A) Uma entidade pode ter um atributo que seja chave, contudo, ele sozinho não consegue identificar um elemento da entidade. Para compor a chave ele precisa de um atributo que vai ser definido na entidade forte a ele associada. Sendo assim, temos uma alternativa **incorreta**.

B) A chave primária de uma relação pode ser classificada em simples, quando possuir apenas um atributo, ou composta, quando tiver dois ou mais atributos. Sendo assim, temos mais uma alternativa **incorreta**.

C) Uma instância de relacionamento é uma associação entre entidades, que inclui exatamente uma entidade de cada tipo de entidade participante. A identificação do relacionamento é feita pela associação entre as chaves das entidades participantes do relacionamento.

D) Os relacionamentos binários admitem cardinalidade máxima 1:1, 1:N e N:M. Logo temos mais uma afirmação **errada**.

Gabarito: A.

---

6. Ano: 2017 Banca: CESPE Órgão: TCE-PE Cargo: Auditor de Obras Públicas Questão: 116

Acerca de aspectos diversos referentes a bancos de dados relacionais julgue o item a seguir.

[116] A chave estrangeira (foreign key) é o campo que estabelece o relacionamento entre duas tabelas de bancos distintos, sendo necessariamente chave primária na tabela de um dos bancos.

Comentário: Essa questão tem uma pegadinha que pode ter levado muita gente a marcar a questão como correta. Ela fala que a chave estrangeira relaciona tabelas de banco distintos. Se você lembrar um banco de dados é descrito por um esquema que possui uma coleção de tabelas. A chave estrangeira é utilizada

98276239072 - FABIANO CARBONELL DA SILVA

para relacionar tabelas dentro do próprio banco ou esquema. Sendo assim, acredito que a alternativa esteja **incorreta**.

Gabarito: E.

---

7. **Ano: 2017 Banca: CESPE Órgão: TCE-PE Cargo: Auditor Questão:**

Acerca de aspectos diversos referentes a bancos de dados relacionais julgue o item a seguir.

[116] Em uma relação, os nomes das colunas são únicos, as linhas são distintas entre si, e a ordem da disposição das linhas e colunas é irrelevante para o banco de dados.

Comentário: A questão apresenta o conceito de relação. Para o modelo relacional não é relevante a ordem na qual as linhas estão armazenadas, contudo tanto no modelo relacional (lógico), quanto no modelo físico temos que levar em consideração a ordem da definição das colunas. Um exemplo interessante sobre isso é que, quando surge a necessidade de inserirmos uma nova coluna em uma tabela, fisicamente ela é "encaixada" ao final. Logo a alternativa está **incorreta**.

Gabarito: E

---

8. **Ano: 2017 Banca: CESPE Órgão: TCE-PE Cargo: Analista De Controle Externo Área: Auditoria De Contas Públicas Questão: 116**

A respeito de bancos de dados relacionais, julgue os itens subsequentes.

116 O relacionamento muitos para muitos entre duas entidades possui atributos, ou seja, dados inerentes ao fato, e não às entidades.

Comentário: A primeira afirmação não ficou muito bem escrita. Para mim, não existe obrigação de um relacionamento ter atributos associados a ele. Contudo, é fato de se tiver atributos associados ao relacionamento esses são inerentes ao fato concreto. Vamos imaginar um exemplo prático. O relacionamento "consulta" entre as entidades médico e paciente. Perceba que a consulta que deve ter os atributos de data e hora, bem como o consultório que o médico vai atender o paciente. Sendo assim, podemos marcar a alternativa 116 como **correta**.

Gabarito: C.

---

9. **Ano: 2017 Banca: CESPE Órgão: TCE-PE Cargo: Analista De Controle Externo Área: Auditoria De Contas Públicas Questão: 116 e 117**

A respeito de bancos de dados relacionais, julgue os itens subsequentes.

117 Uma visão (view) é derivada de uma ou mais relações e armazena os dados em uma tabela física do banco de dados, visando tornar ágeis as consultas.

Comentário: Sabemos que a definição de visão ou view está relacionada apenas a definição de uma consulta, que pode trazer dados de uma ou mais tabelas. Não existe uma tabela física no banco de dados que armazena as informações extraídas da visão. A consulta retorna valores que são exibidos ou entregues aos usuários. Desta forma, a alternativa 117 está **incorreta**.

Gabarito: E

98276239072 - FABIANO CARBONELL DA SILVA

10. Ano: 2016 Banca: CESPE Órgão: TCE-SC Cargo: Auditor de TI

Com relação aos bancos de dados relacionais, julgue os próximos itens.

94 O catálogo de um sistema de gerenciamento de banco de dados relacional armazena a descrição da estrutura do banco de dados e contém informações a respeito de cada arquivo, do tipo e formato de armazenamento de cada item de dado e das restrições relativas aos dados.

Comentário: O dicionário de dados ou catálogo de dados contém as descrições das estruturas dos objetos presentes na base de dados. Presente em todos os SGBDs relacionais ele guarda os metadados ou informações a respeitos dos objetos armazenados. Podemos marcar como correta a assertiva 94.

Gabarito: C.

---

11. Ano: 2016 Banca: CESPE Órgão: TCE-SC Cargo: Auditor de TI

Com relação aos bancos de dados relacionais, julgue os próximos itens.

95 Denomina-se visão uma tabela única derivada de uma ou mais tabelas básicas do banco. Essa tabela existe em forma física e viabiliza operações ilimitadas de atualização e consulta.

Comentário: A definição de visão presente no padrão SQL/ANSI é de uma estrutura temporária que armazena informações advinda de uma ou mais tabelas. A visão não é armazenada fisicamente em disco e é removida ou apagada ao final da sua utilização. Sendo assim, a alternativa 95 encontra-se **incorreta**.

Gabarito: E

---

12. Ano: 2016 Banca: CESPE Órgão: TCE-SC Cargo: Auditor de TI

Com relação aos bancos de dados relacionais, julgue os próximos itens.

96 Em bancos de dados relacionais, as tabelas que compartilham um elemento de dado em comum podem ser combinadas para apresentar dados solicitados pelos usuários.

Comentário: Dentro do contexto de bancos de dados relacionais, é possível usar as operações de junção. Essas operações utilizam atributos que operam sobre o mesmo domínio presentes em cada uma das tabelas. Esses atributos são utilizados para juntar ou relacionar uma tabela com a outra, sempre que tivermos os mesmos valores em ambas as tabelas. Vejam que temos mais uma vez uma alternativa correta.

Gabarito C.

---

13. CESPE - Auditor Federal de Controle Externo/Controle Externo/Auditoria Governamental/2015

Acerca de bancos de dados relacionais, julgue o item subsequente.

86 Chave primária é um campo, ou um conjunto de campos, que abriga valores que individualizam cada registro. Esse campo não pode repetir-se em uma mesma tabela.

Comentário: Certo. A chave primária tem como função identificar cada tupla (registro) de uma tabela, não podendo, portanto, repetir-se em uma mesma tabela. O CPF, por exemplo, é uma informação que

98276239072 - FABIANO CARBONELL DA SILVA

pode ser utilizada para identificar uma tabela de clientes, uma vez que cada indivíduo possui CPF próprio e que não se confunde com o de outro indivíduo.

As chaves primárias podem ser simples (apenas um campo/ atributo) ou compostas (formada por mais de um campo/atributo).

Gabarito: C.

---

14. CESPE - Auditor Federal de Controle Externo/Controle Externo/Auditoria Governamental/2015

Acerca de bancos de dados relacionais, julgue o item subsequente.

87 Em um banco de dados estruturado de acordo com o modelo relacional, todos os elementos dos dados são colocados em tabelas bidimensionais, organizados em linhas e colunas, o que simplifica o acesso e a manipulação dos dados. Operações matematicamente conhecidas como de produto cartesiano, de seleção e de projeção também apoiam a manipulação de dados aderentes ao modelo relacional.

Comentário: Um banco de dados relacional é um conjunto de tabelas descritas formalmente, no qual os dados **podem ser acessados ou remontados de muitas maneiras diferentes sem precisar reorganizar as tabelas do banco de dados**.

Cada tabela, que às vezes é chamada de relação, em um banco de dados relacional **contém uma ou mais categorias de dados em colunas,** também chamadas de atributos. **Cada linha, também chamada de registro ou tupla, contém uma instância única de dados**, ou chave, para as categorias definidas pelas colunas. Cada tabela possui uma chave primária exclusiva, que identifica as informações em uma tabela. A relação entre tabelas pode então ser definida através do uso de chaves estrangeiras - um campo em uma tabela que se vincula à chave primária de outra tabela.

Os cinco operadores primitivos da álgebra relacional, que são as operações sobre o modelo relacional, são a seleção, a projeção, o produto cartesiano, a união de conjuntos e a diferença de conjuntos.

Gabarito: C.

---

15. CESPE - Auditor Federal de Controle Externo/Controle Externo/Auditoria Governamental/2015

Acerca de bancos de dados relacionais, julgue o item subsequente.

88 Os bancos de dados relacionais são constituídos de três componentes: uma coleção de estrutura de dados (relações ou tabelas), uma coleção de operadores (linguagem SQL) e uma coleção de restrições de integridade (conjunto consistente de estados de base de dados e de alterações de estados).

Comentário: Os bancos de dados relacionais são compostos por estruturas de dados, que representam as informações que se deseja **armazenar e relacionar**. Para **manipular** (**selecionar**, **criar**, **apagar**, **alterar**, etc.) essas informações estruturadas, é necessário que um conjunto de operadores esteja disponível para os programadores e administradores da base de dados.

Por fim, é necessário que os bancos de dados suportem um conjunto de restrições de integridade, que serão responsáveis por **impedir que alterações indevidas** (ex.: apagar um registro sem antes tomar

98276239072 - FABIANO CARBONELL DA SILVA

cuidado para as chaves estrangeiras que apontam para esse dado) sejam efetuadas e causem **inconsistências** nas informações estruturas no banco de dados.

Gabarito: C.

---

16. CESPE - Auditor de Controle Externo (TCE-PA)/Informática/Analista de Sistema/2016

Julgue o item que se segue, relativo a modelagem de dados.

Dois diagramas de entidade de relacionamento são equivalentes se possuem entidades e relacionamentos que geram o mesmo esquema de banco de dados.

Comentário: Um diagrama E-R descreve o modelo de dados de um sistema com um grande nível de abstração, independentemente do SGBD a ser escolhido. Um esquema de bancos de dados é a descrição da estrutura em uma linguagem formal suportada pelo SGBD e refere-se à organização de dados (dividido em tabelas no caso de banco de dados relacionais). Logo, mesmo que diagramas E-R sejam diferentes, eles são considerados equivalentes caso gerem o mesmo esquema de banco de dados.

Gabarito: C

---

17. CEBRASPE (CESPE) - Profissional de Tecnologia da Informação (ME)/Atividades Técnicas de Complexidade Gerencial, de Tecnologia da Informação e de Engenharia Sênior/Ciência de Dados/2020

Julgue o seguinte item, a respeito de big data.

O objetivo da técnica de sequência de tempo é identificar a ocorrência de dois eventos diferentes no mesmo momento.

Comentários

A técnica de sequência de tempo analisa sequências de eventos. Em um dos exemplos de Stanley Loh, a técnica de associação pode identificar que fraldas são compradas em conjunto com cerveja, mas na mesma transação. Agora, se muitas pessoas compram uma TV fina hoje e voltam depois de 3 meses para comprar um home theater, isso é função da sequência de tempo.

Diante disso, essa questão seria facilmente resolvida com a interpretação da assertiva da seguinte forma: a técnica de **sequência de tempo** não poderia identificar dois eventos diferentes no **mesmo momento**.

Gabarito: errada.

---

18. CEBRASPE (CESPE) - Profissional de Tecnologia da Informação (ME)/Atividades Técnicas de Complexidade Gerencial, de Tecnologia da Informação e de Engenharia Sênior/Ciência de Dados/2020

Julgue o seguinte item, a respeito de big data.

A mineração de textos utiliza técnicas diferentes da mineração de dados, tendo em vista que os textos representam um tipo específico de dado.

Comentários

98276239072 - FABIANO CARBONELL DA SILVA

Mineração de textos, também conhecido como mineração de dados textuais ou descoberta de conhecimento de bases de dados textuais, em geral, se refere ao processo de extração de informações de interesse e padrões não-triviais ou descoberta de conhecimento em documentos de texto não-estruturados. Pode ser visto como uma extensão da mineração de dados. A mineração de texto segue, em última instância, o mesmo conjunto de etapas da mineração de dados e utiliza-se de um conjunto de técnicas comuns.

Gabarito: errada.

---

19. CEBRASPE (CESPE) - Profissional de Tecnologia da Informação (ME)/Atividades Técnicas de Complexidade Gerencial, de Tecnologia da Informação e de Engenharia Sênior/Ciência de Dados/2020

Julgue o seguinte item, a respeito de big data.

A etapa de modelagem do modelo CRISP-DM permite a aplicação de diversas técnicas de mineração sobre os dados selecionados, conforme os formatos dos próprios dados.

Comentários

Através das técnicas de indução, o Data Mining utiliza estatística e matemática para realizar o cruzamento de dados com objetivo propor hipóteses e solucionar problemas. Ou seja, é a mineração de dados que transforma todo o volume de dados em informações úteis para a tomada de decisões.

A metodologia CRISP-DM ocorre em eventos distintos e reúne as melhores práticas para que o Data Mining seja o mais produtivo e eficiente possível, analisando dados financeiros, de recursos humanos, práticas dos clientes e outros, a fim de propor modelos de melhoria ou solução de problemas.

Gabarito: certa.

---

20. Ano: 2018 Banca: CESPE Órgão: TCM-BA Cargo: Auditor de Contas Questão: 12

Assinale a opção correta a respeito do CRISP-DM.

A CRISP-DM é uma suíte de ferramentas proprietárias que vem se tornando um padrão da indústria para mineração de dados, uma vez que fornece um plano completo e tecnologias para a realização de um projeto de mineração de dados.

B A verificação da qualidade dos dados é uma atividade da fase de entendimento dos dados.

C Durante a fase de preparação dos dados, é realizado um inventário de requisitos, suposições e restrições de recursos.

D Na fase de avaliação dos dados, são realizadas as atividades de identificar valores especiais dos dados e catalogar seu significado.

E Na fase de preparação dos dados, são realizadas as atividades de analisar o potencial de implantação de cada resultado e estimar o potencial de melhoria do processo atual.

Comentário: Vamos comentar cada uma das alternativas, lembrando que o processo do CRISP-DM é organizado em um conjunto de etapas: entendimento do negócio, seleção dos dados (*data*

98276239072 - FABIANO CARBONELL DA SILVA

understanding), preparação dos dados, modelagem dos dados, avaliação do processo e execução (deployment). Veja essas etapas na figura abaixo. Em seguida vamos analisar cada uma das alternativas.

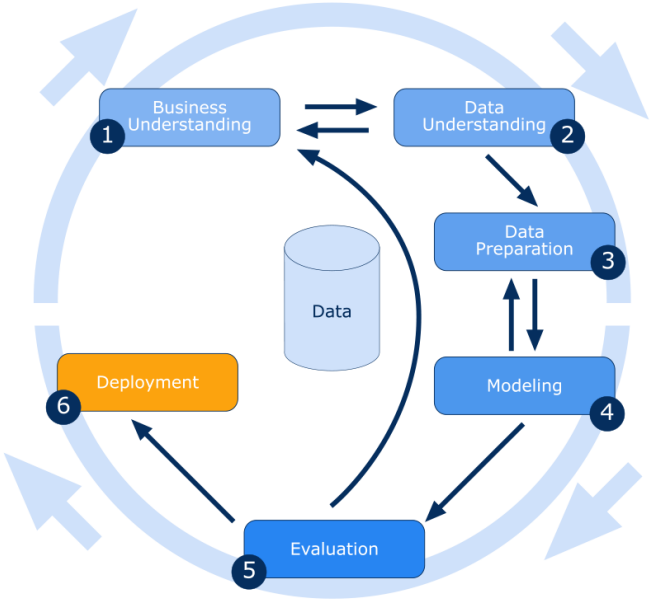

A) **Errada**. O CRISP-DM propõe a ser uma referência que apresenta uma visão geral do ciclo de vida de um projeto de mineração de dados, logo, a alternativa B está **incorreta**.

B) **Correto!** Na fase de entendimento ou seleção dos dados é traçado o perfil dos dados. Neste momento é avaliada a qualidade dos dados.

C) **Errada**. A preparação dos dados está mais preocupada em trazer e ajustar os dados para execução do algoritmo de mineração. A fase de **preparação de dados** consiste na preparação dos dados que visa a **coleta, limpeza**, **transformação**, **integração** e **formatação** dos dados definidos na etapa anterior. Logo, temos mais uma alternativa **incorreta**.

D) **Errada**. Não existe uma fase de avaliação dos dados dentro do processo. Logo, temos mais uma alternativa **incorreta**.

E) **Errada**. Vejam que a alternativa E está **incorreta** pois as ações descritas são associadas a fase de avaliação do processo.

Gabarito: B.

---

21. **Ano: 2018 Banca: CESPE Órgão: TCM-BA Cargo: Auditor de Contas Questão: 13**

A respeito das técnicas e(ou) métodos de mineração de dados,

assinale a opção correta.

A O agrupamento (ou clustering) realiza identificação de grupos de dados que apresentam coocorrência.

B A classificação realiza o aprendizado de uma função que pode ser usada para mapear os valores associados aos dados em um ou mais valores reais.

98276239072 - FABIANO CARBONELL DA SILVA

C A regressão ou predição promove o aprendizado de uma função que pode ser usada para mapear dados em uma de várias classes discretas definidas previamente, bem como encontrar tendências que possam ser usadas para entender e explorar padrões de comportamento dos dados.

D As regras de associação identificam grupos de dados, em que os dados têm características semelhantes aos do mesmo grupo e os grupos têm características diferentes entre si.

E Os métodos de classificação supervisionada podem ser embasados em separabilidade (entropia), utilizando árvores de decisão e variantes, e em particionamento, utilizando SVM (support vector machines).

Comentário: Vamos analisar cada uma das alternativas acima.

A) **Errada**. A alternativa apresenta o conceito de **coocorrência** que está relacionado ao conceito de **regra de associação**, e tenta colocá-lo dentro do contexto de **agrupamento**. Sendo assim, temos mais uma alternativa **incorreta**.

B) **Errada**. A **classificação** baseia-se na definição de um **conjunto de rótulos** que permitem classificar uma nova informação em um conjunto de classes pré-definidas. Veja que essas classes não necessariamente são valores reais. Logo, temos uma alternativa **incorreta**. Quando o classificador utiliza como saída um valor real estamos caracterizando uma **regressão**.

C) **Errada**. A regressão não vai mapear valores em um conjunto de classes. Se você pensar que a regressão é uma função de múltiplas variáveis a imagem desta pode ser um conjunto fechado, porém, contínuo. Logo, temos uma alternativa **errada**. A matemática simplificada de uma regressão pode ser vista na figura abaixo:

D) **Errada**. A alternativa D descreve uma característica da tarefa de clusterização. Logo, temos uma alternativa **incorreta**.

E) **Essa é a nossa resposta.** Basicamente, o **SVM é um algoritmo supervisionado** que tenta criar uma linha (ou uma fronteira) que separa melhor um conjunto de dados. Essa linha normalmente chamamos de "**Hyperplano**". Para entender um pouco mais desse algoritmo acesse o *link*. Veja que ele aplica o conceito de particionamento. Agora ideia da classificação é construir um conceito de separabilidade entre os novos valores de entrada e as classes ou rótulos estabelecidos. Veja na figura abaixo os itens separados por um hyperplano.

98276239072 - FABIANO CARBONELL DA SILVA

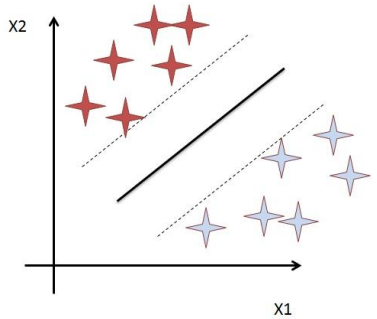

Gabarito: E.

22. **Ano: 2017 Banca: CESPE Órgão: TCE-PE Cargo: Auditor de Obras Públicas Questão: 119**

Julgue o item que se refere a CRISP-DM (Cross Industry Standard Process for Data Mining).

[119] Durante a fase de entendimento do negócio, busca-se descrever claramente o problema, fazer a identificação dos dados e verificar se as variáveis relevantes para o projeto não são interdependentes.

Comentário: Essa para mim foi a questão mais difícil desta prova. Primeiramente você teria que se lembrar das **fases do CRISP-DM,** a **primeira** fase é **o entendimento do negócio** e a **segunda entendimento dos dados**. Vejamos o que cada uma tem como objetivo:

Entendimento do negócio: deve determinar os objetivos de negócio, fazer uma análise da situação atual e estabelecer os objetivos da mineração de dados. Finalizando com um plano de projeto.

Entendimento dos dados: Nesta etapa vamos entender os dados baseados nos requisitos. Nesta etapa podemos incluir uma coleta de dados, descrição, exploração e verificação da qualidade dos mesmos. Nesta etapa temos uma característica peculiar: identificar se as variáveis do modelo são independentes umas das outras. Quando as variáveis são independentes podemos concluir que elas não possuem informações sobrepostas. Em econometria ou analise matemática podemos pensar em variáveis que são linearmente independentes. Uma escolha cuidadosa de variáveis independentes pode fazer com que a execução dos algoritmos seja feita de forma mais eficiente.

Enfim, depois desta explicação teórica, podemos perceber que o examinador associou eventos de etapas diferentes dos CRISP a fase de entendimento do negócio. Logo, a alternativa está **incorreta**.

Gabarito: errada.

23. **Ano: 2017 Banca: CESPE Órgão: TCE-PE Cargo: Analista De Controle Externo Área: Auditoria De Contas Públicas Questão: 119**

Em relação à análise de agrupamentos (clusterização) em mineração de dados, julgue o item seguinte.

119 O método de clustering k-means objetiva particionar ‘n’ observações entre ‘k’ grupos; cada observação pertence ao grupo mais próximo da média.

98276239072 - FABIANO CARBONELL DA SILVA

Comentário: O algoritmo de **K-means** é de fato um **método de clusterização**. O algoritmo inicia com a escolha dos **k** elementos que formaram as sementes iniciais. Vamos tentar entender um pouco mais do funcionamento do mesmo.

Escolhidas as sementes iniciais, é calculada a distância de cada elemento em relação às sementes, agrupando o elemento ao grupo que possuir a menor distância (mais similar) e recalculando o centroide do mesmo. Quando temos mais de um elemento, imagine vários pontos em um papel, o centroide é um ponto central entre esses pontos. O processo é repetido até que todos os elementos façam parte de um dos clusters. Veja a figura abaixo para entender um pouco mais sobre esse processo.

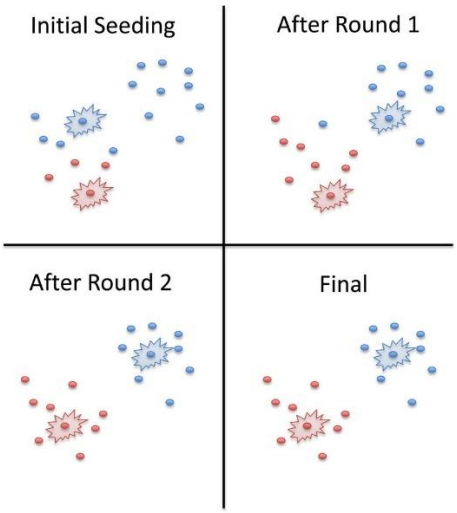

Depois desta etapa, fazemos ajustes nos elementos usando métodos estatísticos que tentam diminuir a dispersão dentro de cada grupo, por meio da mudança de elementos entre os grupos. O processo é interrompido quando a mudança de um elemento de um cluster para outro não gera mais ganho.

Para visualizar o algoritmo funcionando, você pode olhar na página da *Wikipédia em inglês*. Para saber a fonte da questão, basta acessar a definição da Wikipédia em português: "Em mineração de dados, agrupamento k-means é um método de Clustering que objetiva particionar n observações dentre k grupos onde cada observação pertence ao grupo mais próximo da média. Isso resulta em uma divisão do espaço de dados em um Diagrama de Voronoi."

Desta forma, a alternativa está **correta**.

Gabarito: certa.

---

24. **Ano: 2016 Banca: CESPE Órgão: TCE-SC Cargo: Auditor de TI**

Julgue o item subsecutivo, acerca de mineração de dados.

98 Para a realização de prognósticos por meio de técnicas de mineração de dados, parte-se de uma série de valores existentes obtidos de dados históricos bem como de suposições controladas a respeito das condições futuras, para prever outros valores e situações que ocorrerão e, assim, planejar e preparar as ações organizacionais.

Comentário: A alternativa 98 trata dos aspectos de previsão relacionados a mineração de dados. Basicamente, você deve escolher um algoritmo, parametrizar, utilizar dados históricos das bases de dados como entrada e tentar prever o futuro. O texto da questão está **correto**.

98276239072 - FABIANO CARBONELL DA SILVA

Gabarito: certa.

25. **Ano: 2016 Banca: CESPE Órgão: TCE-SC Cargo: Auditor de TI**

Julgue o item subsecutivo, acerca de mineração de dados.

99 As aglomerações, tipos de informação obtidos por meio da mineração de dados, caracterizam-se por se ligarem a um único e específico evento, em torno do qual ocorrem várias ações, com produção sistêmica de informações gerenciais que apoiarão uma nova ocorrência do mesmo tipo de evento.

Comentário: Aglomerações ou clusters são grupos de indivíduos de uma amostra que possuem características semelhantes. Geralmente são definidos intervalos de valores, para cada intervalo temos um clusters, agrupamento ou aglomeração. Essa ideia de eventos em série relacionados a um evento inicial está relacionada a técnicas de associação. Questão, portanto, encontra-se **incorreta**.

Gabarito: errada.

QUESTIONÁRIO DE REVISÃO E APERFEIÇOAMENTO

A ideia do questionário é elevar o nível da sua compreensão no assunto e, ao mesmo tempo, proporcionar uma outra forma de revisão de pontos importantes do conteúdo, a partir de perguntas que exigem respostas subjetivas.

São questões um pouco mais desafiadoras, porque a redação de seu enunciado não ajuda na sua resolução, como ocorre nas clássicas questões objetivas.

O objetivo é que você realize uma autoexplicação mental de alguns pontos do conteúdo, para consolidar melhor o que aprendeu ;)

Além disso, as questões objetivas, em regra, abordam pontos isolados de um dado assunto. Assim, ao resolver várias questões objetivas, o candidato acaba memorizando pontos isolados do conteúdo, mas muitas vezes acaba não entendendo como esses pontos se conectam.

Assim, no questionário, buscaremos trazer também situações que ajudem você a conectar melhor os diversos pontos do conteúdo, na medida do possível.

É importante frisar que não estamos adentrando em um nível de profundidade maior que o exigido na sua prova, mas apenas permitindo que você compreenda melhor o assunto de modo a facilitar a resolução de questões objetivas típicas de concursos, ok?

Nosso compromisso é proporcionar a você uma revisão de alto nível!

Vamos ao nosso questionário:

98276239072 - FABIANO CARBONELL DA SILVA

Perguntas

1. **Defina os termos a seguir quando se aplicam ao modelo de dados relacional: domínio, atributo, tupla n, esquema de relação, estado de relação, grau da relação, esquema de banco de dados relacional e estado de banco de dados relacional.**

2. **Por que as tuplas em uma relação não são ordenadas?**

3. **Por que as tuplas duplicadas não são permitidas em uma relação?**

4. **Qual é a diferença entre uma chave e uma superchave?**

5. **Por que designamos uma das chaves candidatas de uma relação como sendo a chave primária?**

6. **Descreva as características de relações que as tornam diferentes das tabelas e arquivos comuns.**

7. **Descreva os diversos motivos que levam à ocorrência de valores NULL nas relações.**

8. **Descreva as restrições de integridade de entidade e integridade referencial. Por que são consideradas importantes?**

9. **Defina a chave estrangeira. Para que esse conceito é usado?**

10. **Quais são os principais componentes de um sistema de banco de dados?**

11. **Em um banco de dados os dados são persistentes, integrados e compartilhados, explique estes três atributos dos dados em um banco de dados.**

12. **Cite quais as etapas do processo e modelagem de dados em sua respectiva ordem evolutiva e defina cada uma delas.**

Perguntas com respostas

1. Defina os termos a seguir quando se aplicam ao modelo de dados relacional: domínio, atributo, tupla n, esquema de relação, estado de relação, grau da relação, esquema de banco de dados relacional e estado de banco de dados relacional.

Um banco de dados relacional consiste em uma coleção de tabelas. Cada tabela tem um cabeçalho ou uma parte de definição, e um corpo, ou uma parte de conteúdo. A parte do cabeçalho é composta do nome da tabela e nomes de colunas. Por exemplo, uma tabela de alunos pode ter colunas de número do CPF, nome, endereço, cidade, estado, CEP, classe (primeiro, segundo, terceiro ano etc.), especialização e média geral de notas. O corpo mostra as linhas da tabela. Cada linha de uma tabela de alunos representa um aluno matriculado em uma universidade.

98276239072 - FABIANO CARBONELL DA SILVA

2. Por que as tuplas em uma relação não são ordenadas?

Essa propriedade também resulta do fato de que o corpo da relação é um conjunto (de tuplas); em matemática, os conjuntos não são ordenados. Quando representamos uma relação como uma tabela no papel, somos forçados a mostrar as linhas dessa tabela em alguma ordem de cima para baixo, porém, mais uma vez, você deverá ignorar essa ordem, se puder.

3. Por que as tuplas duplicadas não são permitidas em uma relação?

Essa propriedade resulta do fato de que o corpo da relação é um conjunto; em matemática, os conjuntos não contêm elementos duplicados (o que equivale a dizer que os elementos são todos distintos).

4. Qual é a diferença entre uma chave e uma superchave?

Superchave: uma coluna ou uma combinação de colunas contendo valores únicos para cada linha. A combinação de todas as colunas em uma tabela sempre é uma superchave, porque as linhas de uma tabela devem ser únicas. (SUPERCHAVE = UNICIDADE)

Chave: uma superchave mínima. A superchave é mínima se, com a remoção de qualquer coluna, ela deixa de ser única. (CHAVE = UNICIDADE + IRREDUTIBILIDADE)

5. Por que designamos uma das chaves candidatas de uma relação como sendo a chave primária?

Em geral, um esquema de relação pode ter mais de uma chave. Nesse caso, cada uma das chaves é chamada de chave candidata. Chave primária é chave candidata especialmente designada. A chave primária de uma tabela não pode conter valores nulos.

6. Descreva as características de relações que as tornam diferentes das tabelas e arquivos comuns.

Uma relação consiste em um cabeçalho e um corpo. Dentro de qualquer relação temos as seguintes características:

1. Cada tupla contém exatamente um valor (do tipo apropriado) para cada atributo.

2. Atributos não são ordenados da esquerda para a direita.

3. Tuplas não são ordenadas de cima para baixo.

4. Não existem tuplas em duplicata.

7. Descreva os diversos motivos que levam à ocorrência de valores NULL nas relações.

Valores NULL representam atributos cujos valores são desconhecidos ou não existem para alguma tupla individual.

8. Descreva as restrições de integridade de entidade e integridade referencial. Por que são consideradas importantes?

98276239072 - FABIANO CARBONELL DA SILVA

A restrição de integridade de entidade afirma que nenhum valor de chave primária pode ser NULL. Isso porque o valor da chave primária é usado para identificar tuplas individuais em uma relação. Ter valores NULL para a chave primária implica que não podemos identificar algumas tuplas.

A restrição de integridade referencial é especificada entre duas relações e usada para manter a consistência entre tuplas nas duas relações. Informalmente, a restrição de integridade referencial afirma que uma tupla em uma relação que referencia outra relação precisa se referir a uma tupla existente nessa relação.

Restrições de integridade são especificadas em um esquema de banco de dados e espera-se que sejam mantidas em cada estado de banco de dados válido desse esquema.

9. Defina a chave estrangeira. Para que esse conceito é usado?

Chave estrangeira pode ser definida como uma coluna ou uma combinação de colunas em que os valores devem corresponder aos valores de uma chave candidata. A chave estrangeira deve ter tipo de dado igual ao da chave candidata associada.

10. Quais são os principais componentes de um sistema de banco de dados?

98276239072 - FABIANO CARBONELL DA SILVA

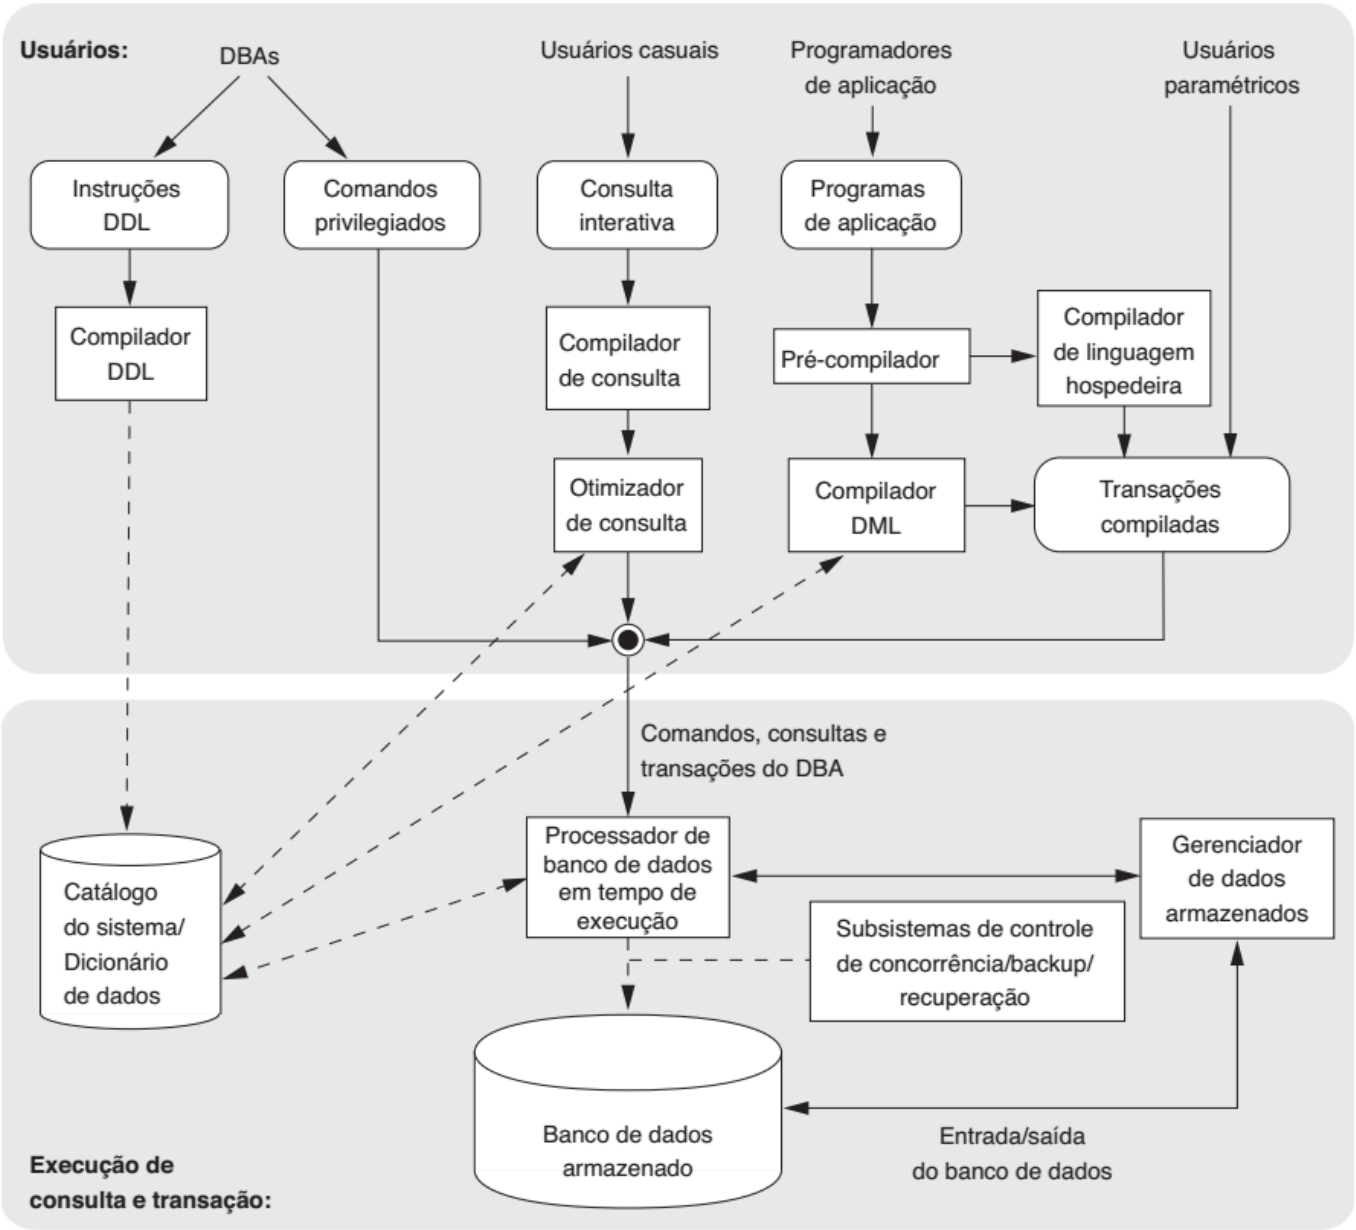

A figura acima ilustra, de uma forma simplificada, os componentes típicos do SGBD. A figura está dividida em duas partes. A parte superior refere-se aos vários usuários do ambiente de banco de dados e suas interfaces. A parte inferior mostra os detalhes internos do SGBD, responsáveis pelo armazenamento de dados e processamento de transações.

11. Em um banco de dados os dados são persistentes, integrados e compartilhados, explique estes três atributos dos dados em um banco de dados.

Persistente: significa que os dados são armazenados de modo permanente, como em um disco magnético. Por exemplo, as organizações necessitam reter dados sobre clientes, fornecedores e estoque em armazenamento permanente porque esses dados são usados repetitivamente.

98276239072 - FABIANO CARBONELL DA SILVA

Compartilhado: significa que um banco de dados pode ter múltiplas aplicações e usuários. Um banco de dados fornece uma memória comum para múltiplas funções em uma organização. Por exemplo, um banco de dados pessoal pode dar suporte a cálculos de folha de pagamento, avaliações de desempenho, informações exigidas pelo governo e assim por diante.

Integrado: significa que dados armazenados como unidades separadas podem ser ligados para fornecer um quadro completo. Por exemplo, um banco de dados de clientes relaciona os dados do cliente (nome, endereço...) com os dados do pedido (número do pedido, data do pedido...) para facilitar o processamento dos pedidos. Os bancos de dados contêm tanto entidades como relacionamentos entre entidades.

12. Cite quais as etapas do processo e modelagem de dados em sua respectiva ordem evolutiva e defina cada uma delas.

Em relação aos modelos de dados temos 3 níveis: conceitual, lógico e físico. Vamos revisar cada um deles:

Modelo Conceitual. A modelagem conceitual baseia-se no mais alto nível e deve ser usada para envolver o cliente, pois o foco aqui é discutir os aspectos do negócio e não da tecnologia. Os exemplos de modelagem de dados vistos pelo modelo conceitual são mais fáceis de compreender, já que não há limitações ou aplicação de tecnologia específica (não temos a definição do SGBD). O diagrama de dados que deve ser construído aqui é o Diagrama de Entidade e Relacionamento, onde deverão ser identificados todas as entidades e os relacionamentos entre elas. Este diagrama é a chave para a compreensão do modelo conceitual de dados.

Modelo Lógico. O modelo lógico já leva em conta algumas limitações e implementa recursos como adequação de padrão e nomenclatura, define as chaves primárias e estrangeiras, normalização, integridade referencial, entre outras. Para o modelo lógico deve ser criado levando em conta os exemplos de modelagem de dados criados no modelo conceitual.

Modelo Físico. No modelo físico fazemos a modelagem física do modelo de banco de dados. Neste caso leva-se em conta as limitações impostas pelo SGBD escolhido e deve ser criado sempre com base nos exemplos de modelagem de dados produzidos no item anterior, modelo lógico. Aqui é trabalhado no nível mais baixo de abstração, descrevendo o modo como os dados são salvos em meios de armazenamentos, como discos e fitas, sendo exigido a definição tanto dos dispositivos de armazenamento físico como dos métodos de acesso (físico) necessários para se chegar aos dados nesses dispositivos, o que o torna dependente tanto de software como de hardware.

Forte abraço e bons estudos.

"Hoje, o 'Eu não sei', se tornou o 'Eu ainda não sei'"

(Bill Gates)

Thiago Cavalcanti

98276239072 - FABIANO CARBONELL DA SILVA

Face: www.facebook.com/profthiagocavalcanti
Insta: www.instagram.com/prof.thiago.cavalcanti
YouTube: youtube.com/profthiagocavalcanti

98276239072 - FABIANO CARBONELL DA SILVA

ESSA LEI TODO MUNDO CONHECE:
PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.

1. Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.

2. Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).

3. Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).

4. Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).

5. Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).

6. Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).

7. Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.

8. O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.

Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.