Estratégia Concursos

Aula 21

Polícia Federal (Agente de Polícia) Passo Estratégico de Informática - Prof. Thiago Cavalcanti

Autor:

Thiago Rodrigues Cavalcanti

06 de Abril de 2023

98276239072 - FABIANO CARBONELL DA SILVA

NOÇÕES DE APRENDIZADO DE MÁQUINA. NOÇÕES DE BIGDATA: CONCEITO, PREMISSAS E APLICAÇÃO

Sumário

Análise Estatística 1
Roteiro de revisão e pontos do assunto que merecem destaque 2
Noções de Aprendizado de Máquina 3
Modelos de Aprendizado de máquina 4
Big Data: Definições e conceitos 5
Falácias sobre Big Data 12
Aplicações de Big Data 14
Classificação de Big Data 15
Padrões atômicos e compostos de uma solução de Big Data 18
Aposta estratégica 24
Questões estratégicas 27

ANÁLISE ESTATÍSTICA

Assunto	Grau de incidência em concursos similares Cebraspe
4 Conceitos de proteção e segurança. 4.1 Noções de vírus, worms e pragas virtuais. 4.2 Aplicativos para segurança (antivírus, firewall, anti-spyware etc.). 5 Computação na nuvem (cloud computing).	15,07%
3 Redes de computadores. 10 Redes de comunicação. 10.1 Introdução a redes (computação/telecomunicações). 10.2 Camada física, de enlace de dados e subcamada de acesso ao meio. 10.3 Noções básicas de transmissão de dados: tipos de enlace, códigos, modos e meios de transmissão. 11 Redes de	13,33%

98276239072 - FABIANO CARBONELL DA SILVA

computadores: locais, metropolitanas e de longa distância. 11.1 Terminologia e aplicações, topologias, modelos de arquitetura (OSI/ISO e TCP/IP) e protocolos. 11.2 Interconexão de redes, nível de transporte.	
1 Conceito de internet e intranet. 2 Conceitos e modos de utilização de tecnologias, ferramentas, aplicativos e procedimentos associados a internet/intranet.	9,86%
2.1 Ferramentas e aplicativos comerciais de navegação.	9,86%
2.2 Noções de sistema operacional (ambiente Windows).	9,86%
2.4 Edição de planilhas (ambientes Microsoft Office e LibreOffice).	6,96%
2.1 Ferramentas e aplicativos comerciais de correio eletrônico, de grupos de discussão, de busca, de pesquisa e de redes sociais.	6,09%
2.4 Edição de textos (ambientes Microsoft Office e LibreOffice).	6,09%
9.4 Banco de dados relacionais: conceitos básicos e características. 9.5 Chaves e relacionamentos. 9.6 Noções de mineração de dados: conceituação e características.	5,22%
2.2 Noções de sistema operacional (ambiente Linux).	4,06%
6 Fundamentos da Teoria Geral de Sistemas. 7 Sistemas de informação. 7.1 Fases e etapas de sistema de informação. 8 Teoria da informação. 8.1 Conceitos de informação, dados, representação de dados, de conhecimentos, segurança e inteligência.	3,48%
9 Banco de dados. 9.1 Base de dados, documentação e prototipação. 9.2 Modelagem conceitual: abstração, modelo entidaderelacionamento, análise funcional e administração de dados. 9.3 Dados estruturados e não estruturados.	3,19%
2.3 Acesso à distância a computadores, transferência de informação e arquivos, aplicativos de áudio, vídeo e multimídia.	2,61%
9.7 Noções de aprendizado de máquina. 9.8 Noções de bigdata: conceito, premissas e aplicação.	2,03%
2.4 Edição de apresentações (ambientes Microsoft Office e LibreOffice).	1,45%
12 Noções de programação Python e R. 13 API (application programming interface). 14 Metadados de arquivos.	0,87%

ROTEIRO DE REVISÃO E PONTOS DO ASSUNTO QUE MERECEM DESTAQUE

A ideia desta seção é apresentar um roteiro para que você realize uma revisão completa do assunto e, ao mesmo tempo, destacar aspectos do conteúdo que merecem atenção.

Para revisar e ficar bem preparado no assunto, você precisa, basicamente, seguir os passos a seguir:

98276239072 - FABIANO CARBONELL DA SILVA

Noções de Aprendizado de Máquina

Vamos começar essa aula tentando responder a uma pergunta simples: o que é **Aprendizado de Máquina**?

> *Machine Learning (ML)* ou aprendizado de máquina é **uma área da inteligência artificial** cujo objetivo é o desenvolvimento de **técnicas computacionais sobre o aprendizado,** bem como a construção de sistemas capazes de adquirir conhecimento de forma automática. Um sistema de aprendizado é um programa de computador que toma decisões baseado em experiências acumuladas por meio de solução bem-sucedida de problemas anteriores. É uma ferramenta poderosa para aquisição automática de conhecimento, entretanto, não existe um único algoritmo ou solução que apresente melhor desempenho para todos problemas.

Segundo *T. Michell*, o aprendizado de máquina trata do projeto e desenvolvimento de algoritmos que imitam o comportamento de aprendizagem humano, com um foco principal em aprender automaticamente a reconhecer padrões complexos e tomar decisões.

Se voltarmos algumas páginas e relembrarmos das tarefas de mineração de dados listadas no início da aula, veremos que todas elas podem ser abordadas por algum algoritmo de aprendizado de máquina. Nesta parte da aula, vamos apresentar alguns desses algoritmos sempre apresentando as tarefas que esses procuram resolver.

A aplicações atuais de ML passam por diferentes escopos. Para termos uma ideia de algumas aplicações que temos hoje em dia, vamos observar o quadro abaixo:

- Classificação de Padrões (ex.: imagens, crédito bancário)
- Processamento de Linguagem Natural (ex.: como usar notícias como fonte de informação)
- Reconhecimento de Objetos (ex.: reconhecer pessoas ou objetos)
- Jogar jogos (ex.: xadrez, gamão)
- Previsão de variáveis relevantes (ex.: inflação, retornos de ativos financeiros)
- Clustering (ex.: segmentar clientes de uma empresa)

Veja a o aprendizado de máquina trabalha como uma ciência que aborda o desenvolvimento de algoritmos e técnicas que permitem computadores/máquinas aprenderem a realizar tarefas, fazer escolhas ou prever resultados.

Duas fontes de erros devem ser analisadas quando estamos trabalhando com algoritmos de aprendizado de máquina: viés (bias) e variância. O **viés** aparece quando o algoritmo aprende um modelo incorreto, muitas vezes pode ser associado à ideia de ***underfitting,*** pois não consegue induzir um modelo que se ajusta aos dados. Já variância está relacionada ao fato de o algoritmo prestar atenção a detalhes sem importância, criando um modelo complexo e pesado, levando a um termo conhecido como ***overfitting***.

98276239072 - FABIANO CARBONELL DA SILVA

Modelos de Aprendizado de máquina

Aprendizado de máquina é a interseção entre ciência da computação teoricamente sólida e dados ruidosos. Essencialmente, trata-se de máquinas que dão sentido aos dados, da mesma maneira que os humanos. O aprendizado de máquina é um tipo de **inteligência artificial** em que um algoritmo ou método extrairá padrões de dados.

De um modo geral, há alguns problemas ou modelos associados ao aprendizado de máquina: aprendizado supervisionado, não supervisionado e por reforço. Estes estão listados e descritos abaixo:

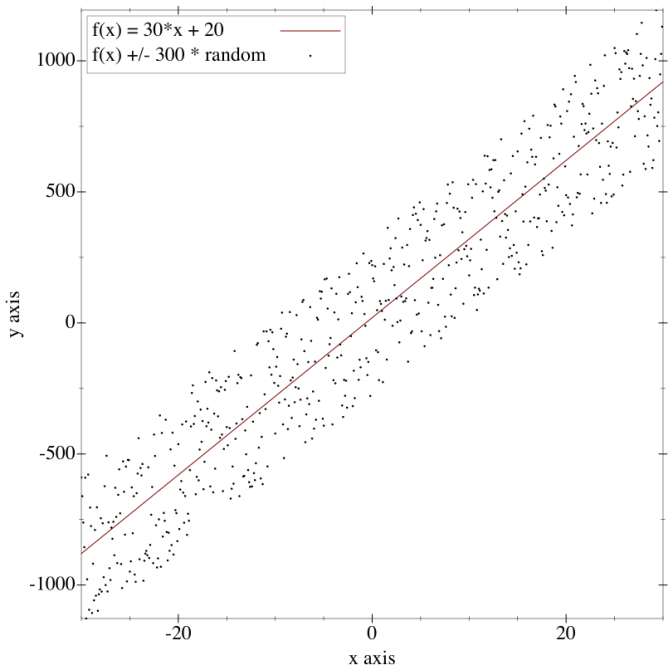

Aprendizagem Supervisionada

O aprendizado supervisionado, ou aproximação de função, procura simplesmente ajustar os dados a uma função qualquer. Por exemplo, dados os dados ruidosos (fora da linha vermelha) mostrados na figura ao lado, você pode ajustar ou construir uma linha se aproxima genericamente dos dados. Uma questão interessante sobre aprendizado supervisionado é que as entradas e as saídas para um determinado conjunto de dados são conhecidas. A tarefa de classificação é um bom exemplo deste tipo de aprendizado.

Algoritmos de aprendizagem supervisionada **<u>supõem a existência de um "professor"</u>** que te ensina que tipo de comportamento você deve exibir em cada situação. Imagine que você deseja classificar empresas saudáveis de não saudáveis e, para fazer isso, você tem uma amostra que associa cada empresa saudável a uma série de variáveis. Então, um algoritmo de aprendizagem supervisionado tentaria usar explicitamente essa informação para, no futuro, ser hábil para separar empresas saudáveis de não saudáveis.

Agora que já sabemos o que seria o aprendizado supervisionado, vamos tentar apresentar uma técnica que trabalha este tópico. **Vamos observar o modelo PROBIT**. Na estatística, um modelo de PROBIT é um tipo de regressão em que a variável dependente pode levar apenas dois valores, por exemplo, **casado ou não**. O objetivo do modelo é estimar a probabilidade de que uma observação com características particulares apareça em uma das categorias específicas. Além disso, classificar as observações com base em suas probabilidades previstas é um tipo de modelo de classificação binária. Veja na figura abaixo um exemplo de classificação usando PROBIT, aproveitamos para introduzir o conceito de perfeitamente separável, neste caso a figura é autoexplicativa.

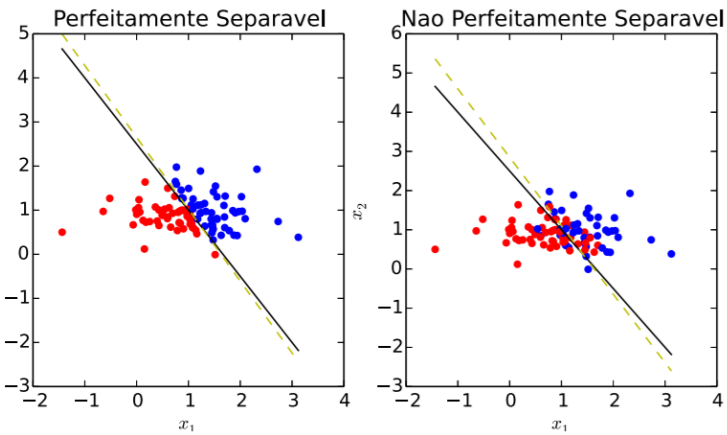

98276239072 - FABIANO CARBONELL DA SILVA

Quanto nem todos os pares de entrada e saída são conhecidos, o modelo pode ser descrito como aprendizado **semi-supervisionado**. O aprendizado semi-supervisionado é uma classe de tarefas e técnicas de aprendizado supervisionadas que também fazem uso de dados não rotulados para treinamento - normalmente, uma pequena quantidade de dados rotulados com uma grande quantidade de dados não rotulados.

Muitos pesquisadores de aprendizado de máquina descobriram que dados não rotulados, quando usados em conjunto com uma pequena quantidade de dados rotulados, podem produzir melhorias consideráveis na precisão da aprendizagem.

Aprendizagem não supervisionada

O aprendizado não supervisionado envolve descobrir o que torna os dados especiais. Por exemplo, se recebêssemos muitos pontos de dados, poderíamos agrupá-los por semelhança, ou talvez determinar quais variáveis são melhores que outras. Nenhum rótulo é dado ao algoritmo de aprendizado, deixando-o sozinho para encontrar a estrutura em sua entrada. O aprendizado não supervisionado pode ser um objetivo em si (descobrir padrões ocultos nos dados) ou um meio para um fim.

Aprendizagem por Reforço

O aprendizado por reforço envolve descobrir como jogar um jogo de múltiplos estágios com recompensas. Os dados de treinamento (em forma de recompensas e punições) são dados apenas como feedback às ações do programa em um ambiente dinâmico, como dirigir um veículo ou jogar um jogo contra um adversário. Um exemplo interessante de aprendizado por reforço é a forma com as empresas ajustam seus preços de forma dinâmica reagindo aos preços dos concorrentes. Veja a figura abaixo:

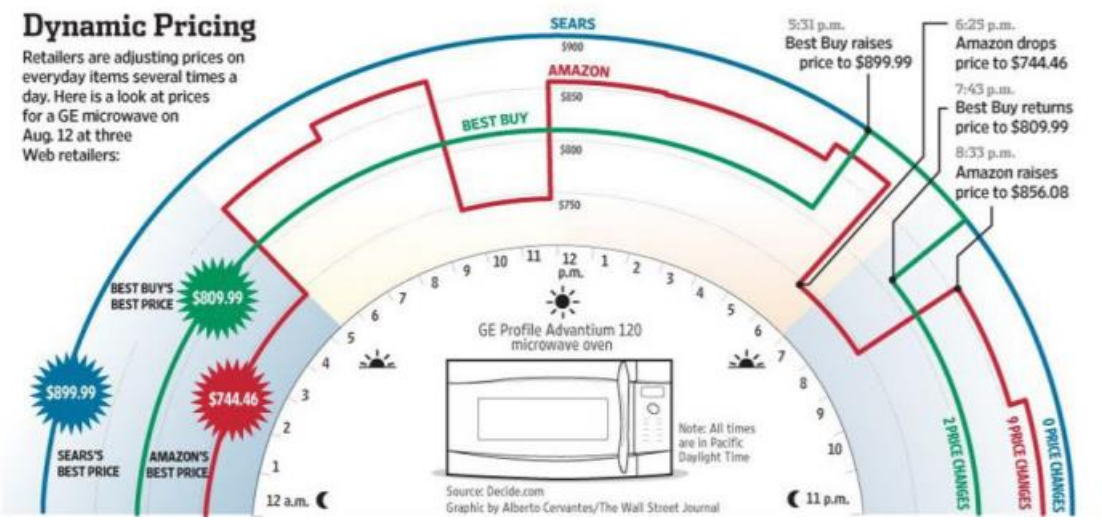

Big Data: Definições e conceitos

A humanidade, nos dias de hoje, produz uma quantidade diária de dados que é simplesmente improcessável pelos próprios seres humanos.

98276239072 - FABIANO CARBONELL DA SILVA

Para se ter uma ideia, a IBM, em 2013, estimou que **2,5 exabytes** (2.500.000.000.000.000.000) de bytes de dados são criados **por dia**. Se cada um dos 7 bilhões de habitantes tivesse que se debruçar sobre essas informações, seriam aproximadamente 300MB de dados diários para cada cidadão, incluindo bebês e idosos, rs.

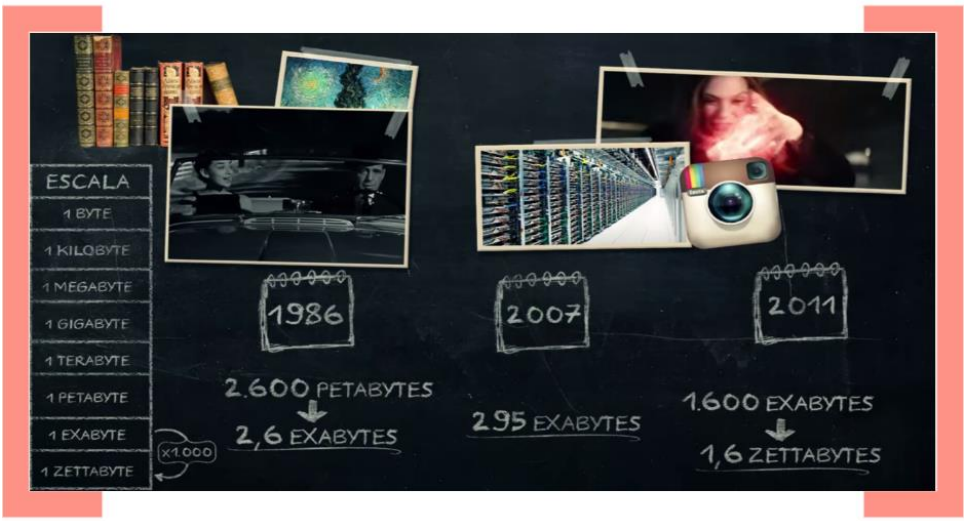

São vídeos no youtube, postagens em redes sociais, blogs, portais de notícias, emails, dentre outros. E o que esses dados possuem em comum? São **dados não-estruturados**. Estima-se que 85% das informações com as quais as empresas lidam hoje não estão estruturadas. Desta forma, o SGBD tradicional e a modelagem relacional (datados da década de 60) não são mais suficientes para lidar com a realidade atual. É necessária uma nova abordagem. Surge então o conceito de Big Data!

> **Big Data** pode ser entendido como a **captura, gerenciamento e análise de dados que vão além de dados estruturados** típicos, que podem ser consultados por sistemas de gerenciamento de banco de dados relacional — frequentemente em arquivos não estruturados, vídeo digital, imagens, dados de sensores, arquivos de log e, na verdade, qualquer dado não contido nos registros com campos pesquisáveis distintos.

Em um certo sentido, os dados não estruturados são dados interessantes, mas difíceis de sintetizar ou tirar conclusões deles, a menos que possam ser correlacionados a dados estruturados. Big data apresenta soluções para integrar os dados estruturados e desestruturados.

Em um primeiro momento, o Big Data pode até ser confundido com a *Business Intelligence*, mas difere na **ordem de grandeza** do volume de dados (que é muito maior), e **na natureza dos dados**. Enquanto as ferramentas de BI tradicionais extraem dados de fontes estruturadas, "abrindo exceções para a captura de dados não estruturados", o Big Data entende que os dados não-estruturados são a "maioria", por assim dizer.

Nossa ideia é começar o assunto apresentando, de forma sucinta, os conceitos básicos que permeiam o termo ***Big Data***. Vamos começar pela definição que surgiu em 2001 no Meta Group (que viria a se juntar com a

98276239072 - FABIANO CARBONELL DA SILVA

Gartner[1] mais adiante) por meio do analista **Doug Laney**. Para compor o conceito ele se utilizou de três termos, conhecidos como os 3Vs: **Volume**, **Velocidade** e **Variedade**. Vejamos a definição de cada um deles.

TOME NOTA!

Volume. Existem muitos fatores que contribuem para o aumento do volume de dados armazenados e trafegados. Podemos citar como exemplo: dados de transações armazenados ao longo de vários anos, dados de texto, áudio ou vídeo disponíveis em streaming nas mídias sociais e a crescente quantidade de dados coletados por sensores. No passado o volume de dados excessivo criou um problema de armazenamento. Mas, com os atuais custos de armazenamento decrescentes, outras questões surgem, incluindo, **como determinar a relevância** entre grandes volumes de dados e **como criar valor** a partir dessa relevância.

Velocidade. De acordo com o Laney, velocidade significa o quão **rápido** os dados estão sendo **produzidos e** o quão rápido os dados devem ser **tratados** para atender as demandas. Etiquetas de RFID e sensores inteligentes estão impulsionando uma necessidade crescente de lidar com dados quase em tempo real. Reagir rápido o suficiente para lidar com a velocidade é um desafio para a maioria das organizações.

Variedade. Os dados de hoje vêm em todos os **tipos de formatos**. Sejam bancos de dados tradicionais, hierarquias de dados criadas por usuários finais e sistemas OLAP, arquivos de texto, e-mail, medidores ou sensores de coleta de dados, vídeo, áudio, dados de ações do mercado e transações financeiras. Em algumas estimativas, 80% dos dados de uma organização não são numéricos! Mas, estes dados também precisam ser incluídos nas análises e nas tomadas de decisões das empresas.

Big Data é importante porque permite que as organizações recolham, armazenem, administrem e manipulem grandes quantidades de dados na velocidade certa, no tempo certo para conseguir os conhecimentos corretos. A novidade é que, pela primeira vez, o custo de ciclos de **computação e armazenamento** alcançou uma relação interessantes de curso x benefício. Por que isso é importante? Há alguns anos atrás, as empresas normalmente armazenariam "fotos" ou subconjuntos de informações importantes, **porque o custo de armazenamento e a limitação do processamento os impedia de armazenar tudo o que queriam analisar**.

Além da melhoria na capacidade de processamento e armazenamento, melhorias na velocidade de rede e confiança removeram outras limitações físicas da capacidade de administrar quantidades massivas de dados a

[1] Gartner é uma empresa de consultoria fundada em 1979 por Gideon Gartner. A Gartner desenvolve tecnologias relacionadas a introspecção necessária para seus clientes tomarem suas decisões todos os dias.

98276239072 - FABIANO CARBONELL DA SILVA

um passo aceitável. Assim, as organizações querem ser capazes de compreender e acionar resultados de diferentes tipos de dados na velocidade certa — não importa quantos dados estejam envolvidos.

> *Se as empresas podem analisar petabytes de dados (o equivalente a 20 milhões de gabinetes, com quatro gavetas cheias de arquivos de texto ou 13.3 anos de conteúdo de HDTV) com desempenho aceitável para discernir padrões e anomalias, elas podem começar a compreender dados de novas maneiras.*
>
> *Judith Hurwiz, et al - Big Data Para Leigos*

A mudança para Big Data **não é exclusivamente em negócios**. Ciência, pesquisa e atividades do governo também ajudaram a impulsioná-la. Pense sobre analisar o genoma humano ou lidar com todos os dados astronômicos coletados em observatórios para avançar nosso conhecimento do mundo à nossa volta. Considere também a quantidade de dados que o governo coleta em suas atividades antiterroristas e você entenderá a ideia de que Big Data não é só sobre negócios.

RESUMINDO

Volume

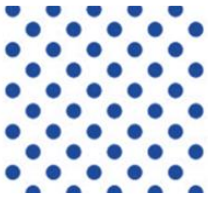

Dados em repouso

- Terabytes ou exabytes de dados existentes para o processo

Velocidade

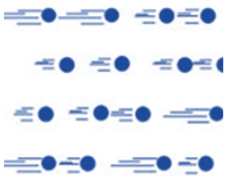

Dados em movimento

- Streaming data (fluxo de dados
- Requer milissegundos ou segundos para resposta.

Variedade

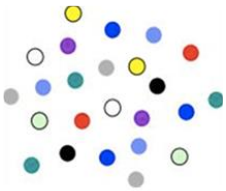

Dados em diferentes formas

- Estruturados
- Semiestruturado
- Não estruturado
  - Texto
  - Multimidia

Veracidade

Dados em dúvida

- Incerteza sobre a consistência e completude.
- Ambiguidade, latência, modelos de aproximação.

Valor

Dados em dinheiro

- Os dados devem estar associados aos modelos de negócio.
- Preocupação com a geração de retorno.

Vejam a figura apresentada acima. Ela representa uma indicação do conceito de Big Data relacionando os três V's sobre os quais tratamos até agora, adicionando duas caraterísticas: **veracidade e valor**. Contudo, existem ainda outros V's, são eles **Visibilidade**, **Variabilidade e Visualização** que complementam o conceito, detalhando um pouco mais algumas características de Big Data. Vamos apresentar a definição destes termos no quadro abaixo.

INDO MAIS FUNDO!

98276239072 - FABIANO CARBONELL DA SILVA

Veracidade. A veracidade foi um termo cunhado pela IBM, considerado o quarto V, que representa **a falta de confiabilidade inerente** em algumas fontes de dados. Por exemplo, medir os sentimentos dos clientes em mídias sociais é incerto por natureza, já que implicam uso do juízo humano. No entanto, eles contêm valiosas informações. Assim, a necessidade de lidar com dados imprecisos e incertos é outra faceta de Big Data, geralmente resolvida usando ferramentas e análises desenvolvidas para gerenciamento e mineração de dados imprecisos.

É necessário avaliar as inconsistências, incompletudes, ambiguidades, latência e possíveis modelos de aproximação utilizados. Os dados podem ainda perder a vigência. Verificar se os dados são consistentes é extremamente necessário para qualquer análise de dados.

Visibilidade. É a relevância dos dados. A organização está ciente de todos os dados que ele gera? Estes poderiam ser (aparentemente) registros de dados inconsequentes. Em outras palavras tentamos entender se todos os dados gerados estão disponíveis, e se são de fato armazenados e ficam **visíveis para os analistas de dados**.

Valor. A Oracle introduziu valor como um atributo na definição de Big Data. Com base na definição da Oracle, *Big Data* é, muitas vezes, caracterizado por uma "densidade de valor relativamente baixa". Isto é, os dados recebidos na forma original, geralmente tem um valor baixo em relação ao seu volume. Entretanto, um valor elevado pode ser obtido pela análise de grandes volumes destes mesmos dados. Assim, as informações geradas **devem produzir algum valor** para as organizações.

Variabilidade (e complexidade). A SAS apresentou variabilidade (e complexidade) como duas dimensões adicionais para Big Data. Variabilidade refere-se **à variação nas taxas de fluxo de dados**. Muitas vezes, a velocidade de Big Data não é consistente e tem picos e depressões periódicas. **Complexidade** refere-se ao fato de Big Data gerar ou receber informações através de uma multiplicidade de fontes. Isso impõe um desafio crucial: a necessidade de se conectar, integrar, limpar e transformar os dados recebidos de diferentes fontes.

Visualização. É o modo como aqueles dados complexos serão representados ou apresentados.

Big data é um termo utilizado para descrever **grandes volumes de dado**s e que ganha cada vez mais relevância à medida que a sociedade se depara com um aumento sem precedentes no número de informações geradas. As dificuldades em armazenar, analisar e utilizar grandes conjuntos de dados têm sido um considerável gargalo para as organizações. Vamos fazer mais uma questão recente sobre esses conceitos:

98276239072 - FABIANO CARBONELL DA SILVA

Dimensões sobre os dados

A IBM cita atualmente 7 dimensões sobre os dados. Essas dimensões são uma outra forma de apresentar as características que vimos até o momento. As definições de velocidade, variedade, volume, valor e variedade são as mesmas neste contexto. Incluímos mais duas percepções que não foram listadas acima: **governança** e **pessoas**. Vejamos suas definições:

- **Governança** - Ao decidir implementar ou não uma plataforma de big data, uma organização pode estar olhando novas fontes e novos tipos de elementos de dados nos quais a propriedade não está definida de forma clara. Por exemplo, no caso de assistência médica, é legal acessar dados de paciente para obter insight? É correto mapear as despesas do cartão de crédito do cliente para sugerir novas compras? Regras semelhantes regem todos os segmentos de mercado. Além da questão da governança de TI, também pode ser necessário redefinir ou modificar os processos de negócios de uma organização para que ela possa adquirir, armazenar e acessar dados externos.

  Pessoas – É necessário ter pessoas com aptidões específicas para entender, analisar os requisitos e manter uma solução de Big Data. Envolve conhecimento do segmento de mercado, domínio técnico sobre as ferramentas de Big Data e conhecimentos específicos de modelagem, estatística e outros.

Essas duas dimensões, na percepção da IBM, juntamente com volume, variedade, velocidade, veracidade e valor dão viabilidade a um projeto de Big Data, podemos observar de forma organizada esses termos na figura abaixo.

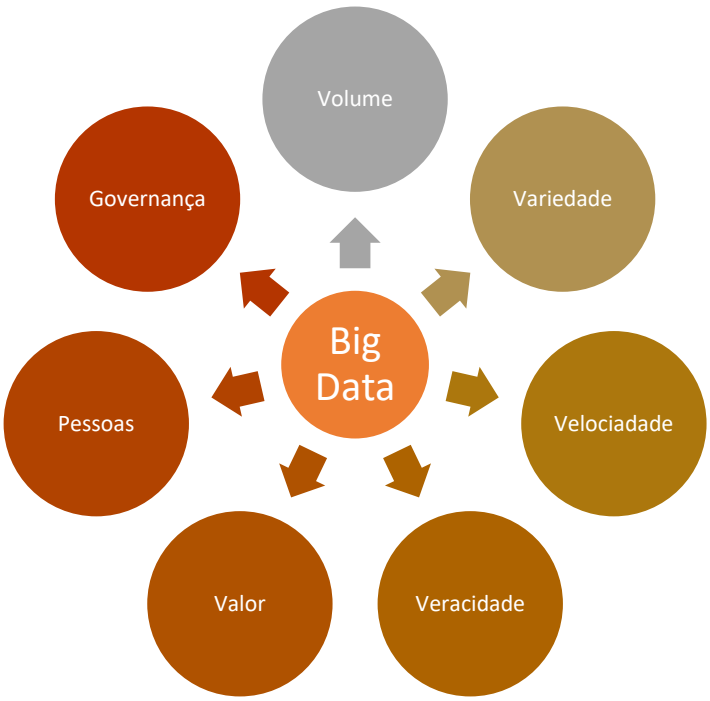

98276239072 - FABIANO CARBONELL DA SILVA

Big data trata, portanto, de grandes volumes, alta velocidade e variedade dos ativos de informação, procurando formas inovadoras e rentáveis de processamento da informação, visando uma melhor percepção dos fatos e uma tomada de decisão mais consistente.

Outra definição da ***TechAmerica*** define big data da seguinte forma:

> *"Big Data é um termo que descreve grandes volumes de dados de alta velocidade, complexos e variáveis que exigem técnicas e tecnologias avançadas para permitir a captura, armazenamento, distribuição, gestão e análise da informação".*

Antes de serguirmos em frente veja no infográfico do Jornal O Globo algumas soluções corporativas que envolvem Big Data:

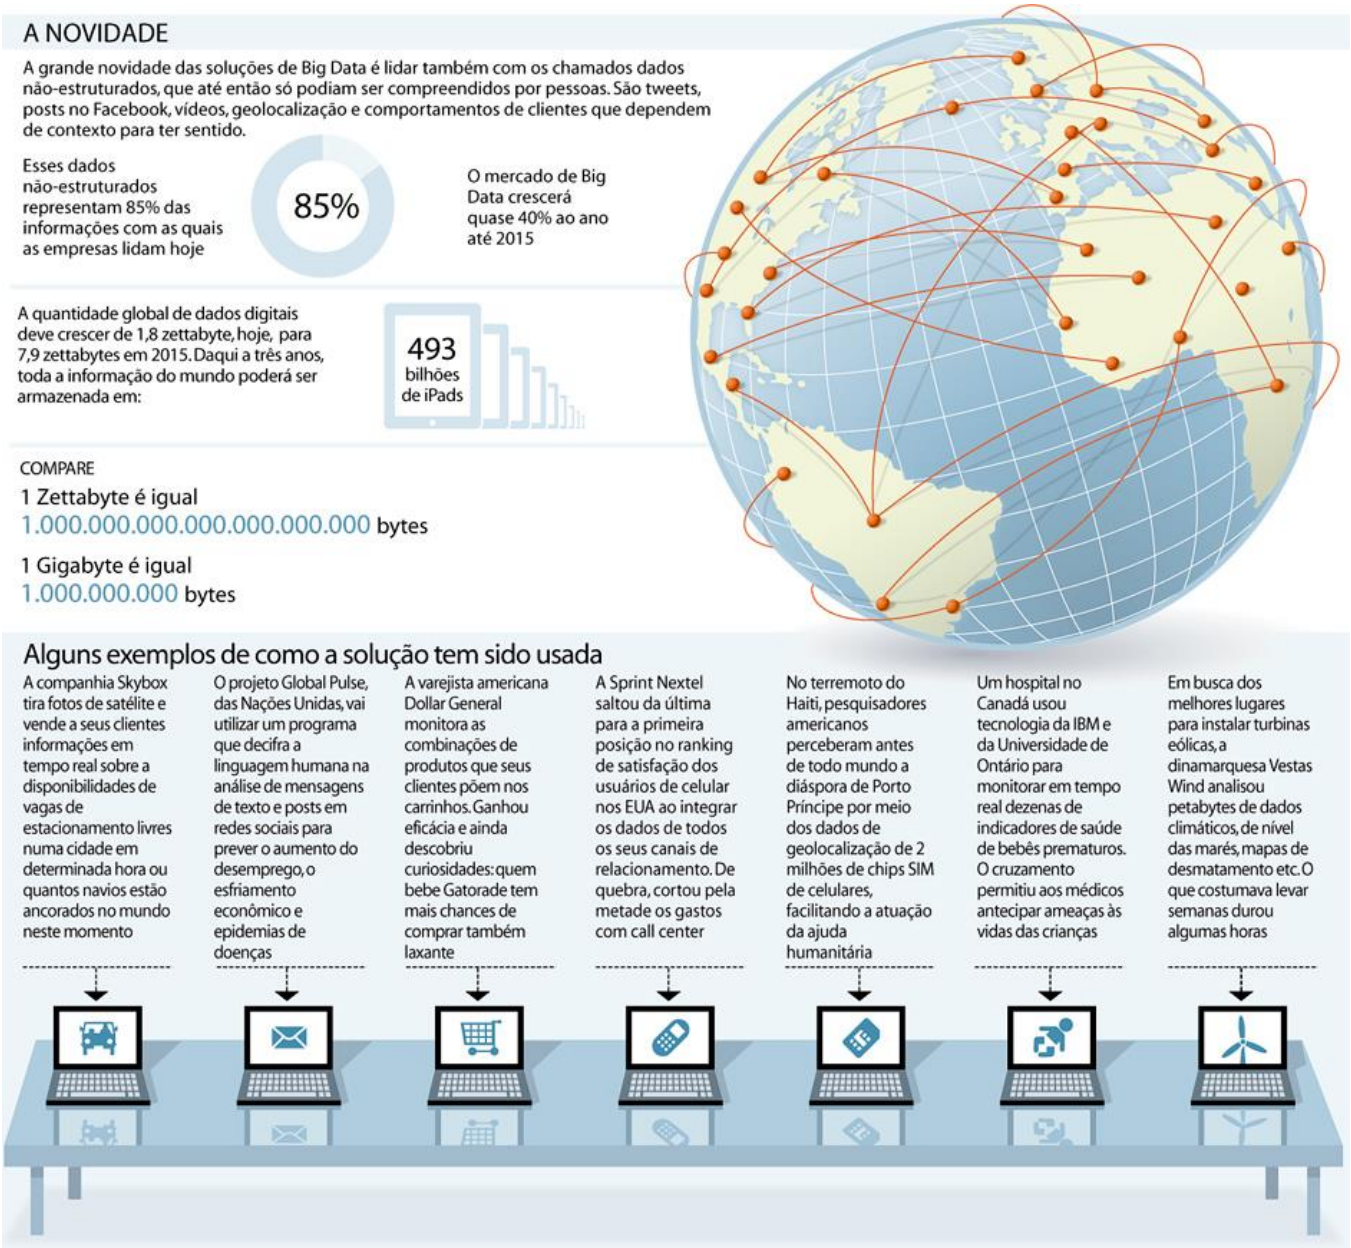

Big Data pelo mundo. Fonte: Jornal O Globo.

98276239072 - FABIANO CARBONELL DA SILVA

Entendido os conceitos básicos vamos avançar no assunto. Antes de falar sobre as premissas e aplicações, gostaria de tecer alguns comentários sobre falácias ou mitos associados a Big Data.

Falácias[2] sobre Big Data

Quando pensamos em premissas sobre Big Data imaginamos uma caixa preta que vai receber dados de um lado e entregar algo pronto do outro. Nesta linha de raciocínio, provavelmente falaciosa, antes de apresentamos as condições ideias para funcionamento dos sistemas ou projetos de Big Data, nós mostraremos os erros que muitos assumem como verdade. Chamaremos de falácias ou mitos sobre Big Data.

Falácia 01 – Big Data engloba somente dados estruturados.

Com o crescente volume de dados, o banco de dados relacional precisou ser complementado com outras estruturas de armazenamento, devido principalmente à escalabilidade e flexibilidade das novas soluções tecnológicas. Entretanto, os dados relacionais continuam sendo valiosos e são muito utilizados em soluções de Big Data. O que mudou de fato foi a inclusão de mais tipos de dados, além dos estruturados. Lembre-se do conceito de **variedade.**

Falácia 02 – Big Data refere-se somente a soluções com petabytes de dados

Embora o volume de dados seja o fator que impulsionou o fenômeno Big Data, aplicações que utilizam conjuntos de dados em uma escala menor do que petabytes também podem se beneficiar das tecnologias de Big Data. Afinal**, o mais importante nessas aplicações é a capacidade de extrair valor dos dados**.

Falácia 03 – Big data é aplicado somente às empresas do Vale do Silício (Califórnia)

Quando se fala em Big Data, é normal associarmos os termos às grandes empresas de tecnologia que prestam serviços na Web, tais como Facebook, Twitter, Netflix, Google. Embora elas tenham sido as primeiras a serem desafiadas com o grande volume, variedade e velocidade de dados, atualmente empresas de outros domínios, como agricultura, varejo e logística, também se beneficiam das tecnologias de Big Data.

Falácia 04 – Big Data é aplicado somente em grandes organizações

Ainda existe essa percepção de que Big Data oferece valor exclusivamente para grandes organizações. Entretanto, pequenas e médias empresas também podem obter vantagem competitiva por meio de soluções de Big Data, oferecendo uma melhor experiência aos seus clientes, otimizando processos, reduzindo custos ou criando novos produtos e serviços.

Falácia 05 – Big Data requer uso de dados externos

[2] O termo falácia deriva do verbo latino *fallere*, que significa enganar. Designa-se por falácia um raciocínio errado com aparência de verdadeiro. Na lógica e na retórica, uma falácia é um argumento logicamente inconsistente, sem fundamento, inválido ou falho na tentativa de provar eficazmente o que alega.

98276239072 - FABIANO CARBONELL DA SILVA

Embora a adoção de dados de diferentes fontes seja uma prática muito adotada em soluções de Big Data, a aquisição de dados externos é um requisito obrigatório. Na verdade, a sugestão para quem inicia um projeto de Big data é buscar extrair valor primeiramente dos dados internos para somente depois ampliar suas jornadas a dados de terceiros.

Falácia 06 - Big Data pode prever o futuro

Big data e todas as suas ferramentas de análise, comentários, experiências científicas e visualizações não podem dizer o que vai acontecer no futuro. Por quê? Os dados que você coletar vem inteiramente do passado. Temos ainda de atingir um grau de evolução em que será possível coletar dados e os valores do futuro. Sendo assim, nós podemos analisar o que aconteceu no passado e tentar desenhar **as tendências** entre as ações e os pontos de decisão, e as suas consequências, baseadas nos dados. Podemos usar isso para **adivinhar** que, em **circunstâncias semelhantes**, se uma decisão semelhante for tomada, resultados semelhantes ocorreriam como resultado. Mas **não podemos prever o futuro**.

Falácia 07 - Big Data pode substituir seus valores ou os da sua organização

Big Data é pobre para substituir valores ou aqueles costumes e padrões pelos quais você vive sua vida e sua empresa se esforça para operar. Suas escolhas sobre essas questões podem ser bem cristalinas, e pode ser mais fácil e claro resolver as vantagens e desvantagens de diferentes cursos da ação, mas os dados em si não podem ajudá-lo a interpretar como as decisões certas se comparam com os padrões que você definiu para si e para a sua empresa.

Os dados podem descrever todos os tipos de cenários, tanto os próprios números quanto com a ajuda de software de visualização. Sua equipe pode criar muitas projeções de cenários sobre um determinado assunto, mas esses resultados são simplesmente isso - uma projeção. O trabalho de um executivo, como um CIO, é utilizar as ferramentas e pessoal disponível dentro de seu negócio, e realmente **reconciliar os dados contra os valores** da sua empresa.

Falácia 08 - Big Data pode resolver problemas não quantificáveis

Eis o velho ditado: Quando você só tem um martelo, tudo parece um prego. Uma vez que você começa a ter algum sucesso usando big data para prever e resolver problemas de negócios, haverá inevitavelmente uma tentação para "perguntar aos dados" toda vez que você tiver um problema ou um item sobre o qual a resolução não está clara.

Como mencionado anteriormente, os dados podem apresentar mais e melhores opções e, talvez, deixar claro o que pode acontecer com cada uma dessas escolhas. Às vezes, porém, os dados não são bons e isso ocorre quando ele é usado de forma individual.

Por quê? É quase impossível de quantificar o comportamento de um indivíduo. As pessoas têm seus próprios conjuntos de circunstâncias, os seus próprios universos, suas próprias razões e contextos. É impossível aplicar a matemática para um único indivíduo. Em vez disso, você tem que olhar para um grupo de indivíduos, de preferência um subgrupo com características semelhantes. Só então você pode observar as tendências de comportamento que se aplicam a todo o grupo.

98276239072 - FABIANO CARBONELL DA SILVA

Agora que sabemos o que pode e o que **não** pode ser feito com Big Data, vamos entender quais as premissas que devem ser verificadas quando decidimos pela implementação de um projeto de Big Data. Primeiro precisamos considerar os elementos fundamentais para o crescimento de Big Data tais como o aumento da **capacidade de armazenamento**, aumento do **poder de processamento** e **disponibilidade de dados**.

Aplicações de Big Data

As aplicações de *Big Data* e análise de dados são as mais variadas. Uma lista retirada do livro do Aguinaldo Aragon nos traz as seguintes opções de uso: desenvolvimento de mercado, inovação, desenvolvimento de produtos e serviço, eficiência operacional, previsões de demanda de mercado, detecção de fraudes, gerenciamento de riscos, previsão de concorrência, vendas, campanhas de marketing, avaliação de desempenho de funcionários, alocação de orçamento anual, estabelecimento de previsões financeiras, gestão de planos de saúde, identificação de potenciais compradores e entendimento da base de cliente. Essa lista extensa nos mostra apenas parte das oportunidades geradas pela utilização de *Big Data*.

O uso de *Big Data* por empresas como **Amazon** e **Netflix** tem demostrado como a mineração de dados pode gerar resultados surpreendentes. A partir destes dados, é possível conhecer melhor as escolhas dos usuários. Implementações dos conceitos de Big Data permitem, hoje, possibilidades quase infinitas, utilizando, por exemplo, mineração de dados conseguimos verdadeiros insights sobre os dados.

Um exemplo disso foi a pesquisa feita pela Consultoria MGI. Ela estudou dados em cinco grandes domínios - saúde nos Estados Unidos, o setor público na Europa, varejo nos Estados Unidos, dados de produção e dados de localização de pessoas em nível mundial. Big Data poderia gerar valor em cada um deles. Por exemplo, um varejista pode utilizar do conceito para aumentar sua margem operacional em mais de 60%.

O aproveitamento de **Big Data no setor público tem um potencial enorme** também. Se o programa de saúde dos Estados Unidos fosse usar big data de forma criativa e eficaz poderia impulsionar a eficiência e qualidade, o setor poderia criar mais de US$ 300 bilhões em valor a cada ano. Dois terços dos quais seriam sob a forma de **redução nas despesas** de saúde dos EUA em cerca de 8 por cento. Nas economias desenvolvidas da Europa, os administradores do governo poderiam economizar mais de € 100 bilhões em melhorias de eficiência operacional usando big data, não incluindo o uso para reduzir a fraude e erros ou aumentar a cobrança das receitas fiscais.

A quantidade de dados em nosso mundo está explodindo, e a análise de grandes conjuntos de dados - os chamados big data - se tornará uma base essencial na concorrência pelo mercado ou na prestação de um serviço público de qualidade, apoiando novas ondas de crescimento na produtividade, inovação e expectativa dos consumidores. Líderes em todos os setores terão de lidar com as implicações de Big Data, não apenas os gestores orientados a dados, ou cientistas de dados.

O crescente volume e detalhamento das informações capturadas por empresas, o aumento de dados multimídia, mídia social, e a Internet das Coisas vão alimentar o crescimento exponencial dos dados no futuro.

A minha experiência pessoal no estudo de Big Data é que quando começamos a ler sobre o assunto esses conceitos teóricos vistos até aqui são apresentados de forma semelhante em vários artigos disponíveis na internet e em livros especializados, mas aí você deve estar fazendo a seguinte pergunta: E como eu implemento esse trem? (Homenagem aos meus amigos mineiros). E alguém vai te responder: usa uma base **NoSQL** com

98276239072 - FABIANO CARBONELL DA SILVA

a infraestrutura do **Hadoop**! Se você observar esses tópicos estão presentes nesta aula ... tenha um pouco de paciência que chegaremos neles.

Classificação de Big Data

É possível categorizar problemas de negócios em **tipos** de problemas de big data. Quando problemas de big data são categorizados por tipo, é mais fácil ver as características de cada tipo de dados. Essas características ajudam a entender como os dados são obtidos, como são processados para o formato apropriado e com que frequência novos dados estão disponíveis.

Dados de diferentes fontes possuem características diferentes; por exemplo, dados de mídia social podem ter vídeos, imagens e texto não estruturado, como postagens de blog, entrando continuamente.

Quer conferir alguns exemplos? A tabela a seguir contém problemas comuns de negócios e atribui um tipo de big data a cada um.

ESQUEMATIZANDO

Problemas de negócios	Tipo de big data	Descrição
Serviços públicos: Prever o consumo de energia	Dados gerados por máquina	Concessionárias de serviços públicos implementaram medidores inteligentes para medir o consumo de água, gás e eletricidade a intervalos regulares de uma hora ou menos. Esses medidores inteligentes geram enormes volumes de dados de intervalo que precisam ser analisados. Para ter eficiência operacional, a empresa precisa monitorar os dados entregues pelo sensor. Uma solução de big data pode analisar dados de geração de energia (fornecimento) e de consumo de energia (demanda) usando medidores inteligentes.
Telecomunicações: Analítica de perda de clientes	Dados da web e sociais Dados de transação (operacionais)	Operadores de telecomunicações precisam criar modelos detalhados de perda de clientes que incluam dados de mídias sociais e de transação, para estar à frente da concorrência. Provedores que implementam uma estratégia de analítica preditiva podem gerenciar e prever a perda analisando os padrões de chamada dos assinantes.
Varejo: Sistema de mensagens personalizado com base	Dados da web e sociais	Varejistas podem usar tecnologia de reconhecimento facial combinada a uma foto da mídia social para

98276239072 - FABIANO CARBONELL DA SILVA

em reconhecimento facial e mídia social	Biométrica	fazer ofertas personalizadas a clientes com base no comportamento de compra e na localização. Esse recurso pode ter um impacto tremendo nos programas de fidelização dos varejistas, mas há sérias considerações sobre a privacidade. Os varejistas precisariam ser transparentes com relação à privacidade para implementar esses aplicativos.

Problemas de negócios de big data por tipo. Fonte: ***http://www.ibm.com/developerworks/br/library/bd-archpatterns1/***

A figura a seguir mostrará as várias categorias ou taxonimias que podemos usar para classificar Big Data, e as possíveis divisões ou grupos em cada categoria. As categorias mais relevantes estão em azul turquesa.

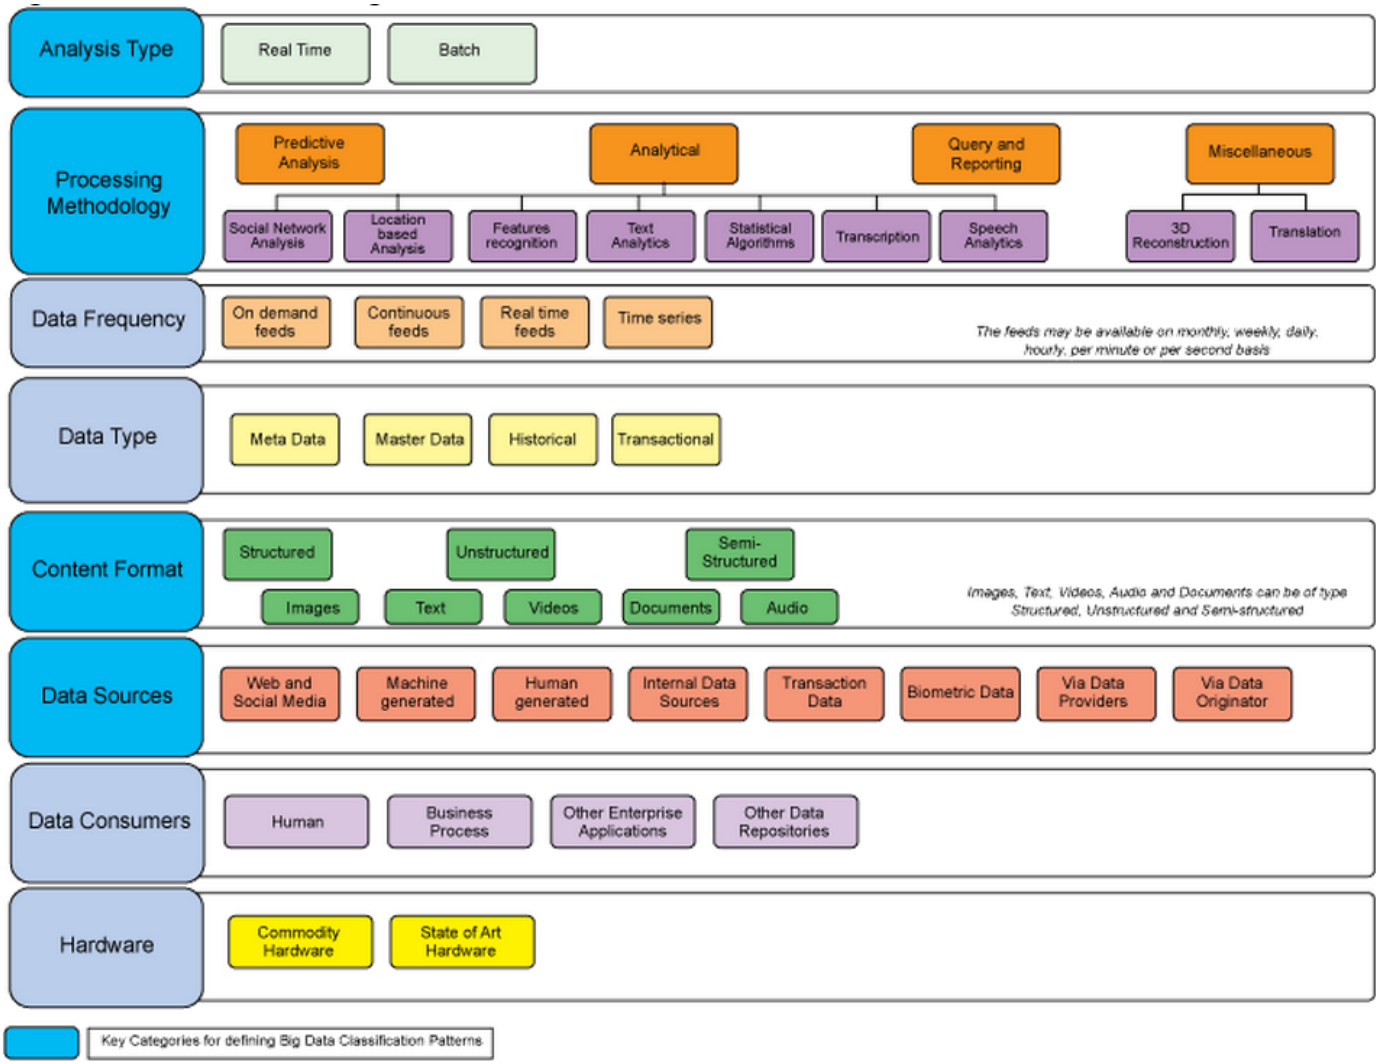

Falando um pouco mais sobre as classificações:

98276239072 - FABIANO CARBONELL DA SILVA

Tipo de análise — Se os dados são analisados em **tempo real** ou agrupados para análise posterior. Essa escolha afeta várias outras decisões sobre produtos, ferramentas, hardware, fontes de dados e a frequência estimada dos dados. Para alguns casos de uso é necessária uma mistura dos dois tipos.

Metodologia de processamento — O tipo de técnica a ser aplicada para processar dados (por exemplo, preditiva, analítica, consulta ad hoc e relatórios). As necessidades de negócios determinam a metodologia de processamento apropriada. É possível usar uma combinação de técnicas. A escolha de metodologia de processamento ajuda a identificar as ferramentas e técnicas apropriadas para uso na solução de big data.

Frequência e tamanho dos dados — O volume estimado de dados e a frequência com que chegam. Saber a frequência e o tamanho ajuda a determinar o mecanismo de armazenamento, formato de armazenamento e as ferramentas necessárias de pré-processamento. Frequência e tamanho de dados dependem das fontes.

- Sob demanda, como dados de mídia social
- Feed contínuo, em tempo real (dados de clima ou transacionais)
- Série temporal (dados com base em tempo)

Tipo de dados — Tipo dos dados a serem processados — transacionais, históricos, principais e outros. Saber o tipo de dados ajuda a segregar os dados no armazenamento.

Formato de conteúdo — Formato dos dados recebidos — estruturados (SGBDR, por exemplo), não estruturados (áudio, vídeo e imagens, por exemplo) ou semiestruturados. O formato determina como os dados recebidos precisam ser processados e é essencial para escolher ferramentas e técnicas e definir uma solução de uma perspectiva de negócios.

Fonte de dados— Fontes de dados (onde os dados são gerados) — web e mídia social, gerados por máquina, gerados por humanos, etc. Identificar todas as fontes de dados ajuda a determinar o escopo de uma perspectiva de negócios.

Consumidores de dados — Uma lista de todos os possíveis consumidores dos dados processados:

- Processos de negócios
- Usuários corporativos
- Aplicativos corporativos
- Pessoas individuais em várias funções de negócios
- Parte dos fluxos do processo
- Outros repositórios de dados ou aplicativos corporativos

Hardware — O tipo de hardware no qual a solução de big data será implementada — hardware barato ou de ponta. Entender as limitações do hardware ajuda na escolha da solução big data.

98276239072 - FABIANO CARBONELL DA SILVA

Padrões atômicos e compostos de uma solução de Big Data

Os padrões auxiliam a definir os parâmetros, quando da adoção de uma solução de big data. Veremos dois tipos principais: os padrões **atômicos** descrevem as abordagens típicas para o consumo, processamento, acesso e armazenamento de big data; os padrões **compostos**, que são formados por padrões atômicos, são classificados de acordo com o escopo da solução de big data.

Por apresentarem as ideias mais relevantes acerca do Big Data, exploraremos os padrões atômicos.

PADRÕES ATÔMICOS

Os **padrões atômicos** ajudam a identificar a forma que os dados são consumidos, processados, armazenados e acessados por problemas de big data. Eles também podem ajudar a identificar os componentes necessários.

Cada padrão lida com requisitos específicos — visualização, análise de dados históricos, dados de mídia social e armazenamento de dados não estruturados, por exemplo. Os padrões atômicos podem trabalhar em conjunto para criar um padrão composto. Não há camadas ou sequência para esses padrões atômicos. Por exemplo, os padrões de visualização podem interagir com os padrões de acesso a dados para mídia social diretamente e os padrões de visualização podem interagir com o padrão de processamento de análise avançada.

98276239072 - FABIANO CARBONELL DA SILVA

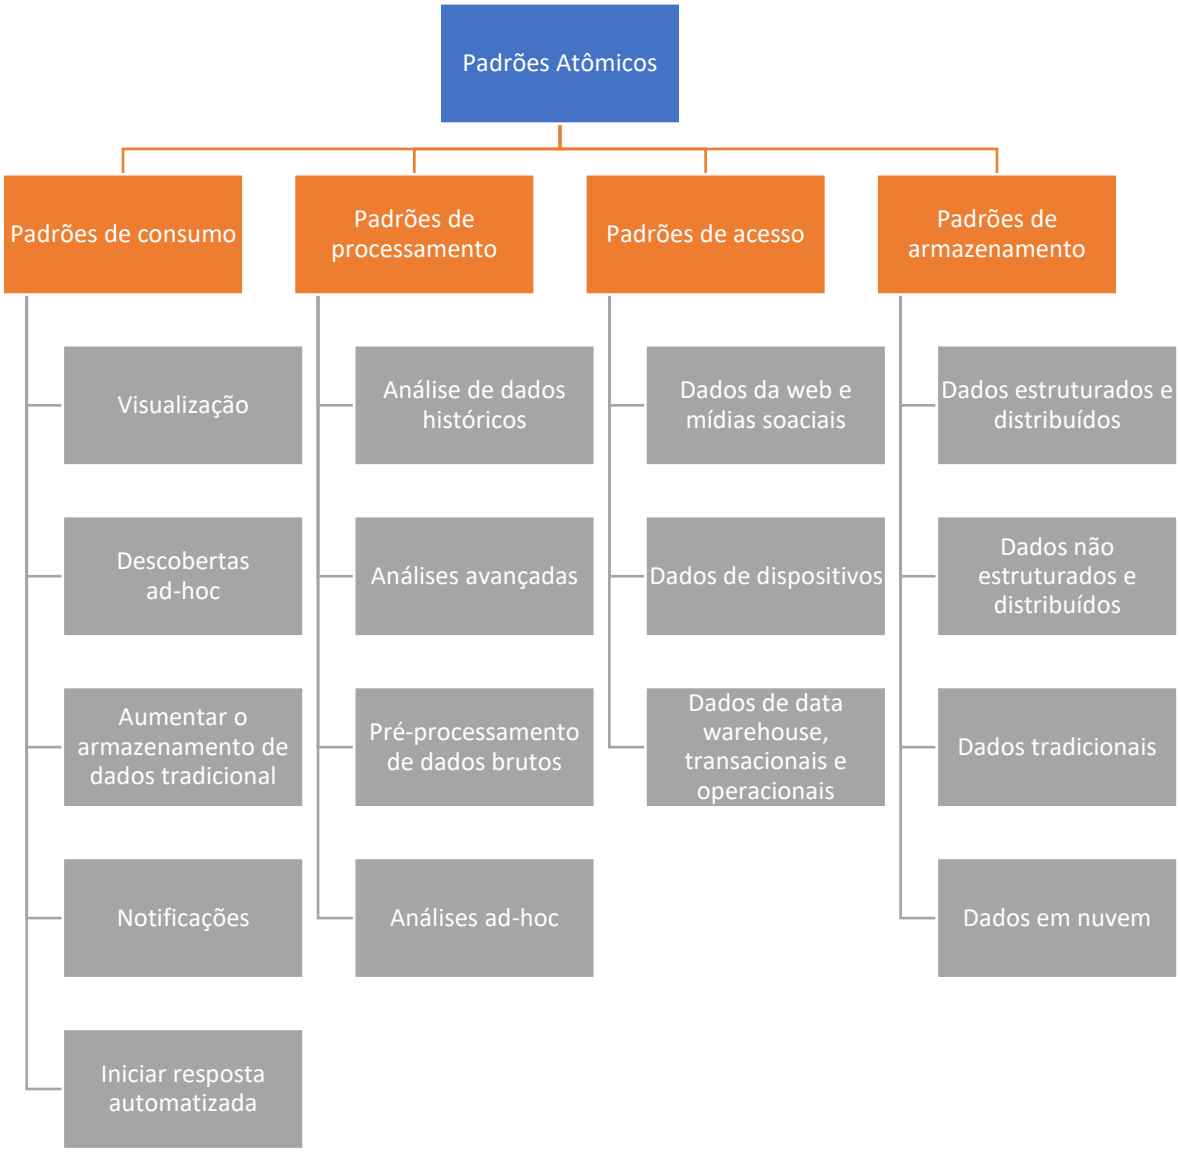

Padrões atômicos de Big Data. Fonte: http://www.ibm.com/developerworks/br/library/bd-archpatterns4/

Vejamos um pouco de cada padrão atômico:

PADRÕES DE CONSUMO

Lidam com as várias formas em que o resultado da análise de dados é consumido. Inclui padrões de consumo de dados para atender a diversos requisitos. Vejamos os principais padrões de consumo a seguir:

Visualização

A forma tradicional de visualizar dados se baseia em gráficos, painéis e relatórios de resumo. Essas abordagens tradicionais não são sempre a melhor maneira de visualizar os dados.

Os requisitos típicos para visualização de big data, incluindo os requisitos emergentes, são listados abaixo:

- Realizar análise em tempo real e exibição de dados de fluxo
- Extrair dados de forma interativa, com base no contexto
- Executar procuras avançadas e obter recomendações
- Visualizar informações paralelamente
- Ter acesso a hardware avançado para necessidades de visualização futuristas

A pesquisa para determinar como os insights de big data podem ser consumidos por humanos e máquinas está em andamento. Os desafios incluem o volume de dados envolvido e a necessidade de associar contexto a eles. O insight dever apresentado no contexto adequado.

Descoberta ad hoc

Criar de relatórios padrão que sejam adequados para todas as necessidades de negócios, via de regra, não é viável, pois as empresas têm requisitos de consultas de dados de negócios diversas. Os usuários precisam da capacidade de enviar consultas *ad hoc*, ou seja, consultas criadas "na hora", ao procurar por informações especificas, dependendo do problema.

Aumentar os armazenamentos de dados tradicionais

Aumentar os armazenamentos de dados existentes ajuda a ampliar o escopo de dados disponível para a analítica atual para incluir dados que residem dentro e fora dos limites organizacionais, como dados de mídia social, que podem melhorar os dados principais. Ao ampliar o escopo para incluir novas tabelas de fatos, dimensões e dados principais nos armazenamentos existentes e adquirir dados de clientes a partir de mídia social, uma organização pode obter um insight mais profundo do cliente.

Notificação

Os insights de big data permitem que as pessoas, negócios e máquinas ajam instantaneamente usando notificações para indicar eventos. A plataforma de notificação deve ser capaz de lidar com o volume antecipado de notificações a serem enviadas de maneira oportuna. Essas notificações são diferentes das malas diretas ou do envio em massa de mensagens SMS, pois o conteúdo geralmente é específico para o consumidor. Por exemplo, os mecanismos de recomendação podem fornecer insights sobre a enorme base de clientes em todo o mundo, e as notificações podem ser envidas para tais clientes.

Iniciar uma resposta automatizada

Os insights de negócios derivados do big data podem ser usados para acionar ou iniciar outros processos de negócios ou transações.

PADRÕES DE PROCESSAMENTO

O big data pode ser processado quando os dados estão em repouso ou em movimento. Dependendo da complexidade da análise, os dados podem não ser processados em tempo real. Esse padrão lida com como o

98276239072 - FABIANO CARBONELL DA SILVA

big data é processado em tempo real, quase em tempo real ou em lote (rotinas *batch*, processadas em horários pré-determinados).

Vejamos um pouco mais sobre esses padrões a seguir:

Análise de dados históricos

A análise de dados históricos tradicional é limitada a um período predefinido de dados, que normalmente depende das políticas de retenção de dados. Após desse período, geralmente os dados são arquivados ou limpos em virtude de limitações de armazenamento e processamento.

A análise histórica envolve analisar as tendências históricas para um determinado período, conjunto de períodos e produtos e compará-las aos dados atuais disponíveis.

Analítica Avançada

O big data fornece enormes oportunidades de obter insights criativos. É possível correlacionar diferentes conjuntos de dados em muitos contextos. A descoberta desses relacionamentos requer técnicas e algoritmos complexos inovadores.

A análise avançada inclui previsões, decisões, processos inferenciais, simulações, identificações de informações contextuais e resoluções da entidade. Os aplicativos de analítica avançada incluem análise de dados biométricos, por exemplo, análise de DNA, análise espacial, analítica baseada em localização, análise científica, pesquisa e muitas outras. A analítica avançada requer a computação exigente para gerenciar a enorme quantidade de dados.

Pré-processar dados brutos

A extração de dados a partir de dados não estruturados, como imagens, áudio, vídeo, feeds binários ou até mesmo texto, é uma tarefa complexa e precisa de técnicas como aprendizado de máquina e processamento de idioma natural, etc. O outro grande desafio é como verificar a precisão e a exatidão do resultado de tais técnicas e algoritmos.

Para executar a análise em quaisquer dados, eles devem estar em algum tipo de formato estruturado. Os dados não estruturados acessados de várias fontes podem ser armazenados como estão e, em seguida, transformados em dados estruturados e novamente armazenados nos sistemas de armazenamento de big data. O texto não estruturado pode ser convertido em dados estruturados ou semiestruturados. Da mesma forma, os dados de imagem, áudio e vídeo precisam ser convertidos nos formatos que podem ser usados para análise. Além disso, a precisão e exatidão da analítica avançada que usa algoritmos preditivos e estatísticos dependem da quantidade de dados e algoritmos usados para treinar os modelos.

Análise ad hoc

O processamento de consultas ad hoc no big data traz desafios diferentes daqueles incorridos ao realizar consultas ad hoc em dados estruturados pelo fato de as fontes e formatos dos dados não serem fixos e exigirem mecanismos diferentes para recuperá-los e processá-los.

98276239072 - FABIANO CARBONELL DA SILVA

Embora as consultas ad hoc simples possam ser resolvidas pelos provedores de big data, na maioria dos casos, elas são complexas porque os dados, algoritmos, formatos e resoluções da entidade devem ser descobertos dinamicamente. O conhecimento dos cientistas de dados e dos usuários corporativos é necessário para definir a análise exigida para as seguintes tarefas:

- Identificar e descobrir os cálculos e algoritmos
- Identificar e descobrir as fontes de dados
- Definir os formatos necessários que podem ser consumidos pelos cálculos
- Executar os cálculos nos dados paralelamente

PADRÕES DE ACESSO

Existem muitas fontes de dados e formas em que os dados podem ser acessados em uma solução de big data, vejamos as mais comuns:

Web e mídias sociais

A Internet é a fonte de dados que fornece muitos dos insights produzidos atualmente. A web e a mídia social são úteis em praticamente todas as análises, mas são necessários mecanismos de acesso diferentes para obter esses dados.

A web e a mídia social são a fonte de dados mais complexa de todas em virtude de sua enorme variedade, velocidade e volume. Há aproximadamente de 40 a 50 categorias de websites e cada uma exigirá um tratamento diferente para acessar esses dados.

(gerados por) Dispositivos

O conteúdo gerado por dispositivos inclui dados de sensores. Os dados são detectados a partir das origens de dados, como informações sobre o clima, medições elétricas e dados sobre poluição, e capturados pelos sensores. Os dados podem ser fotos, vídeos, texto e outros formatos binários.

Dados transacionais, operacionais e de Warehouse

É possível armazenar os dados operacionais e transacionais em warehouse existentes para evitar a limpeza ou o arquivamento deles (em virtude de limitações de armazenamento e processamento) ou para reduzir a carga no armazenamento tradicional quando os dados são acessados por outros consumidores.

Os dados transacionais podem ser inseridos no armazenamento de warehouse usando conectores padrão disponibilizados por diversos fornecedores de banco de dados. O pré-processamento de dados transacionais é muito mais fácil, pois a maior parte deles é estruturada. Os processos de extração, transformação e carregamento simples podem ser usados para mover os dados transacionais para o armazenamento em um *data warehouse*.

PADRÕES DE ARMAZENAMENTO

98276239072 - FABIANO CARBONELL DA SILVA

Os padrões de armazenamento auxiliam a determinar o armazenamento adequado para diversos formatos e tipos de dados. Os dados podem ser armazenados como estão, com relação a pares de valores de chave ou em formatos predefinidos. Vejamos os principais padrões:

Dados não estruturados e distribuídos

A maior parte do big data não é estruturada, já sabemos, e pode conter informações que podem ser extraídas de diferentes formas para diferentes contextos. Na maioria das vezes, os dados não estruturados devem ser armazenados como estão, em seu formato original.

Tais dados podem ser armazenados em sistemas de arquivos distribuídos, como **HDFS (Hadoop Distributed File System)**, e em armazenamento de documentos **NoSQL** (**Not Only SQL**), como o **MongoDB**. Esses sistemas fornecem uma maneira eficiente de recuperar dados não estruturados.

Dados estruturados e distribuídos

Os dados estruturados incluem aqueles que chegam da fonte de dados e já estão em um formato estruturado e os dados não estruturados que foram pré-processados. Esses dados convertidos devem ser armazenados para evitar a frequente conversão de dados brutos para dados estruturados.

Tecnologias como **BigTable** do Google são usadas para armazenar dados estruturados. O BigTable é um sistema de autogerenciamento tolerante a falhas de grande escala que inclui terabytes de memória e petabytes de armazenamento.

Armazenamento de dados tradicionais

O armazenamento de dados tradicional não é a melhor opção para armazenar big data, mas nos casos em que as empresas estão realizando a exploração de dados inicial, elas podem optar por usar o data warehouse, o sistema **RDBMS** (sistemas relacionais) e outros armazenamentos de conteúdo existentes. Esses sistemas de armazenamento existentes podem ser usados para armazenar os dados que são compilados e filtrados usando a plataforma de big data. ***Os sistemas de armazenamento de dados tradicionais não são adequados para o big data***.

Armazenamento na nuvem

Muitos provedores de infraestrutura da nuvem possuem recursos de armazenamento estruturado e não estruturado distribuídos. As tecnologias de big data são um pouco diferentes das perspectivas de configurações, manutenção, gerenciamento de sistemas e programação e modelagem tradicionais. Além disso, as qualificações necessárias para implementar as soluções de big data são raras e caras. As empresas explorando as tecnologias de big data podem usar soluções de nuvem que fornecem o gerenciamento de sistemas, manutenção e armazenamento de big data.

Contudo, não-raro, os dados a serem armazenados são confidenciais, incluindo dados biométricos e registros médicos. ***A segurança de dados, o compartilhamento de dados, a governança de dados e outras políticas relacionadas aos dados, são aspectos a serem considerados ao ponderar a nuvem como um repositório de***

98276239072 - FABIANO CARBONELL DA SILVA

armazenamento para big data. A capacidade de transferir enormes quantidades de dados também é outra consideração fundamental para o armazenamento em nuvem.

APOSTA ESTRATÉGICA

A ideia desta seção é apresentar os pontos do conteúdo que mais possuem chances de serem cobrados em prova, considerando o histórico de questões da banca em provas de nível semelhante à nossa, bem como as inovações no conteúdo, na legislação e nos entendimentos doutrinários e jurisprudenciais[3].

Conceitos de Big Data

[3] Vale deixar claro que nem sempre será possível realizar uma aposta estratégica para um determinado assunto, considerando que às vezes não é viável identificar os pontos mais prováveis de serem cobrados a partir de critérios objetivos ou minimamente razoáveis.

98276239072 - FABIANO CARBONELL DA SILVA

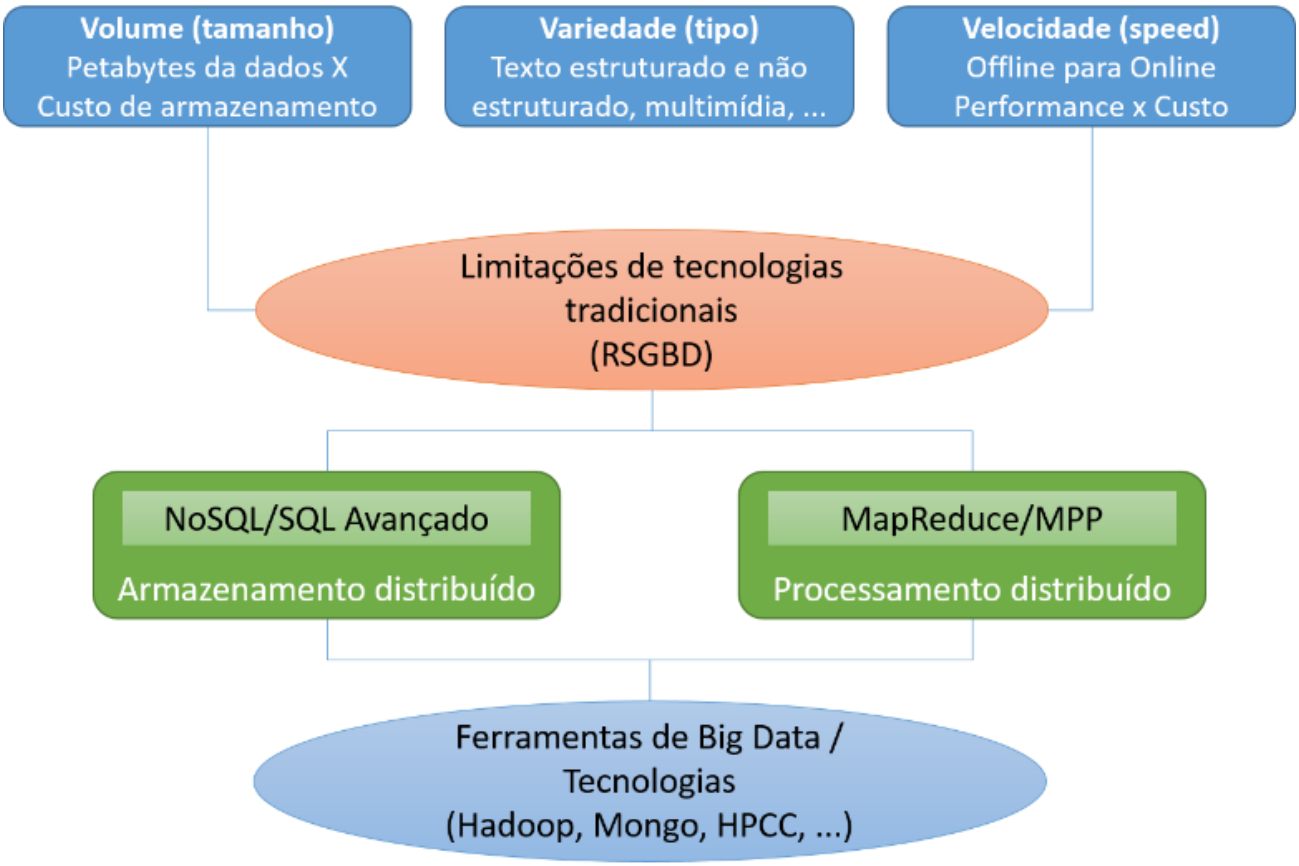

Conceitos importantes

Você deve ter noção de cada um dos conceitos abaixo:

5 Vs:

- **Velocidade:** A velocidade se refere à grande agilidade com que os dados são produzidos.
- **Variedade**: define a grande diversidade de informações e que podem ser úteis para a geração de valor.
- **Volume:** diz respeito às grandes quantidades de informação.
- **Valor**: trata do retorno direto ou indireto da análise dos dados.
- **Veracidade**: a necessidade que temos de garantir que os dados coletados sejam autênticos (com relação à fonte da informação) e que são verdadeiros naquele momento.

Escalabilidade horizontal - na medida em que o volume de dados cresce, aumenta-se a necessidade de escalabilidade e melhoria do desempenho. Dentre todas as possibilidades para esta solução, a escalabilidade horizontal se torna a mais viável adicionando recursos ao ambiente operacional. Veja a figura abaixo:

98276239072 - FABIANO CARBONELL DA SILVA

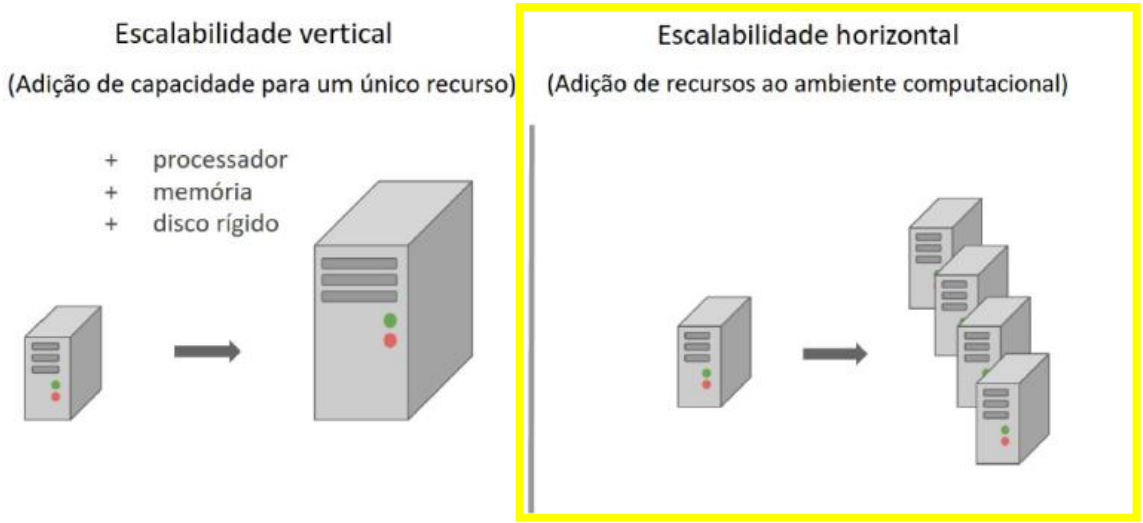

Persistência poliglota – A capacidade de usar diferentes bases de dados para armazenar dados de diferentes tipos visando otimizar o armazenamento e a recuperação dos mesmos.
Teorema CAP - Consistência, Disponibilidade, Tolerância à Partição - Este teorema diz que, é impossível para um sistema computacional distribuído, oferecer simultaneamente, consistência, disponibilidade e tolerância a falhas. O acrônimo vem de Consistency, Availability, and Partition tolerance

Bases de dados NoSQL (Not Only SQL) - Bancos de Dados não relacionais, que oferecem um modelo diferenciado do tradicional modelo Relacional:

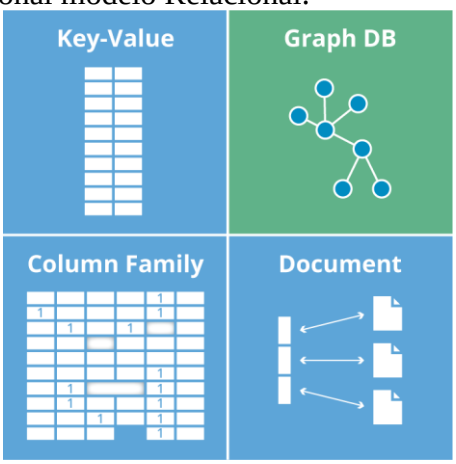

Hadoop - Projeto da fundação Apache voltada ao processamento de grandes volumes de dados

- **Map Reduce** - Modelo que consiste em operações de mapeamento e redução, utilizada para processar grandes volumes de dados em um sistema de computação distribuído.
- **HDFS** - Acrônimo para Hadoop Distributed File System. O HDFS é um sistema de arquivos distribuídos mantidos pela função Apache sobre qual o Hadoop está estruturado

Imprima o capítulo Aposta Estratégica separadamente e dedique um tempo para absolver tudo o que está destacado nessas duas páginas. Caso tenha alguma dúvida, volte ao Roteiro de Revisão e Pontos do Assunto que Merecem Destaque. Se ainda assim restar alguma dúvida, não hesite em me perguntar no fórum.

98276239072 - FABIANO CARBONELL DA SILVA

QUESTÕES ESTRATÉGICAS

Nesta seção, apresentamos e comentamos uma amostra de questões objetivas selecionadas estrategicamente: são questões com nível de dificuldade semelhante ao que você deve esperar para a sua prova e que, em conjunto, abordam os principais pontos do assunto.

A ideia, aqui, não é que você fixe o conteúdo por meio de uma bateria extensa de questões, mas que você faça uma boa revisão global do assunto a partir de, relativamente, poucas questões.

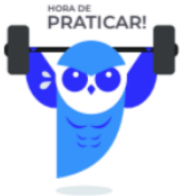

1. CEBRASPE (CESPE) - Analista de Tecnologia da Informação (TCE-RO)/Desenvolvimento de Sistemas/2019 (e mais 5 concursos)

Com relação a fundamentos e conceitos de Big Data, julgue os itens a seguir.

I O volume de dados é uma característica importante de Big Data.

II Em Big Data, a qualidade do dado não tem importância, porque a transformação dos dados não impacta os negócios.

III A característica de velocidade de entrada dos dados impacta o modelo de processamento e armazenamento.

IV A variedade dos dados não é característica intrínseca nos fundamentos de Big Data.

Estão certos apenas os itens

a) I e II.

b) I e III.

c) II e IV.

d) I, III e IV.

e) II, III e IV.

Comentário:

O termo Big Data faz referência a um grande volume de dados. Nos dias atuais, as entidades são bombardeadas com um enorme fluxo de informações cruciais para suas atividades. Esses dados podem vir de fontes diferentes e podem ser de tipos diversos (estruturados, semiestruturados ou não estruturados).

Inicialmente, o Big Data tinha como característica os 3V's:

98276239072 - FABIANO CARBONELL DA SILVA

Volume: existência de uma quantidade massiva de dados;

Velocidade: rapidez no acesso aos dados; e

Variedade: grande variedade dos tipos de dados, provenientes de diferentes fontes.

Hoje em dia se fala nos 5 V's, pois foram incluídas mais duas características:

Veracidade: importante que as informações sejam verdadeiras; e

Valor: as informações devem ser capazes de agregar valor ao negócio em questão.

Analisando as alternativas, temos:

I O volume de dados é uma característica importante de Big Data.

CORRETA. Uma das características marcantes do Big Data é que não se trata de um pequeno conjunto de dados, mas sim de uma quantidade massiva (por isso o termo big, do inglês "grande").

II Em Big Data, a qualidade do dado não tem importância, porque a transformação dos dados não impacta os negócios.

ERRADA. As características da variedade e do valor nos diz que a qualidade do dado é sim importante, afinal é preciso que ele seja verdadeiro e que agregue valor ao negócio.

III A característica de velocidade de entrada dos dados impacta o modelo de processamento e armazenamento.

CORRETA. A velocidade é uma das características fundamentais do big data e impacta sim o modelo. Os dados devem ser recebidos e tratados com a velocidade mais rápida possível para que as decisões estratégicas sejam efetivas.

IV A variedade dos dados não é característica intrínseca nos fundamentos de Big Data.

ERRADA. A variedade é sim uma das características do Big Data, de forma que o ideal é que os dados sejam provenientes das mais diversas fontes, a fim de sejam ricos e variados, agregando valor ao negócio.

Gabarito: alternativa B.

---

2. **CEBRASPE (CESPE) - Auditor Estadual (TCM-BA)/Controle Externo/2018 (e mais 1 concurso)**

Acerca de visualização e análise exploratória de dados, assinale a opção correta.

a) As variáveis são características que podem ser observadas ou medidas em cada elemento pesquisado, sendo classificadas em inteiras, textuais ou imagens.

b) A entrada de dados deve assumir convenções tais como: os dados devem estar no formato de matriz; cada linha da matriz deve ter pelo menos um atributo identificador; e cada coluna da matriz deve ter um nome distinto.

98276239072 - FABIANO CARBONELL DA SILVA

c) A informação de uma ou mais variáveis que não estiver disponível (por exemplo, falta de resposta, rasura etc.) deve ser marcada (ou indicada) com zero.

d) Um arquivo csv (comma separated values), no qual as colunas de um conjunto de dados são separadas por vírgula, pode ser aberto em qualquer editor de texto ou planilha eletrônica.

e) A eliminação completa (casewise deletion) consiste em eliminar os arquivos que apresentem mais de um dado perdido.

Comentário: Um arquivo csv (comma separated values), no qual as colunas de um conjunto de dados são separadas por vírgula, pode ser aberto em qualquer editor de texto ou planilha eletrônica.

Correta: Certíssimo. Um arquivo csv é um arquivo de texto (assim como um txt), mas as colunas de um conjunto de dados são separados por vírgula. Esses arquivos de texto podem ser abertos em qualquer editor de texto, e também em planilhas eletrônicas.

Portanto, alternativa correta letra D.

Gabarito: alternativa D.

---

3. **Ano: 2018 Banca: CESPE Órgão: TCM-BA Cargo: Auditor de Contas Questão: 14**

Acerca de big data, assinale a opção correta.

A A utilização de big data nas organizações não é capaz de transformar os seus processos de gestão e cultura.

B Sistemas de recomendação são métodos baseados em computação distribuída, que proveem uma interface para programação de clusters, a fim de recomendar os tipos certos de dados e processar grandes volumes de dados.

C Pode-se recorrer a software conhecidos como scrapers para coletar automaticamente e visualizar dados que se encontram disponíveis em sítios de navegabilidade ruim ou em bancos de dados difíceis de manipular.

D As ações inerentes ao processo de preparação de dados incluem detecção de anomalias, deduplicação, desambiguação de entradas e mineração de dados.

E O termo big data se baseia em cinco Vs: velocidade, virtuosidade, volume, vantagem e valor.

Comentário: Vamos comentar cada uma das alternativas acima:

A) Esse conceito de transformar processos de gestão e cultura está associado a outro conceito, o de gestão de processos de negócio, conhecido como BPM. Logo, temos uma alternativa **incorreta**.

B) Um **Sistema de Recomendação** combina várias técnicas computacionais para selecionar itens personalizados com base nos interesses dos usuários e conforme o contexto no qual estão inseridos. Tais itens podem assumir formas bem variadas como, por exemplo, livros, filmes, notícias, música, vídeos, anúncios, links patrocinados, páginas de internet, produtos de uma loja virtual, etc. Empresas como Amazon, Netflix e Google são reconhecidas pelo uso intensivo de sistemas de recomendação com

98276239072 - FABIANO CARBONELL DA SILVA

os quais obtém grande vantagem competitiva. Veja que não existe nenhuma obrigação dos sistemas serem estruturados em um cluster e usarem computação distribuída.

C) Essa é a nossa resposta, e confesso desde já que não apresentamos esse conceito em nosso material. ***Data scraping*** (do inglês, raspagem de dados) é uma técnica computacional na qual um programa extrai dados de saída legível somente para humanos, proveniente de um serviço ou aplicativo. Os dados extraídos geralmente são minerados e estruturados em um formato padrão como CSV, XML ou JSON. Vejam que o objetivo é transformar os dados não estruturados em modelos mais fáceis de manipular.

D) ***Data preparation*** é o processo de **coletar, limpar, normalizar, combinar, estruturar e organizar dados para análise**. Ele é o passo inicial (e fundamental) para que o trabalho com Big Data seja bem-sucedido, uma vez que aumenta a qualidade dos dados – e, consequentemente, dos resultados com **data mining**. Dados "pobres", de qualidade ruim, geram resultados incorretos e não-confiáveis ao fim do processo de uso das tecnologias de Data Science. Vejam que a mineração de dados é uma ação feita em uma etapa posterior a preparação dos dados. Logo, temos uma alternativa **incorreta**.

E) Observem que os v´s listados na alternativa não são os que está descrito na definição de big data, os conceitos corretos são: Volume, Velocidade, Variedade, Veracidade e Valor.

Gabarito: alternativa C.

---

4. Ano: 2018 Banca: CESPE Órgão: TCE-PB Prova: Auditor de Contas Públicas - Demais Áreas

Com referência a big data, assinale a opção correta.

a) A definição mais ampla de big data restringe o termo a duas partes — o volume absoluto e a velocidade —, o que facilita a extração das informações e dos insights de negócios.

b) O sistema de arquivos distribuído Hadoop implementa o algoritmo Dijkstra modificado para busca irrestrita de dados em árvores aglomeradas em clusters com criptografia.

c) Em big data, o sistema de arquivos HDFS é usado para armazenar arquivos muito grandes de forma distribuída, tendo como princípio o write-many, read-once.

d) Para armazenar e recuperar grande volume de dados, o big data utiliza bancos SQL nativos, que são bancos de dados que podem estar configurados em quatro tipos diferentes de armazenamentos: valor chave, colunar, gráfico ou documento.

e) O MapReduce é considerado um modelo de programação que permite o processamento de dados massivos em um algoritmo paralelo e distribuído.

Comentário: Vejamos cada uma das afirmações acima.

a) a definição mais simples de big data já estrutura o termo em 3 conceitos: volume, variedade e velocidade. Logo, temos uma alternativa incorreta.

b) Essa questão tem diversos conceitos dispersos que não fazem sentido da forma como foi apresentada no texto. Veja que o Hadoop possui de fato um sistema de armazenamento distribuído: o HDFS. O HDFS possui uma arquitetura mestre/escravo. Um cluster HDFS consiste em um único **NameNode**,

98276239072 - FABIANO CARBONELL DA SILVA

considerado o servidor mestre que gerencia o *namespace* do sistema de arquivos e regula o acesso a arquivos por clientes. Além disso, há vários **DataNodes**, geralmente um por nó do cluster, que gerenciam o armazenamento associado aos nós em que são executados. **Não existe o uso do algoritmo de Dijkstra**[4] **para busca em registros**, ele está preocupado em achar o menor caminho e um grafo.

Sobre criptografia, o HDFS implementa criptografia transparente de ponta a ponta. Depois de configurados, os dados lidos e gravados em diretórios HDFS especiais são criptografados e descriptografados de forma transparente, sem exigir alterações no código do aplicativo do usuário.

c) Em big data temos um princípio semelhante ao do data warehoure, os dados são escritos apenas uma vez, write-once e lido por diversas pessoas, read-many. Assim, a alternativa c também está errada.

d) Sabemos que os bancos de dados NoSQL não são SQL nativos, logo, não podemos marcar essa alternativa como resposta.

e) Sobrou apenas essa alternativa que apresentou uma definição consistente de MapReduce. Logo, marcamos nossa resposta nesta letra E.

Gabarito: alternativa E.

---

5. **CEBRASPE (CESPE) - Analista de Tecnologia da Informação (EBSERH)/2018**

Com relação a banco de dados, julgue o item seguinte.

As soluções de big data focalizam dados que já existem, descartam dados não estruturados e disponibilizam os dados estruturados.

Comentário: O termo dados não estruturados geralmente se refere a informações que não residem em um banco de dados de coluna/linha tradicional. Como é de se esperar, é o oposto de dados estruturados, que são os dados armazenados em campos em um banco de dados.

Arquivos de dados não estruturados geralmente incluem texto e conteúdo multimídia. Os exemplos incluem mensagens de e-mail, documentos de processamento de texto, vídeos, fotos, arquivos de áudio, apresentações, páginas da Web e muitos outros tipos de documentos comerciais.

O termo big data está intimamente associado a dados não estruturados. Big data refere-se ao conjuntos de dados extremamente grandes que são difíceis de analisar com ferramentas tradicionais. Big data pode incluir dados estruturados e não estruturados, mas a IDC (International Data Corporation - Corporação Internacional de Dados) estima que 90% do big data sejam dados não estruturados. Muitas das ferramentas projetadas para analisar big data podem manipular dados não estruturados.

Gabarito: E

---

[4] Uma aplicação de busca em um grafo comum é encontrar o caminho mais curto obtido entre um nó inicial e um ou mais nós de destino. Comumente feito em uma única máquina com o **Algoritmo de Dijkstra**.

98276239072 - FABIANO CARBONELL DA SILVA

6. **Ano: 2017 Órgão: TCE-PE Cargo: Auditor de Obras Públicas Questão: 120**

Com relação a Big Data, julgue o item subsequente.

Além de estar relacionado à grande quantidade de informações a serem analisadas, o Big Data considera o volume, velocidade e a variedade dos dados estruturados – dos quais se conhece a estrutura de armazenamento – bem como dos não estruturado, como imagens, vídeos, áudios e documentos.

Comentário: Big Data é o termo que descreve o imenso volume de dados – estruturados e não estruturados – que impactam os negócios no dia a dia. A definição da questão está perfeitamente de acordo com o conceito, citando inclusive os 3Vs da definição inicial de Doug Laney. Sendo assim, a resposta para esta alternativa está correta.

Gabarito: C

---

7. **Ano: 2017 Banca: CESPE Órgão: TCE-PE Cargo: Analista De Controle Externo Área: Auditoria De Contas Públicas Questão: 120**

No que se refere a Big Data, julgue o item subsecutivo.

120 O termo Big Data Analytics refere-se aos poderosos softwares que tratam dados estruturados e não estruturados para transformá-los em informações úteis às organizações, permitindo-lhes analisar dados, como registros de call center, postagens de redes sociais, de blogs, dados de CRM e demonstrativos de resultados.

Comentário: Vejamos uma definição forma de Big Data Analytics: "... é o trabalho analítico e inteligente de grandes volumes de dados, estruturados ou não-estruturados, que são coletados, armazenados e interpretados por softwares de altíssimo desempenho. Trata-se do cruzamento de uma infinidade de dados do ambiente interno e externo, gerando uma espécie de "bússola gerencial" para tomadores de decisão."

Vejam que a definição está plenamente de acordo com o texto da questão, nos habilitando a confirmar como correta a alternativa.

Gabarito: C

---

8. **Ano: 2018 Banca: CESPE Órgão: CGM de João Pessoa – PB Prova: Auditor Municipal de Controle Interno - Desenvolvimento de Sistemas**

A respeito de business intelligence, julgue o próximo item.

Situação hipotética: Um órgão público pretende fazer uma análise de big data com o objetivo de realizar mineração em grandes conjuntos de dados corporativos para localizar ou encontrar padrões ocultos, o que exigirá uma grande quantidade de processamento.

98276239072 - FABIANO CARBONELL DA SILVA

Assertiva: Nesse caso, há necessidade de contratação de um SaaS (software como serviço), que acrescentará uma camada adicional de integração com frameworks de desenvolvimento de aplicativos, recursos de middleware e funções como bancos de dados.

Comentário: Para respondermos a essa questão precisamos olhara para os conceitos de Infraestrutura, Plataforma e Software como serviço, vamos, primeiramente olhara para a figura a seguir:

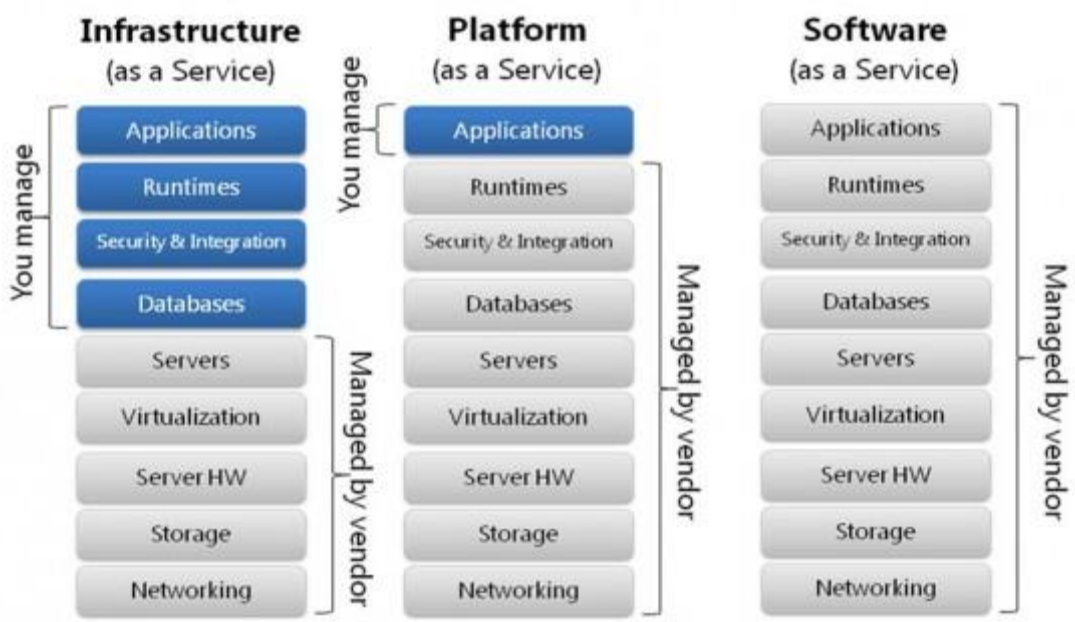

Gabarito: E.

...

Forte abraço e bons estudos.

"Hoje, o 'Eu não sei', se tornou o 'Eu ainda não sei'"

(Bill Gates)

Thiago Cavalcanti

Face: www.facebook.com/profthiagocavalcanti
Insta: www.instagram.com/prof.thiago.cavalcanti

98276239072 - FABIANO CARBONELL DA SILVA

YouTube: youtube.com/profthiagocavalcanti

98276239072 - FABIANO CARBONELL DA SILVA

ESSA LEI TODO MUNDO CONHECE:
PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.

1. Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.

2. Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).

3. Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).

4. Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).

5. Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).

6. Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).

7. Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.

8. O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.

Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.