Estratégia Concursos

Aula 19

PRF (Policial) Passo Estratégico de Informática

Autor:
Diego Carvalho

18 de Novembro de 2024

98276239072 - FABIANO CARBONELL DA SILVA

Índice

1) O que é mais cobrado no assunto - Big Data - CEBRASPE 3

2) Roteiro de Revisão - Big Data 4

3) Aposta Estratégica - Big Data 16

4) Questões Estratégicas - Big Data - CEBRASPE 17

5) Questionário de Revisão - Big Data 23

6) Lista de Questões Estratégicas - Big Data - CEBRASPE 32

7) Gabarito de Questões Estratégicas - Big Data - CEBRASPE 34

8) Referências Bibliográficas - Big Data 35

98276239072 - FABIANO CARBONELL DA SILVA

O QUE É MAIS COBRADO DENTRO DO ASSUNTO?

Considerando os tópicos que compõem o nosso assunto, possuímos a seguinte distribuição percentual:

TÓPICO	% DE COBRANÇA [CEBRASPE]
Conceitos Básicos	21%
Premissas	37%
NoSQL (Not Only SQL)	14%
Propriedades ACID/BASE	08%
Teorema CAP	06%
Arquitetura de Big Data	09%
Inteligência Artificial	05%

98276239072 - FABIANO CARBONELL DA SILVA

Roteiro de Revisão e Pontos do Assunto que Merecem Destaque

A ideia desta seção é apresentar um roteiro para que você realize uma revisão completa do assunto e, ao mesmo tempo, destacar aspectos do conteúdo que merecem atenção.

Vamos iniciar vendo a definição de diversos autores sobre Big Data:

AUTORES	DESCRIÇÃO
OXFORD ENGLISH DICTIONARY	Big Data é um dado de grande tamanho, tipicamente ao nível que sua manipulação e gerenciamento apresenta desafios significativos a logística.
DUMBILL E EDD	Big Data é o dado que excede a capacidade de processamento convencional dos sistemas de bancos de dados.
MAYER-SCHÖNBERGER E CUKIER'S	Big Data é a habilidade da sociedade de aproveitar a informação por novas maneiras para produzir introspecção úteis ou bens e serviços de valor significante.
INTERNATIONAL DATA CORPORATION	Big Data é uma nova geração de tecnologias e arquiteturas, projetadas economicamente para extrair valor de volumes muito grandes e vastos de dados, permitindo alta velocidade de captura, descoberta e análise.
KIM, TRIMI E JI-HYONG	Big Data é o termo geral para a enorme quantidade de dados digitais coletados a partir de todos os tipos de fontes.
MAHRT E SCHARKOW	Big Data denota um maior conjunto de dados ao longo do tempo, conjunto de dados estes que são grandes demais para serem manipulados por infraestruturas de armazenamento e processamento regulares.
DAVENPORT E KWON	Big Data são dados demasiadamente volumosos ou muito desestruturados para serem gerenciados e analisados através de meios tradicionais.
DI MARTINO	Big Data se refere ao conjunto de dados cujo tamanho está além da habilidade de ferramentas típicas de banco de dados em capturer, gerenciar e analisar.
RAJESH	Big Data são conjuntos de dados que são tão grandes que se tornam difíceis de trabalhar com o uso de ferramentas atualmente disponíveis.

O Data Lake é um grande repositório capaz de armazenar dados estruturados, semi-estruturados e não-estruturados, assim como um método para organizar grandes volumes de dados de diversos formatos e de diversas fontes diferentes. Vejamos a diferença entre Data Warehouse e Data Lake:

98276239072 - FABIANO CARBONELL DA SILVA

DATA WAREHOUSE	DATA LAKE
Dados geralmente são tratados (limpos, combinados, organizados, etc) antes de serem armazenados.	Dados geralmente são armazenados da maneira que foram capturados – brutos, sem nenhum tratamento.
Podem armazenar todos os tipos de dados, mas o foco é nos dados estruturados.	Armazenam dados estruturados, semi-estruturados e não-estruturados.
Ideal para usuários operacionais visto que as ferramentas analíticas são mais fáceis de usar.	Ideal para cientistas de dados visto que as ferramentas analíticas são mais difíceis de usar.
Armazenamento de dados custam geralmente mais caro e consome mais tempo.	Armazenamento de dados custam geralmente mais barato e consome menos tempo.
Um esquema é definido antes dos dados serem armazenados.	Um esquema é definido após os dados serem armazenados.
Armazenam um grande volume de dados.	Armazenam um gigantesco volume de dados.

O Big Data foi inicialmente conceituado a partir de três premissas básicas: Volume, Velocidade e Variedade (3 V's). Atualmente podemos afirmar que a definição pode ser quebrada em dimensões, quais sejam: Volume, Velocidade, Variedade, Veracidade e Valor. Existem autores que tratam até de 10V's (+Variabilidade, Validade, Vulnerabilidade, Volatilidade e Visualização), apesar de não ser provável cair em prova. Vejamos:

PREMISSAS	DESCRIÇÃO
VOLUME	Corresponde à grande quantidade de dados acumulada.
VELOCIDADE	Corresponde à rapidez na geração e obtenção de dados.
VARIEDADE	Corresponde à grande diversidade de tipos ou formas de dados.
VERACIDADE	Corresponde à confiança na geração e obtenção dos dados.
VALOR	Corresponde à utilidade e valor agregado ao negócio.

Vejamos as principais palavras-chave de cada dimensão/premissa:

VOLUME	VELOCIDADE	VALOR	VERACIDADE	VARIEDADE
Terabytes	Transmissão	Estatístico	Confiabilidade	Estruturado
Registros	Tempo Real	Hipóteses	Autenticidade	Não-Estruturado
Tabelas/Arquivos	Processos	Correlações	Origem/Reputação	Múltiplas Fontes

Vejamos agora os tipos de análise:

98276239072 - FABIANO CARBONELL DA SILVA

TIPO DE ANÁLISE	QUESTÃO?	DESCRIÇÃO
ANÁLISE DESCRITIVA	O QUE ACONTECEU?	Em vez de se focar no futuro, busca fazer uma fotografia do presente, para que decisões de cunho imediato possam ser tomadas com segurança. Ela trabalha com histórico de dados, cruzando informações com o objetivo de gerar um panorama claro e preciso dos temas relevantes para a empresa no presente momento. Exemplo: por meio do cruzamento de dados, conclui-se que determinada pessoa atualmente é identificada como má pagadora.
ANÁLISE DIAGNÓSTICA	POR QUE ACONTECEU?	O foco está na relação de causas e consequências percebidas ao longo do tempo, dentro de um determinado tema. Assim, a análise diagnóstica funciona baseada na coleta de dados relacionados a um determinado assunto, cruzando informações com o objetivo de entender quais fatores influenciaram o resultado atual. Exemplo: determinada pessoa nunca havia sido identificada como má pagadora – somente é agora porque ficou viúva recentemente.
ANÁLISE PREDITIVA	O QUE IRÁ ACONTECER?	Este tipo de análise é o mais indicado para quem precisa prever algum tipo de comportamento ou resultado. Esta técnica busca analisar dados relevantes ao longo do tempo, buscando padrões comportamentais e suas variações de acordo com cada contexto, a fim de prever como será o comportamento de seu público ou mercado no futuro, dadas as condições atuais. Exemplo: quanto estará o valor do dólar no ano que vem?
ANÁLISE PRESCRITIVA	O QUE DEVO FAZER?	Segue um modelo similar à Análise Preditiva, no entanto com objetivos ligeiramente diferentes. Em vez de tentar prever um determinado acontecimento, esta análise busca prever as consequências deste acontecimento. Exemplo: dado um aumento do valor do dólar no ano que vem, como isso poderá afetar as importações de matéria prima, consequentemente, o faturamento das vendas de determinada empresa.

Uma dúvida comum é sobre a diferença entre Business Intelligence, Big Data Analytics e Data Mining! Alguns autores consideram um é a evolução do anterior, abrangendo mais dados e ferramentas matemáticas/estatísticas; outros afirmam que – na verdade – é tudo a mesma coisa e que possuem nomes diferentes apenas por uma questão de marketing: vende mais dizer que uma ferramenta de software é uma solução de Big Data Analytics do que uma solução de Data Mining.

BIG DATA ANALYTICS É:	BIG DATA ANALYTICS NÃO É:
Uma estratégia baseada em tecnologia que permite coletar insights mais profundos e relevantes de clientes, parceiros e negócio, ganhando assim uma vantagem competitiva.	Somente tecnologia – no nível empresarial, refere-se a explorar fontes amplamente melhoradas de dados para adquirir insights.

98276239072 - FABIANO CARBONELL DA SILVA

Trabalhar com conjuntos de dados cujo porte e variedade estão além da habilidade de captura, armazenamento e análise de softwares de banco de dados típicos.	Somente volume – também se refere à variedade e à velocidade, mas – talvez mais importante – refere-se ao valor derivado dos dados.
Processamento de um fluxo contínuo de dados em tempo real, possibilitando a tomada de decisões sensíveis ao tempo mais rápido do que em qualquer outra época.	Mais gerada ou mais utilizada somente por grandes empresas online como Google ou Amazon. Embora as empresas de internet possam ter sido pioneiras no Big Data na escala web, aplicativos chegam a todas as indústrias.
Distribuído na natureza, isto é, o processamento de análise vai aonde estão os dados para maior velocidade e eficiência.	Uso de bancos de dados relacionais tradicionais de "tamanho único" criados com base em disco compartilhado e arquitetura de memória. Análise de Big Data usa uma rede de recursos de computação para processamento massivamente paralelo e escalável.
Um novo paradigma no qual a tecnologia da informação colabora com usuários empresariais e "cientistas de dados" para identificar e implementar análises que ampliam a eficiência operacional e resolvem novos problemas empresariais.	Um substituto de bancos de dados relacionais – dados estruturados continuam a ser de importância crítica para as empresas. No entanto, sistemas tradicionais podem não ter capacidade de manipular as novas fontes e contextos do Big Data.
Transferir a tomada de decisão dentro da empresa e permitir que pessoas tomem decisões melhores, mais rápidas e em tempo real.	

A tabela a seguir exibe as diferenças fundamentais entre NoSQL e SQL quanto ao modelo, armazenamento, flexibilidade, adequação, escalabilidade e exemplos de aplicações.

CRITÉRIO	NOSQL	SQL
MODELO	Não-Relacional	Relacional
ARMAZENAMENTO	Variados (Grafos, Documentos, etc)	Tabelas
FLEXIBILIDADE	Alta flexibilidade (Esquema indefinido)	Baixa flexibilidade (Esquema definido)
ADEQUAÇÃO	Mais adequado a dados não-estruturados	Mais adequado a dados estruturados
ESCALABILIDADE	Em geral, escalabilidade horizontal	Em geral, escalabilidade vertical
SGBD	MongoDB, Cassandra, HBase, Neo4J, etc	Oracle, MySQL, DB2, SQL Server, etc

98276239072 - FABIANO CARBONELL DA SILVA

Uma arquitetura de Big Data é projetada para lidar com a ingestão (consumo), processamento e análise de dados que são muito grandes ou complexos para sistemas de banco de dados tradicionais. O diagrama anterior mostra os componentes lógicos que se encaixam em uma arquitetura de Big Data. A maioria das arquiteturas de Big Data inclui alguns ou todos os seguintes componentes:

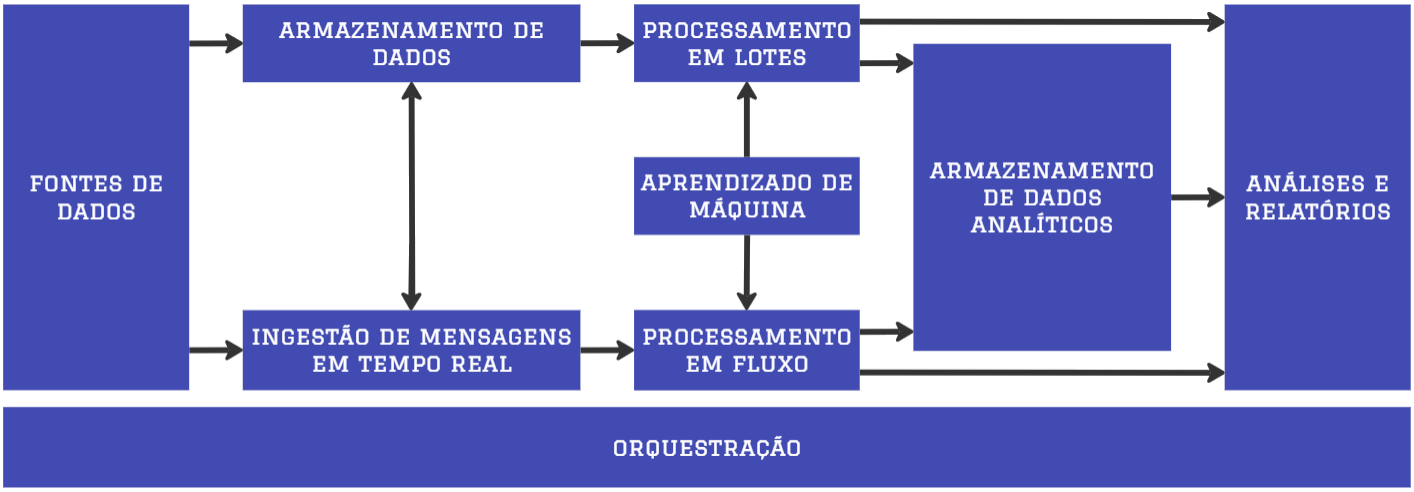

COMPONENTES	DESCRIÇÃO
FONTES DE DADOS	Incluem bancos de dados, arquivos de log e fontes em tempo real, como dispositivos IoT, que fornecem dados para soluções de Big Data.
ARMAZENAMENTO DE DADOS	Dados são armazenados em Data Lakes ou sistemas distribuídos, como Azure Data Lake ou BLOBs no Armazenamento do Azure, para suportar operações de grande escala.
PROCESSAMENTO EM LOTE	Processa grandes volumes de dados em lote, filtrando e agregando dados para análise, usando tecnologias como Hadoop, Spark e U-SQL no Azure.
INGESTÃO DE MENSAGENS EM TEMPO REAL	Captura e armazena mensagens de dados em tempo real usando hubs como Azure Event Hubs, IoT Hubs ou Kafka, atuando como buffer para processamento.
PROCESSAMENTO EM FLUXO	Processa dados de streaming em tempo real, filtrando e agregando para análise, usando tecnologias como Azure Stream Analytics, Storm ou Spark Streaming.
ARMAZENAMENTO DE DADOS ANALÍTICOS	Dados processados são armazenados para consultas e análise em Data Warehouses relacionais, NoSQL, Hive ou serviços como Azure Synapse Analytics.
ANÁLISE E RELATÓRIOS	Gera insights e relatórios interativos usando ferramentas como Power BI, Excel, ou Jupyter notebooks, capacitando cientistas e analistas de dados.

98276239072 - FABIANO CARBONELL DA SILVA

ORQUESTRAÇÃO	Automatiza fluxos de trabalho de dados, integrando processamento e movimentação de dados entre fontes e coletores, usando Azure Data Factory ou Apache Oozie.

ARQUITETURA LAMBDA

A arquitetura Lambda é uma arquitetura de processamento de dados projetada para lidar com grandes quantidades de dados, aproveitando os métodos de processamento em lote e o processamento em fluxo. Trata-se de uma abordagem híbrida que combina processamento em lote e em fluxo em uma única arquitetura unificada. A arquitetura lambda é resultado da demanda cada vez maior por processamento de dados em tempo real. O resultado final é uma arquitetura que pode processar de forma eficiente e eficaz dados históricos e dados online - ideal para aplicativos orientados a dados. A arquitetura é usada em muitos aplicativos de Big Data, incluindo mecanismos de recomendação, análise em tempo real, detecção de fraude e reconhecimento de imagem.

CAMADA DE LOTE	Responsável por armazenar e processar todos os dados do sistema em sua forma bruta. Trata-se de um armazenamento distribuído, tolerante a falhas, imutável (*append-only*) que armazena todos os dados no sistema, incluindo dados históricos – o resultado é armazenado como uma exibição em lote. Ele é usado para gerar um conjunto de dados mestre atualizado que pode ser consultado pelas camadas de velocidade e serviço.
CAMADA DE VELOCIDADE	Responsável por processar pequenos fluxos de dados e consultas em tempo real. Essa camada é responsável por fornecer acesso quase em tempo real aos dados usando tecnologias de processamento de fluxo. Ela é normalmente usada para processar eventos à medida que ocorrem e disponibilizar os resultados para consulta ou análise. Por fim, pode-se afirmar que ela reduz a latência em detrimento da precisão dos dados.
CAMADA DE SERVIÇO	Responsável por fornecer acesso de baixa latência às visualizações de dados pré-processadas para realização de consultas mais eficientes. É a camada que fornece os resultados da consulta aos consumidores de dados. Ela é normalmente um sistema somente leitura que responde com eficiência às consultas. As tecnologias comuns usadas nas camadas de serviço são índices de pesquisa, caches distribuídos e bancos de dados na memória.

98276239072 - FABIANO CARBONELL DA SILVA

ARQUITETURA KAPPA

A arquitetura Kappa é uma arquitetura de processamento de dados projetada para lidar com grandes volumes de dados em tempo real. É uma arquitetura baseada em fluxo que usa um conjunto de dados mestre único, que é atualizado e armazenado em tempo real. Essa arquitetura depende de um Data Lake imutável e microsserviços orientados a eventos para processar e armazenar dados. Ele foi projetado para ser horizontalmente escalável e tolerante a falhas, permitindo que as empresas processem dados de forma rápida e confiável com o mínimo de esforço. A arquitetura Kappa é usada para aplicativos como análise de dados, aprendizado de máquina, análise de streaming e tomada de decisão em tempo real.

CARACTERÍSTICAS DE BANCOS DE DADOS NÃO RELACIONAIS

Bancos de dados não relacionais não usam a estrutura tradicional baseada em tabela de bancos de dados relacionais como tabela, chave e valor.

Bancos de dados não relacionais geralmente são mais escaláveis horizontalmente do que os bancos de dados relacionais – é possível adicionar uma nova máquina ao cluster para aumentar a capacidade do sistema distribuído.

Bancos de dados não relacionais geralmente usam modelos de dados mais simples, como pares chave-valor ou documentos, para lidar melhor com dados complexos não estruturados.

Bancos de dados não relacionais geralmente usam arquiteturas distribuídas, que permitem processamento de consultas mais rápido e maior disponibilidade.

Bancos de dados não relacionais geralmente usam estruturas de dados mais flexíveis, como JSON, que permite uma integração de dados mais dinâmica.

Bancos de dados não relacionais geralmente fornecem melhor desempenho e escalabilidade do que os bancos de dados relacionais tradicionais para diversas atividades.

Bancos de dados não relacionais geralmente fornecem mais flexibilidade na modelagem de dados, permitindo que os desenvolvedores modifiquem sua estrutura de dados com mais rapidez e facilidade.

Bancos de dados não relacionais geralmente usam linguagens de consulta NoSQL, que – em regra – são mais fáceis de aprender do que SQL.

Bancos de dados não relacionais geralmente requerem menos manutenção do que os bancos de dados relacionais tradicionais.

Bancos de dados não relacionais geralmente usam diferentes tecnologias de armazenamento, como armazenamento baseado em nuvem, para lidar melhor com grandes conjuntos de dados.

98276239072 - FABIANO CARBONELL DA SILVA

Bancos de dados não relacionais geralmente fornecem diferentes recursos de pesquisa do que os bancos de dados relacionais tradicionais, mas eventualmente podem ser mais ineficientes.
Bancos de dados não relacionais geralmente oferecem melhor suporte para processamento e streaming de dados em tempo real.
Bancos de dados não relacionais podem frequentemente ser usados em conjunto com bancos de dados relacionais tradicionais para lidar melhor com dados complexos.
Bancos de dados não relacionais permitem a inserção de dados a qualquer momento sem a necessidade de definir previamente um esquema ou por meio de um esquema flexível.
Bancos de dados não relacionais normalmente não impõem regras de integridade de dados, o que pode levar a erros e inconsistência de dados – o que geralmente não ocorre com bancos de dados relacionais.

TÉCNICAS	DESCRIÇÃO
REPLICAÇÃO	Cópia de dados para múltiplos servidores, aumentando a disponibilidade e escalabilidade, permitindo acesso a mais usuários e garantindo continuidade se um servidor falhar.
PARTICIONAMENTO (FRAGMENTAÇÃO)	Divisão lógica de uma tabela em partes menores, armazenadas em servidores diferentes, melhorando a performance ao permitir processamento paralelo. Pode ser vertical, horizontal ou híbrido.
SHARDING	Divisão de um banco de dados em "shards" (partições menores), distribuindo os dados por múltiplos servidores, o que melhora a escalabilidade e a performance do sistema.
HASHING CONSISTENTE	Algoritmo de distribuição de dados entre servidores de forma balanceada e tolerante a falhas, assegurando que os dados estejam acessíveis mesmo em caso de falhas.
VIEWS MATERIALIZADAS	Exibições predefinidas de dados armazenadas para acelerar consultas, eliminando a necessidade de processar os dados a partir de suas fontes originais.
INDEXAÇÃO	Criação de índices que organizam os dados, permitindo consultas rápidas e eficiente recuperação de dados, especialmente em grandes volumes de informação.
CACHE	Armazenamento temporário de dados em locais de acesso rápido, como a RAM, para acelerar o tempo de resposta e facilitar a recuperação imediata dos dados requisitados.

O **Modelo Orientado a Chave-Valor** é uma estrutura de banco de dados NoSQL onde os dados são armazenados como pares de chave e valor. A chave atua como um identificador único, enquanto o valor pode ser qualquer tipo de dado, como texto, números ou objetos. Esse modelo é simples, altamente escalável e eficiente para consultas rápidas, sendo amplamente utilizado em aplicações que exigem desempenho e flexibilidade, como caches e armazenamento de sessão.

98276239072 - FABIANO CARBONELL DA SILVA

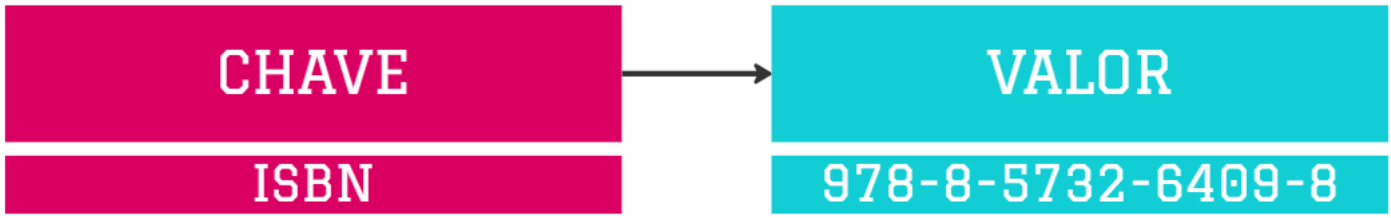

CARACTERÍSTICAS	DESCRIÇÃO
SEM ESQUEMA	Modelos de chave-valor não necessitam definir uma estrutura de tabela ou colunas antes que os dados sejam armazenados.
FÁCIL DE USAR	Devido à simplicidade do banco de dados, os dados podem aceitar qualquer tipo de dados, até mesmo tipos diferentes, quando necessário.
RÁPIDO TEMPO DE RESPOSTA	Seu tempo de resposta é rápido devido à sua simplicidade, visto que o restante ambiente próximo a ele é muito construído e aprimorado.
ESCALABILIDADE E DISPONIBILIDADE	Os dados são distribuídos em vários nós, o que fornece escalabilidade e melhor disponibilidade.

O **Modelo Orientado a Colunas** é um tipo de banco de dados NoSQL onde os dados são armazenados em formato de colunas, ao invés de linhas. Cada coluna contém dados associados a uma chave, e múltiplas colunas podem ser agrupadas em famílias de colunas. Esse modelo é altamente eficiente para consultas analíticas que processam grandes volumes de dados, sendo amplamente utilizado em DW e Big Data devido à sua capacidade de leitura e escrita rápidas.

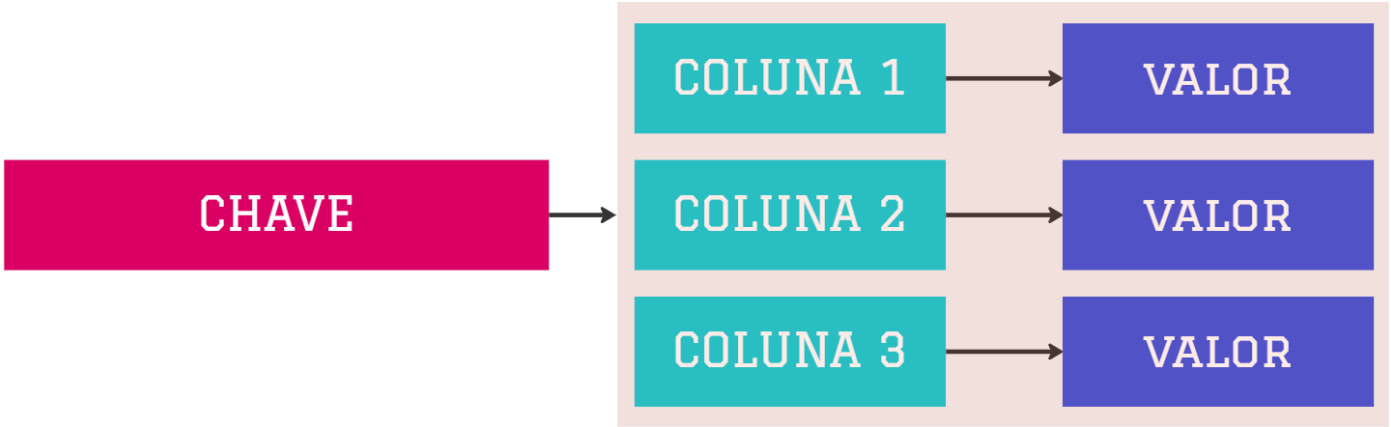

CARACTERÍSTICAS	DESCRIÇÃO
OTIMIZADO PARA LEGIBILIDADE	Modelos orientados a colunas são otimizados para legibilidade, permitindo leituras mais rápidas e eficientes.
ALTAMENTE ESCALÁVEL	Modelos orientados a colunas são altamente escaláveis e podem acomodar grandes conjuntos de dados de forma rápida e fácil.
MODELO DE DADOS FLEXÍVEL	A flexibilidade do modelo de dados de um modelo orientado a colunas permite alterações de esquema mais rápidas e fáceis.

98276239072 - FABIANO CARBONELL DA SILVA

BAIXA LATÊNCIA	Os modelos orientados a colunas oferecem baixa latência ao consultar dados, pois os dados podem ser armazenados em várias colunas em vez de uma longa linha.
ALTA DISPONIBILIDADE	Os modelos orientados a colunas geralmente são projetados para alta disponibilidade e podem ser replicados em vários nós.

O **Modelo Orientado a Documentos** é um tipo de banco de dados NoSQL que armazena dados em documentos, geralmente no formato JSON, XML ou BSON. Cada documento é uma unidade autossuficiente que contém pares de chave-valor e pode incluir estruturas aninhadas, oferecendo flexibilidade na modelagem de dados. Esse modelo é ideal para aplicações que lidam com dados não estruturados/semiestruturados, como sistemas de gerenciamento de conteúdo e e-commerce.

CARACTERÍSTICAS	DESCRIÇÃO
MODELO DE DADOS FLEXÍVEL	Modelos orientados a documentos são mais flexíveis do que os bancos de dados relacionais tradicionais, pois não têm esquemas e podem acomodar dados com estruturas variadas.
ALTA ESCALABILIDADE	Modelos orientados a documentos são altamente escaláveis e podem acomodar conjuntos de dados maiores com facilidade.
ALTO DESEMPENHO	Modelos orientados a documentos são muito eficientes em termos de recuperação de dados e fornecem alto desempenho.
ALTA DISPONIBILIDADE	Modelos orientados a documentos são altamente disponíveis e podem lidar com várias solicitações simultâneas.
FÁCIL DE USAR	Modelos orientados a documentos são relativamente fáceis de usar, pois usam uma linguagem de consulta simples para manipulação de dados.

O **Modelo Orientado a Grafos** é um tipo de banco de dados NoSQL que representa dados como nós (entidades), arestas (relações) e propriedades (atributos). Ele é projetado para capturar e consultar relacionamentos complexos entre dados de forma eficiente. Esse modelo é ideal para aplicações como redes sociais, sistemas de recomendação e análise de fraudes, onde as conexões entre entidades são fundamentais para a análise e processamento.

CARACTERÍSTICAS	DESCRIÇÃO DE MODELOS DE BANCOS DE DADOS ORIENTADOS A GRAFOS
SEM ESQUEMA	São projetados para armazenar dados sem esquema predefinido, permitindo modelos de dados flexíveis e evolução do esquema.
ALTAMENTE CONECTADO	Seguindo as relações entre os dados, os bancos de dados orientados a grafos podem facilmente percorrer e consultar dados conectados de maneiras complexas.
ALTAMENTE ESCALÁVEL	Permitem o dimensionamento de dados com facilidade e a capacidade de adicionar rapidamente mais nós e relacionamentos.

98276239072 - FABIANO CARBONELL DA SILVA

DESEMPENHO DE CONSULTA RÁPIDA	Projetados para consultar rapidamente dados com relacionamentos complexos e acessar os dados em uma fração do tempo dos bancos de dados tradicionais.
BAIXA LATÊNCIA	Podem acessar dados rapidamente e responder em um ambiente de baixa latência, permitindo aplicações em tempo real.

Propriedades BASE são características de bancos de dados NoSQL que priorizam escalabilidade e disponibilidade, representando: Basic Availability, Soft-state, e Eventual Consistency. Já as propriedades ACID, comuns em bancos de dados relacionais, garantem a integridade das transações por meio de: Atomicidade, Consistência, Isolamento, e Durabilidade. ACID foca em transações seguras; BASE, em performance e flexibilidade.

PROPRIEDADES ACID	DESCRIÇÃO
ATOMICIDADE	Requer que todas as operações de banco de dados que formam uma transação sejam todas bem-sucedidas ou todas falhem.
CONSISTÊNCIA	Requer que qualquer transação leve o banco de dados de um estado válido para outro.
ISOLAMENTO	Garante que a execução simultânea de transações não afete os resultados de nenhuma das transações.
DURABILIDADE	Afirma que os resultados de uma transação devem persistir mesmo se o sistema falhar.

PROPRIEDADES BASE	DESCRIÇÃO
BASICAMENTE DISPONÍVEL	Significa que o sistema sempre aceitará solicitações, mesmo que não seja capaz de processá-las imediatamente.
ESTADO SUAVE	Significa que o sistema não precisa manter um estado constante e pode eventualmente convergir para um estado consistente.
EVENTUALMENTE CONSISTENTE	Significa que o sistema pode não responder a uma solicitação imediatamente, mas eventualmente convergirá para um estado consistente.

O **Teorema CAP** afirma que um sistema de banco de dados distribuído pode garantir no máximo dois dos três seguintes atributos simultaneamente: Consistência (todos os nós veem os mesmos dados ao mesmo tempo), Disponibilidade (o sistema responde a todas as requisições, mesmo que alguns nós estejam inativos) e Tolerância a Partições (o sistema continua funcionando, mesmo com falhas na comunicação entre os nós). Esse teorema orienta o design de sistemas distribuídos.

CARACTERÍSTICA	DESCRIÇÃO
CONSISTÊNCIA	Significa que todos os clientes veem os mesmos dados ao mesmo tempo, não importa em qual nó eles se conectem. Para que isso aconteça, sempre que os dados forem gravados em um nó, ele deve ser instantaneamente encaminhado ou replicado para todos os outros nós do sistema antes que a gravação seja considerada "bem-sucedida".

98276239072 - FABIANO CARBONELL DA SILVA

DISPONIBILIDADE	Significa que qualquer cliente que fizer uma solicitação de dados obterá uma resposta, mesmo que um ou mais nós estejam desativados. Ou seja, todos os nós em funcionamento no sistema distribuído retornam uma resposta válida para qualquer solicitação, sem exceção.
TOLERÂNCIA DE PARTIÇÃO	A partição é uma quebra de comunicações dentro de um sistema distribuído, uma conexão perdida ou temporariamente lenta entre dois nós. Tolerância de partição significa que o cluster deve continuar a funcionar mesmo de ocorrer uma ou mais falhas de comunicação entre os nós no sistema.

98276239072 - FABIANO CARBONELL DA SILVA

APOSTA ESTRATÉGICA

A ideia desta seção é apresentar os pontos do conteúdo que mais possuem chances de serem cobrados em prova, considerando o histórico de questões da banca em provas de nível semelhante à nossa, bem como as inovações no conteúdo, na legislação e nos entendimentos doutrinários e jurisprudenciais.

Eu listei abaixo os pontos com maior probabilidade de cobrança no contexto de **Big Data**. Estas são as minhas apostas:

1. Aposto que haverá questões sobre a **definição de Big Data**, que se refere a conjuntos de dados tão grandes e complexos que exigem tecnologias e arquiteturas específicas para processamento.

2. Vale revisar as 5 dimensões do Big Data (os 5 Vs): **Volume**, **Velocidade**, **Variedade**, **Veracidade** e **Valor**, que descrevem as principais características dos dados nesse contexto.

3. Pode cair uma questão sobre **Data Warehouse** e **Data Lake**, destacando a diferença entre o armazenamento tratado e organizado no Data Warehouse e os dados brutos e sem tratamento no Data Lake.

4. Aposto em questões sobre **ETL (Extract, Transform, Load)** e **ELT (Extract, Load, Transform)**, focando em como esses processos movem e preparam dados para análise.

5. Vale revisar o conceito de Big Data Analytics, que envolve a análise preditiva de grandes volumes de dados para **identificar padrões e gerar insights valiosos para negócios**.

6. Aposto em perguntas sobre **NoSQL**, um tipo de banco de dados não relacional usado em Big Data, e suas vantagens em comparação com os bancos de dados tradicionais para manipulação de grandes volumes de dados.

7. Questões sobre **Arquiteturas de Big Data** podem abordar os componentes principais como fontes de dados, armazenamento, processamento em lote e em tempo real, análise e relatórios.

8. Aposto que a **escalabilidade horizontal e vertical** no processamento de Big Data será tema de questões, explicando como aumentar a capacidade de armazenamento e processamento de dados.

98276239072 - FABIANO CARBONELL DA SILVA

QUESTÕES ESTRATÉGICAS

Nesta seção, apresentamos e comentamos uma amostra de questões objetivas selecionadas estrategicamente: são questões com nível de dificuldade semelhante ao que você deve esperar para a sua prova e que, em conjunto, abordam os principais pontos do assunto.

A ideia, aqui, não é que você fixe o conteúdo por meio de uma bateria extensa de questões, mas que você faça uma boa revisão global do assunto a partir de, relativamente, poucas questões.

1. (CESPE / SEPLAN-RR - 2023) Variedade, em big data, refere-se à quantidade de fontes que geram os dados com potencial de serem altamente desestruturados.

Comentários:

Perfeito! A variedade, em big data, diz respeito à diversidade de tipos e formatos de dados, além da capacidade de lidar com dados provenientes de várias fontes.

Gabarito: Correto

2. (CESPE / SEPLAN-RR - 2023) Big data somente se aplica a dados não estruturados.

Comentários:

Big Data abrange não apenas dados não estruturados, mas também dados estruturados e semi-estruturados. O foco está na capacidade de lidar com grandes volumes de dados, independentemente de sua estrutura, e extrair insights e valor desses dados.

Gabarito: Errado

3. (CESPE / TCE-SC - 2022) Big data necessitam de algoritmos de computação mais robustos em comparação aos algoritmos tradicionais de banco de dados, que não são capazes de lidar com os volumes de dados representados em big data.

Comentários:

Perfeito! A natureza volumosa e complexa dos conjuntos de dados de big data exige abordagens e algoritmos de processamento mais robustos do que aqueles tradicionalmente utilizados em bancos de dados convencionais. Os algoritmos tradicionais muitas vezes não são adequados para lidar eficientemente com os volumes e velocidades de dados característicos do Big Data, tornando necessária a adoção de métodos específicos, como algoritmos distribuídos, sistemas de processamento paralelo e tecnologias de armazenamento escalável, para enfrentar os desafios inerentes a esse domínio de processamento de dados.

Gabarito: Correto

98276239072 - FABIANO CARBONELL DA SILVA

4. (CESPE / SECONT-ES - 2022) Kappa, uma arquitetura de software usada para processar dados, fornece acesso a métodos de processamento em lote e processamento de fluxo com uma abordagem em quatro camadas.

Comentários:

A arquitetura Kappa é uma arquitetura de processamento de dados projetada para lidar com grandes volumes de dados em tempo real – ela não suporta processamento em lote (*batch*). Além disso, temos duas camadas: Camada de Real-Time (Velocidade) e Camada de Serviço.

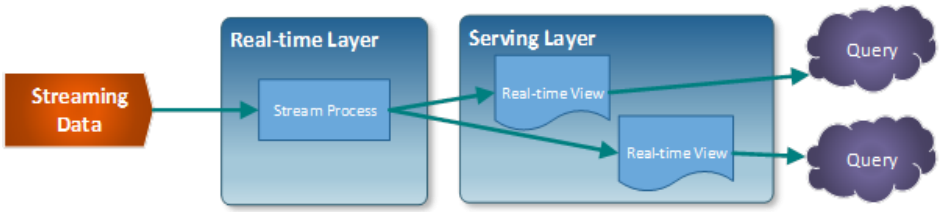

Gabarito: Errado

5. (CESPE / SEFAZ-SE – 2022) Com relação a noções de big data, julgue os itens que se seguem.

I Como qualquer tecnologia, soluções de big data também apresentam algumas restrições. Por exemplo, elas não podem ser utilizadas na área da saúde para determinar a causa de uma doença, porque esse é um procedimento complexo que somente pode ser executado por pessoas devidamente capacitadas – nesse caso, os médicos.

II Big data é qualquer tipo de fonte de dados que possui, no mínimo, as seguintes três características: volume de dados extremamente grande; velocidade de dados extremamente alta; e variedade de dados extremamente ampla.

III Para que as organizações obtenham os conhecimentos corretos, a tecnologia big data não permite que elas executem as operações de armazenar e administrar as grandes quantidades de dados de si próprias.

IV Big data é uma combinação de tecnologias de gestão de dados que evoluíram ao longo dos anos, razão por que não é considerado um mercado único.

Estão certos apenas os itens:

a) I e III
b) I e IV
c) II e IV
d) II e V
e) III e V

Comentários:

98276239072 - FABIANO CARBONELL DA SILVA

(I) Errado. Que viagem! Big Data não só pode como já é muito utilizado na área de saúde; (II) Correto. Há versões que consideram tanto 3V's quanto 5V's; (III) Errado. Não há restrições para que organizações executem operações de armazenamento e administração; (IV) Correto. Atualmente é considerado um grande conjunto de tecnologias que envolve diversas áreas de conhecimento.

Gabarito: Letra C

6. (CESPE / PETROBRAS – 2022) Em sistemas NoSQL baseados em armazenamento de chavevalor, a chave é multidimensional e composta pela combinação do nome de tabela com a chave linha-coluna e com o rótulo de data e hora.

Comentários:

No modelo chave-valor, a chave é bidimensional e composta pela combinação de um identificador alfanumérico único (chave) e um valor associado em uma tabela (valor). Em outras palavras, esse modelo armazena dados por meio de uma estrutura de mapeamento ou dicionário, em que todo dado armazenado possui uma chave identificadora e seu valor em si – para cada chave de entrada, é retornado um valor de saída.

Gabarito: Errado

7. (CESPE / TCE-RJ - 2021) Os fatores críticos de sucesso da análise de Big Data incluem uma sólida infraestrutura de dados, além de ferramentas analíticas e pessoal habilitado para lidar com elas.

Comentários:

Questão com interpretação bem ampla e genérica. É claro que é necessário ter infraestrutura de dados, ferramentas e pessoas para que a análise de Big Data tenha sucesso! Uma infraestrutura de dados fornece o armazenamento, o poder de processamento e a tecnologia necessários para coletar, armazenar, gerenciar, analisar e visualizar dados. Sem uma forte infraestrutura de dados, seria difícil adquirir, gerenciar e analisar grandes quantidades de dados. As ferramentas analíticas são usadas para coletar, armazenar e processar dados para gerar insights e responder a perguntas, tais como Apache Hadoop, Apache Spark, Tableau e Microsoft Azure. Por fim, requer pessoas que tenham habilidades e conhecimentos para entender e analisar grandes quantidades de dados. Pessoas com experiência em ciência de dados, estatística, programação e inteligência de negócios são necessárias para entender os dados e usá-los para fundamentar decisões.

Gabarito: Correto

8. (CESPE / SEFAZ-AL - 2021) Sistemas NoSQL com fundamento em documentos possuem um modelo de dados simples embasado no acesso rápido pela palavra; os resultados estão relacionados à informação e podem ser encontrados percorrendo-se os textos usando-se expressões regulares.

Comentários:

98276239072 - FABIANO CARBONELL DA SILVA

Em um modelo de banco de dados orientado a documentos, as pesquisas funcionam comparando os valores nos documentos com os critérios de consulta. Os documentos no banco de dados podem ser pesquisados usando uma variedade de critérios, incluindo conteúdo, rótulos e propriedades. Quando uma pesquisa é realizada, o banco de dados pesquisa todos os documentos, extraindo os documentos que correspondem aos critérios da consulta. Os resultados da pesquisa são retornados ao usuário na forma de uma lista de documentos que correspondem à consulta. Logo, não há nenhuma relação com expressões regulares, que são basicamente padrões de pesquisa usados para procurar e manipular texto.

Gabarito: Errado

9. (CESPE / ISS-Aracaju – 2021) Big data ajudou a sedimentar o cargo de cientista de dados. Entre as funções desse cargo inclui-se:

a) a modelagem estruturada.
b) a análise retrospectiva.
c) a modelagem não estruturada.
d) a modelagem relacional.
e) o processamento comparativo.

Comentários:

Questão bizarra! Todos os itens podem ser executados por um cientista de dados. *Ele não pode fazer uma modelagem relacional?* Claro que pode! De toda forma, essa questão foi retirada do livro do Taurion (2013), em que ele diferencia Analista de BI e Cientista de Dados.

ANALISTA DE BI	CIENTISTA DE DADOS
Cognos, Modelo Relacional, Banco de Dados SQLServer, Oracle, DB2.	Hadoop, Modelos Relacionais e NoSQL, bancos e dados não relacionais e in-memory.
Modelagem Relacional/Estruturada.	Inclui também modelagem não estruturada. Modelagem analítica é essencial.
Desenvolve queries estruturadas sobre dados passados.	Cria perguntas e busca relacionamentos entre fatos aparentemente desconexos.

Em primeiro lugar, o autor não é uma unanimidade; em segundo lugar, o autor não disse que essas eram atividades exclusivas de cada papel. Logo, não se trata de atividades taxativas!

Gabarito: Letra C

10. (CESPE / SERPRO – 2021) No que se refere aos três Vs do Big Data, o termo volume refere-se a dados que, atualmente, não são estruturados nem armazenados em tabelas relacionais, o que torna sua análise mais complexa.

Comentários:

98276239072 - FABIANO CARBONELL DA SILVA

O termo "volume" refere-se à quantidade massiva de dados gerados, independentemente de serem estruturados ou não. A análise de dados não estruturados pode ser mais complexa, mas o conceito de volume está relacionado à quantidade de dados, não ao formato ou estrutura.

Gabarito: Errado

11. (CESPE / SERPRO – 2021) Big data caracteriza-se, principalmente, por volume, variedade e velocidade, o que se justifica devido ao fato de os dados serem provenientes de sistemas estruturados, que são maioria, e de sistemas não estruturados, os quais, embora ainda sejam minoria, vêm, ao longo dos anos, crescendo consideravelmente.

Comentários:

Big Data se caracteriza por volume, variedade e velocidade, porém, os dados provenientes de sistemas não estruturados já superam os estruturados. A maior parte dos dados atualmente gerados é não estruturada, como mídias sociais, imagens e vídeos, diferentemente do que a afirmação sugere.

Gabarito: Errado

12. (CESPE / SERPRO – 2021) Uma das principais características de big data é que seu custo de armazenamento de dados é relativamente baixo se comparado a um data warehouse.

Comentários:

Pode parecer contraintuitivo, mas o Data Warehouse possui um custo de armazenamento realmente maior em relação ao Big Data – esse é mais otimizado para armazenar gigantescos volumes de dados do que aquele.

Gabarito: Correto

13. (CESPE / TCE-RJ – 2021) Em Big Data, a premissa volume refere-se à capacidade de processar, em um ambiente computacional, diferentes tipos e formatos de dados, como fotos, vídeos e geolocalização.

Comentários:

A premissa mencionada refere-se à variedade, e não ao volume. A "variedade" trata dos diferentes tipos e formatos de dados (estruturados, semiestruturados e não estruturados). Já o "volume" se refere à quantidade massiva de dados gerados e armazenados.

Gabarito: Errado

14. (CESPE / TCE-RJ – 2021) Volume, variedade e visualização são as três características, conhecidas como 3 Vs, utilizadas para definir Big Data.

Comentários:

98276239072 - FABIANO CARBONELL DA SILVA

As três características iniciais do Big Data são volume, variedade e velocidade, não visualização. Visualização pode ser importante, mas não faz parte dos 3 Vs originais. As três características definem a grande quantidade, diversidade e rapidez dos dados.

Gabarito: Errado

15. (CESPE / Polícia Federal – 2021) As aplicações de bigdata caracterizam-se exclusivamente pelo grande volume de dados armazenados em tabelas relacionais.

Comentários:

Big data é caracterizado por cinco principais atributos: volume, variedade, velocidade, valor e veracidade. Logo, definir Big Data apenas pelo grande volume de dados armazenados em tabelas relacionais é uma visão limitada e não abrange a totalidade do conceito.

PREMISSAS	DESCRIÇÃO
VOLUME	Corresponde à grande quantidade de dados acumulada.
VELOCIDADE	Corresponde à rapidez na geração e obtenção de dados.
VARIEDADE	Corresponde à grande diversidade de tipos ou formas de dados.
VERACIDADE	Corresponde à confiança na geração e obtenção dos dados.
VALOR	Corresponde à utilidade e valor agregado ao negócio.

Em suma: Volume é apenas um dos cinco V's do Big Data! Ele também se caracteriza pela Veracidade, Velocidade, Valor e Variedade. Além disso, os dados são armazenados em diferentes formatos e, não apenas, tabelas relacionais.

Gabarito: Errado

98276239072 - FABIANO CARBONELL DA SILVA

Questionário de Revisão e Aperfeiçoamento

A ideia do questionário é elevar o nível da sua compreensão no assunto e, ao mesmo tempo, proporcionar uma outra forma de revisão de pontos importantes do conteúdo, a partir de perguntas que exigem respostas subjetivas.

São questões um pouco mais desafiadoras, porque a redação de seu enunciado não ajuda na sua resolução, como ocorre nas clássicas questões objetivas.

O objetivo é que você realize uma autoexplicação mental de alguns pontos do conteúdo, para consolidar melhor o que aprendeu ;)

Além disso, as questões objetivas, em regra, abordam pontos isolados de um dado assunto. Assim, ao resolver várias questões objetivas, o candidato acaba memorizando pontos isolados do conteúdo, mas muitas vezes acaba não entendendo como esses pontos se conectam.

Assim, no questionário, buscaremos trazer também situações que ajudem você a conectar melhor os diversos pontos do conteúdo, na medida do possível.

É importante frisar que não estamos adentrando em um nível de profundidade maior que o exigido na sua prova, mas apenas permitindo que você compreenda melhor o assunto de modo a facilitar a resolução de questões objetivas típicas de concursos, ok?

Nosso compromisso é proporcionar a você uma revisão de alto nível! Vamos ao nosso questionário:

Perguntas

1. **O que é Big Data?**
2. **Quais são os cinco Vs do Big Data?**
3. **O que é volume no contexto de Big Data?**
4. **O que significa a velocidade no Big Data?**
5. **Qual é a importância da variedade no Big Data?**
6. **O que é veracidade em Big Data?**
7. **O que significa valor no Big Data?**
8. **O que é Big Data Analytics?**
9. **Quais são os tipos de análise de dados?**

98276239072 - FABIANO CARBONELL DA SILVA

10. O que é análise descritiva?
11. O que é análise preditiva?
12. O que é análise prescritiva?
13. O que é análise diagnóstica?
14. Como a análise preditiva é usada em negócios?
15. O que é um Data Warehouse?
16. O que é um Data Lake?
17. Qual é a diferença entre Data Warehouse e Data Lake?
18. Qual a função de um cientista de dados no Big Data?
19. O que é computação em nuvem?
20. Como a computação em nuvem se relaciona com Big Data?
21. O que é mineração de dados?
22. Qual é a importância da análise em tempo real?
23. O que são dados estruturados?
24. O que são dados semiestruturados?
25. O que são dados não estruturados?
26. O que é NoSQL?
27. Qual é a função de algoritmos em Big Data?
28. Como os bancos de dados NoSQL diferem dos relacionais?
29. O que é Hadoop?
30. O que é MapReduce?
31. O que é machine learning em Big Data?
32. Como a inteligência artificial auxilia no Big Data?
33. O que é arquitetura de Big Data?

98276239072 - FABIANO CARBONELL DA SILVA

34. O que é processamento em lote?
35. O que é processamento em tempo real?
36. Como a Netflix usa Big Data?
37. Como o Google Maps utiliza Big Data?
38. O que é um sistema distribuído em Big Data?
39. O que é tolerância a falhas em Big Data?
40. O que são bancos de dados orientados a grafos?
41. O que é um modelo de chave-valor?
42. O que é o CAP Theorem?
43. O que é consistência eventual?
44. O que é replicação de dados?
45. Como o Facebook utiliza Big Data?
46. O que é Data Mining?
47. O que é um Data Scientist?
48. O que é elasticidade em sistemas de Big Data?
49. Como os governos utilizam Big Data?
50. O que é análise de sentimento?

98276239072 - FABIANO CARBONELL DA SILVA

Perguntas com Respostas

1. O que é Big Data?

Big Data refere-se a grandes volumes de dados que não podem ser processados por sistemas tradicionais, exigindo novas tecnologias para extração de valor e insights.

2. Quais são os cinco Vs do Big Data?

Volume, Velocidade, Variedade, Veracidade e Valor são as cinco características fundamentais que definem Big Data.

3. O que é volume no contexto de Big Data?

Refere-se à quantidade massiva de dados gerada a cada segundo, como e-mails, transações e postagens nas redes sociais.

4. O que significa a velocidade no Big Data?

A velocidade refere-se à rapidez com que os dados são gerados e precisam ser processados em tempo real, como transações financeiras.

5. Qual é a importância da variedade no Big Data?

A variedade abrange diferentes tipos de dados, incluindo estruturados, semiestruturados e não estruturados, como vídeos e e-mails.

6. O que é veracidade em Big Data?

Veracidade trata da qualidade e confiabilidade dos dados, garantindo que sejam verdadeiros e representem a realidade atual.

7. O que significa valor no Big Data?

Valor refere-se à utilidade dos dados para uma organização, garantindo que grandes volumes de dados gerem benefícios claros.

8. O que é Big Data Analytics?

É o processo de estudar e interpretar grandes volumes de dados com o objetivo de extrair padrões de comportamento e tendências relevantes.

9. Quais são os tipos de análise de dados?

Análise descritiva, diagnóstica, preditiva e prescritiva são os quatro principais tipos de análise usados para interpretar dados.

98276239072 - FABIANO CARBONELL DA SILVA

10. O que é análise descritiva?

A análise descritiva cria uma "fotografia" do presente, baseada no histórico de dados, para ajudar na tomada de decisões imediatas.

11. O que é análise preditiva?

A análise preditiva usa dados históricos para prever resultados futuros, identificando padrões e tendências comportamentais.

12. O que é análise prescritiva?

Ela foca em prever as consequências de um evento, ajudando empresas a tomarem decisões baseadas em possíveis impactos futuros.

13. O que é análise diagnóstica?

Análise diagnóstica identifica as causas de eventos ou comportamentos observados, cruzando dados para determinar fatores influentes.

14. Como a análise preditiva é usada em negócios?

A análise preditiva ajuda as empresas a antecipar mudanças de mercado e ajustar suas estratégias com base em padrões de comportamento.

15. O que é um Data Warehouse?

É um sistema de armazenamento de dados estruturados, que organiza e trata as informações antes de seu uso para análise.

16. O que é um Data Lake?

Data Lake é um repositório que armazena dados brutos, não tratados, sejam eles estruturados, semiestruturados ou não estruturados.

17. Qual é a diferença entre Data Warehouse e Data Lake?

Um Data Warehouse organiza dados tratados e estruturados, enquanto o Data Lake armazena dados brutos e sem tratamento prévio.

18. Qual a função de um cientista de dados no Big Data?

Cientistas de dados analisam grandes volumes de dados para extrair insights valiosos que possam influenciar decisões estratégicas.

19. O que é computação em nuvem?

98276239072 - FABIANO CARBONELL DA SILVA

É a prática de usar servidores remotos na internet para armazenar, gerenciar e processar dados, em vez de servidores locais.

20. Como a computação em nuvem se relaciona com Big Data?

A computação em nuvem fornece a infraestrutura escalável necessária para lidar com o armazenamento e processamento de grandes volumes de dados.

21. O que é mineração de dados?

Mineração de dados é o processo de explorar grandes conjuntos de dados para identificar padrões e insights úteis para os negócios.

22. Qual é a importância da análise em tempo real?

A análise em tempo real permite que empresas respondam rapidamente a dados à medida que são gerados, essencial em mercados dinâmicos.

23. O que são dados estruturados?

Dados estruturados são organizados em um formato fixo, como planilhas e bancos de dados, facilitando o acesso e a análise.

24. O que são dados semiestruturados?

São dados que possuem algum nível de organização, como e-mails e arquivos XML, mas não seguem um modelo rígido como os estruturados.

25. O que são dados não estruturados?

Dados não estruturados não têm uma organização definida e incluem vídeos, imagens, textos livres e publicações em redes sociais.

26. O que é NoSQL?

NoSQL é um tipo de banco de dados que permite armazenar e acessar grandes volumes de dados não estruturados e semiestruturados.

27. Qual é a função de algoritmos em Big Data?

Algoritmos são usados para analisar e processar grandes volumes de dados de forma eficiente, extraindo padrões e insights valiosos.

28. Como os bancos de dados NoSQL diferem dos relacionais?

NoSQL não requer esquemas rígidos como os bancos de dados relacionais, tornando-se mais flexível para lidar com dados de diversas formas.

98276239072 - FABIANO CARBONELL DA SILVA

29. O que é Hadoop?

Hadoop é uma plataforma de software que permite o processamento distribuído de grandes volumes de dados através de clusters de computadores.

30. O que é MapReduce?

MapReduce é um modelo de programação usado no Hadoop para processar grandes volumes de dados distribuídos em várias máquinas.

31. O que é machine learning em Big Data?

Machine learning é o uso de algoritmos que permitem a uma máquina aprender com dados e melhorar suas previsões ao longo do tempo.

32. Como a inteligência artificial auxilia no Big Data?

A inteligência artificial ajuda a automatizar a análise de grandes volumes de dados, identificando padrões e fazendo previsões de forma eficiente.

33. O que é arquitetura de Big Data?

É o design da infraestrutura necessária para coletar, processar e analisar grandes volumes de dados que excedem a capacidade dos sistemas tradicionais.

34. O que é processamento em lote?

Processamento em lote refere-se à análise de grandes volumes de dados em intervalos definidos, ao invés de em tempo real.

35. O que é processamento em tempo real?

Processamento em tempo real permite analisar e agir sobre dados imediatamente após sua geração, crucial em mercados dinâmicos.

36. Como a Netflix usa Big Data?

A Netflix analisa padrões de comportamento dos usuários para personalizar recomendações e melhorar a experiência de visualização.

37. Como o Google Maps utiliza Big Data?

O Google Maps utiliza dados de trânsito e localização em tempo real de milhões de usuários para prever condições de tráfego.

38. O que é um sistema distribuído em Big Data?

98276239072 - FABIANO CARBONELL DA SILVA

Um sistema distribuído armazena e processa dados em vários servidores simultaneamente, aumentando a capacidade de lidar com grandes volumes de dados.

39. O que é tolerância a falhas em Big Data?

Tolerância a falhas é a capacidade de um sistema de continuar funcionando corretamente, mesmo que parte da infraestrutura falhe.

40. O que são bancos de dados orientados a grafos?

Bancos de dados orientados a grafos focam nos relacionamentos entre entidades, permitindo a modelagem de dados interconectados de forma eficiente.

41. O que é um modelo de chave-valor?

É um tipo de banco de dados NoSQL que armazena dados em pares de chave e valor, permitindo acessos rápidos.

42. O que é o CAP Theorem?

O teorema CAP define que um banco de dados distribuído só pode garantir dois dos três princípios: consistência, disponibilidade e tolerância à partição.

43. O que é consistência eventual?

Consistência eventual é uma propriedade dos sistemas distribuídos onde os dados se tornam consistentes após algum tempo, não imediatamente.

44. O que é replicação de dados?

Replicação é o processo de criar cópias de dados em vários servidores para garantir alta disponibilidade e tolerância a falhas.

45. Como o Facebook utiliza Big Data?

O Facebook analisa dados de usuários em tempo real para personalizar anúncios e melhorar a experiência de navegação na plataforma.

46. O que é Data Mining?

Data Mining envolve a extração de padrões e conhecimento a partir de grandes volumes de dados, usados para melhorar decisões empresariais.

47. O que é um Data Scientist?

Data Scientist é o profissional responsável por extrair, analisar e interpretar grandes volumes de dados para fornecer insights estratégicos.

98276239072 - FABIANO CARBONELL DA SILVA

48. O que é elasticidade em sistemas de Big Data?

Elasticidade refere-se à capacidade de expandir ou reduzir recursos computacionais de acordo com a demanda de processamento de dados.

49. Como os governos utilizam Big Data?

Governos utilizam Big Data para detectar fraudes, otimizar serviços públicos e prever crises econômicas ou sociais com base em tendências.

50. O que é análise de sentimento?

Análise de sentimento examina grandes volumes de dados, como postagens em redes sociais, para determinar as emoções associadas a um tema ou produto.

98276239072 - FABIANO CARBONELL DA SILVA

Lista de Questões Estratégicas

1. **(CESPE / SEPLAN-RR - 2023) Variedade, em big data, refere-se à quantidade de fontes que geram os dados com potencial de serem altamente desestruturados.**

2. **(CESPE / SEPLAN-RR - 2023) Big data somente se aplica a dados não estruturados.**

3. **(CESPE / TCE-SC - 2022) Big data necessitam de algoritmos de computação mais robustos em comparação aos algoritmos tradicionais de banco de dados, que não são capazes de lidar com os volumes de dados representados em big data.**

4. **(CESPE / SECONT-ES - 2022) Kappa, uma arquitetura de software usada para processar dados, fornece acesso a métodos de processamento em lote e processamento de fluxo com uma abordagem em quatro camadas.**

5. **(CESPE / SEFAZ-SE – 2022) Com relação a noções de big data, julgue os itens que se seguem.**

   I Como qualquer tecnologia, soluções de big data também apresentam algumas restrições. Por exemplo, elas não podem ser utilizadas na área da saúde para determinar a causa de uma doença, porque esse é um procedimento complexo que somente pode ser executado por pessoas devidamente capacitadas – nesse caso, os médicos.

   II Big data é qualquer tipo de fonte de dados que possui, no mínimo, as seguintes três características: volume de dados extremamente grande; velocidade de dados extremamente alta; e variedade de dados extremamente ampla.

   III Para que as organizações obtenham os conhecimentos corretos, a tecnologia big data não permite que elas executem as operações de armazenar e administrar as grandes quantidades de dados de si próprias.

   IV Big data é uma combinação de tecnologias de gestão de dados que evoluíram ao longo dos anos, razão por que não é considerado um mercado único.

   Estão certos apenas os itens:

   a) I e III
   b) I e IV
   c) II e IV
   d) II e V
   e) III e V

6. **(CESPE / PETROBRAS – 2022) Em sistemas NoSQL baseados em armazenamento de chavevalor, a chave é multidimensional e composta pela combinação do nome de tabela com a chave linha-coluna e com o rótulo de data e hora.**

98276239072 - FABIANO CARBONELL DA SILVA

7. **(CESPE / TCE-RJ - 2021) Os fatores críticos de sucesso da análise de Big Data incluem uma sólida infraestrutura de dados, além de ferramentas analíticas e pessoal habilitado para lidar com elas.**

8. **(CESPE / SEFAZ-AL - 2021) Sistemas NoSQL com fundamento em documentos possuem um modelo de dados simples embasado no acesso rápido pela palavra; os resultados estão relacionados à informação e podem ser encontrados percorrendo-se os textos usando-se expressões regulares.**

9. **(CESPE / ISS-Aracaju – 2021)** Big data ajudou a sedimentar o cargo de cientista de dados. Entre as funções desse cargo inclui-se:

   a) a modelagem estruturada.
   b) a análise retrospectiva.
   c) a modelagem não estruturada.
   d) a modelagem relacional.
   e) o processamento comparativo.

10. **(CESPE / SERPRO – 2021) No que se refere aos três Vs do Big Data, o termo volume refere-se a dados que, atualmente, não são estruturados nem armazenados em tabelas relacionais, o que torna sua análise mais complexa.**

11. **(CESPE / SERPRO – 2021) Big data caracteriza-se, principalmente, por volume, variedade e velocidade, o que se justifica devido ao fato de os dados serem provenientes de sistemas estruturados, que são maioria, e de sistemas não estruturados, os quais, embora ainda sejam minoria, vêm, ao longo dos anos, crescendo consideravelmente.**

12. **(CESPE / SERPRO – 2021) Uma das principais características de big data é que seu custo de armazenamento de dados é relativamente baixo se comparado a um data warehouse.**

13. **(CESPE / TCE-RJ – 2021) Em Big Data, a premissa volume refere-se à capacidade de processar, em um ambiente computacional, diferentes tipos e formatos de dados, como fotos, vídeos e geolocalização.**

14. **(CESPE / TCE-RJ – 2021) Volume, variedade e visualização são as três características, conhecidas como 3 Vs, utilizadas para definir Big Data.**

15. **(CESPE / Polícia Federal – 2021) As aplicações de bigdata caracterizam-se exclusivamente pelo grande volume de dados armazenados em tabelas relacionais.**

98276239072 - FABIANO CARBONELL DA SILVA

GABARITO

1. CORRETO
2. ERRADO
3. CORRETO
4. ERRADO
5. LETRA C
6. ERRADO
7. CORRETO
8. ERRADO
9. LETRA C
10. ERRADO
11. ERRADO
12. CORRETO
13. ERRADO
14. ERRADO
15. ERRADO

98276239072 - FABIANO CARBONELL DA SILVA

Referências Bibliográficas

MAYER-SCHÖNBERGER, Viktor; CUKIER, Kenneth. Big Data: A Revolution That Will Transform How We Live, Work, and Think. Boston: Houghton Mifflin Harcourt, 2013.

MARZ, Nathan; WARREN, James. Big Data: Principles and best practices of scalable real-time data systems. Shelter Island: Manning Publications, 2015.

ZIKOS, Angelos. Big Data: From data to information and knowledge. Cham: Springer, 2021.

98276239072 - FABIANO CARBONELL DA SILVA

ESSA LEI TODO MUNDO CONHECE:
PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.

1. Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.

2. Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).

3. Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).

4. Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).

5. Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).

6. Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).

7. Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.

8. O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.

Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.